



UNIVERSIDAD MAYOR DE SAN SIMÓN
FACULTAD DE CIENCIAS Y TECNOLOGÍA



DIRECCIÓN DE POSGRADO

DIPLOMADO ESTADÍSTICA APLICADA A LA TOMA DE DECISIONES

TERCERA VERSIÓN

MODELO PREDICTIVO DE CLASIFICACIÓN DE CHURN BASADO EN PATRONES DE CONTACTO PARA UNA STARTUP BOLIVIANA

**PROYECTO PRESENTADO PARA OBTENER EL GRADO DE LICENCIATURA EN
INGENIERÍA INDUSTRIAL
MODALIDAD DOBLE TITULACIÓN**

POSTULANTE : FLAVIA MAYLIN DAVILA PEREZ

TUTOR : M.SC. ING. DANNY LUIS HUANCA SEVILLA

Cochabamba – Bolivia

2025

MODELO PREDICTIVO DE CLASIFICACIÓN DE CHURN BASADO EN PATRONES DE CONTACTO PARA UNA STARTUP BOLIVIANA

Por

Flavia Maylin Davila Pérez

El presente documento, Trabajo de Grado es presentado a la Dirección de Posgrado de la Facultad de Ciencias y Tecnología en cumplimiento parcial de los requisitos para la obtención del grado académico de Licenciatura (o sólo diplomado) en Ingeniería Industrial, modalidad Doble Titulación, habiendo cursado el Diplomado ‘Estadística Aplicada a la Toma de Decisiones’ propuesta por el Centro de Estadística Aplicada (CESA) en su tercera versión.

ASESOR/TUTOR

M.Sc. Ing. Danny Luis Huanca Sevilla

COMITÉ DE EVALUACIÓN

Ing. M.Sc. Ronald Edgar Patiño Tito. (Presidente)

Ing. M.Sc. Guillen Salvador Roxana,. (Coordinador)

Ing. M.Sc. Oscar Contreras Carrasco (Tribunal)

Ing. M.Sc. Wilson Orlando Trujillo Aranibar (Tribunal)



DIRECCIÓN DE POSGRADO, FACULTAD DE CIENCIAS Y TECNOLOGIA

Cochabamba, Bolivia

Aclaración

Este documento describe el trabajo realizado como parte del programa de estudios de Diplomado ‘Estadística Aplicada a la Toma de Decisiones’ en el Centro de Estadística Aplicada CESA y la Dirección de Posgrado de la Facultad de Ciencias y Tecnología. Todos los puntos de vista y opiniones expresadas en el mismo son responsabilidad exclusiva del autor y no representan necesariamente las de la institución.

Resumen

Las startups bolivianas desempeñan un papel clave en el desarrollo económico y tecnológico del país, al ofrecer soluciones innovadoras en diversos sectores. Para una startup, la reducción el riesgo de ‘churn’ es muy importante, ya que enfrentan un entorno altamente competitivo y en constante cambio.

En el contexto de la startup objeto de este proyecto, el ‘Churn Comercial’ se refiere a la pérdida de clientes ocurrida 90 días después de una conversión exitosa. El objetivo es identificar los factores clave en los patrones de contacto de los clientes para generar insights aplicables a otras startups similares en Bolivia, además de ofrecer recomendaciones estratégicas alineadas con la visión de la empresa, para mejorar la retención de clientes y fomentar su crecimiento.

El proyecto se enfoca en el análisis predictivo de ‘Churn Comercial’ basado en patrones de contacto para una startup con un modelo de negocio B2B y un producto del tipo SaaS del estado plurinacional de Bolivia. La metodología utilizada en el desarrollo de este proyecto abarca desde la obtención de los datos hasta la implementación y mejora de modelos predictivos de machine learning.

Se extrajeron datos desde la API del CRM donde la startup boliviana aloja sus datos, aplicando el enfoque de procesamiento de datos de la arquitectura Medallion. Se tomaron en cuenta los datos de las actividades y características de los negocios, obtenidos entre 2021 y 2024, con un enfoque en los clientes del territorio boliviano.

El desarrollo del proyeto siguió los lineamientos y la estructura metodológica de minería de datos CRISP-DM, la cual comprende el entendimiento del negocio, la obtención de los datos y su entendimiento, su procesamiento para su posterior uso en el modelado, evaluación y mejora de modelos predictivos de churn comercial en una startup boliviana.

Los resultados obtenidos Los resultados obtenidos en las métricas de evaluación globales de los modelos entrenados demuestran la eficiencia tanto del modelo Decision Tree Classifier como del XGBoost Classifier al procesar datos limitados con clases binarias desbalanceadas. Aunque los modelos Logistic Regression y Complement Naive Bayes también lograron buenos resultados, el Decision Tree Classifier sobresale por su alta precisión en la diferenciación de clases, con un AUC-ROC de 97%, precisión global del 80%, Recall del 84%, y F1-Score del 81%, mostrando un desempeño equilibrado. Por su parte, el modelo XGBoost presenta un rendimiento sólido con un AUC-ROC de 95.59%, precisión global del 77%, Recall del 96%, y F1-Score del 83%. Estos resultados destacan la capacidad de los modelos de árboles de decisión para predecir efectivamente el abandono de clientes, superando a otros modelos en discriminación entre clases y en la identificación de casos relevantes.

Palabras clave

Startup, churn, predicción, patrones de contacto, machine learning

*A mi luz, mi guía, pilar de valores y maestros en la vida, por estar a mi
lado en cada etapa de mi vida apoyándome y brindándome amor
incondicional, gracias mamá y papá.*

Agradecimientos

A mi persona por darme los ánimos y la motivación cada día de poder seguir adelante y poder lograr mis objetivos personales, por dar lo mejor de mí siempre y por mi resiliencia ante las situaciones más adversas

A mi familia, por brindarme su compañía y motivación a lo largo de esta etapa de mi vida.

A los amigos que fueron parte de este proceso, por motivarme y acompañarme en la realización de este proyecto y aportar con su positivismo a mi vida.

A la startup boliviana por confiarme sus datos y permitirme brindarles este proyecto como un aporte a su crecimiento.

A la prestigiosa Universidad Mayor de San Simón por permitirme formarme a lo largo de estos años y darme los mejores años académicos de mi vida, permitiéndome encontrarme y descubrir mis capacidades

A la Dirección de Posgrado de la Facultad de Ciencias y Tecnología por darme la oportunidad de cursar este posgrado y la oportunidad de aprender de primera mano de expertos en el área ayudándome a mejorar mis skills y darme herramientas con las que podré aportar al desarrollo de mi país.

Tabla de contenidos

1.	Introducción.....	1
1.1.	Antecedentes.....	1
1.2.	Justificación.....	3
1.3.	Planteamiento del problema.....	3
1.4.	Objetivo general.....	5
1.4.1.	Objetivos específicos.....	5
2.	Marco teórico.....	6
2.1.	Inteligencia Artificial (IA).....	6
2.2.	Machine Learning.....	6
2.3.	Modelos predictivos de Machine Learning.....	7
2.3.1.	Modelos predictivos de clasificación.....	7
2.3.2.	EDA (Exploratory Data Analysis).....	15
2.3.3.	Variable destino o etiqueta.....	16
2.4.	Modelo CRISP-DM (Cross Industry Standard Process for Data Mining).....	16
2.5.	StartUps.....	16
2.5.1.	Características de una startup.....	17
2.6.	Software As A Service (SaaS).....	17
2.7.	Ciclo de vida de un cliente.....	18
2.7.1.	Churn.....	18
2.8.	CRM (Customer Relationship Management).....	19
2.9.	Arquitectura Medallion.....	19
2.9.1.	Capas (Bronce, Plata y Oro).....	20
2.10.	Descripción estadística.....	20
2.10.1.	Media.....	20
2.10.2.	Mediana (Me).....	21
2.10.3.	Moda (Mo).....	21

2.10.4.	Mínimo (Min) y Máximo (Max).....	21
2.10.5.	Rango	21
2.10.6.	Varianza.....	21
2.10.7.	Desviación estándar	21
2.10.8.	Correlación.....	22
2.10.9.	Prueba Chi-Cuadrado	22
2.10.10.	Prueba ANOVA.....	22
2.11.	Python en la Ciencia de Datos	23
2.11.1.	Manipulación de datos con Python.....	23
2.11.2.	Aprendizaje Automático con Python.....	23
2.11.3.	Métricas de Evaluación.....	24
2.11.4.	Métodos de ajuste y optimización de modelos	27
3.	Marco metodológico	29
3.1.	Área de estudio	29
3.2.	Flujograma metodológico	29
3.3.	Fuentes de información	31
3.3.1.	Fuente de datos primaria: PipeDrive CRM.....	31
3.3.2.	Fuentes de datos secundarias.....	31
3.4.	Comprensión del negocio.....	31
3.4.1.	Objetivos del negocio.....	31
3.4.2.	Situación actual de la startup.....	32
3.4.3.	Procesos actuales de la empresa	32
3.4.4.	Recursos y Restricciones	33
3.5.	Extracción de datos.....	33
3.5.1.	Capas de la arquitectura Medallion.....	33
3.5.2.	Entendimiento de los datos	34
3.6.	Análisis y preparación de los datos	37
3.6.1.	Análisis Exploratorio de Datos (EDA)	37
3.6.2.	Preparación de los datos.....	60

3.7.	Entrenamiento de Modelos	61
3.7.1.	Análisis del problema.....	61
3.7.2.	Selección de Algoritmos.....	61
3.7.3.	Etapa Preliminar de Implementación	61
3.8.	Evaluación y selección del modelo	64
3.8.1.	Evaluación preliminar de modelos.....	64
3.8.2.	Selección del modelo	78
4.	Resultados y Discusión	79
4.1.	Entendimiento de las necesidades y objetivos.....	79
4.2.	Extracción y comprensión de los datos	80
4.3.	Análisis y proceso de datos.....	80
4.4.	Entrenamiento de Modelos	81
4.4.1.	Resultados de la Evaluación: Modelo Complement Naive Bayes.....	82
4.4.2.	Resultados de Evaluación: Modelo Logistic Regression.....	84
4.4.3.	Resultados de la Evaluación: Modelo Decision Tree Classifier	86
4.4.4.	Resultados de la Evaluación: Modelo Random Forest Classifier.....	89
4.4.5.	Resultados de la Evaluación: Modelo XGBoost.....	91
4.4.6.	Resultados globales del entrenamiento	93
4.5.	Selección del modelo predictivo	98
4.5.1.	Importancia de Variables.....	98
4.6.	Discusión de resultados	99
5.	Conclusiones	102
6.	Recomendaciones	105
	Referencias bibliográficas.....	107
	Anexos.....	112
Anexo 1.	Estructura de trabajo: Arquitectura MEDALLION	112
Anexo 2.	Procesamiento de datos capa Bronce.....	113
Anexo 3.	Procesamiento de datos capa Plata (subcapa de estandarización).....	114
Anexo 4.	Procesamiento de datos capa Plata (subcapa de filtrado)	115

Anexo 5.	Procesamiento de datos capa Plata (subcapa de enriquecimiento)	116
Anexo 6.	Procesamiento de datos capa Oro.....	117
Anexo 7.	Análisis exploratorio de datos.....	118
Anexo 8.	Entrenamiento de Modelos.....	119
Anexo 9.	Data Frame resultante de la extracción de datos	120
Anexo 10.	Instrucciones para la reproducción del modelo.....	120
Anexo 11.	CD	121

Lista de figuras

Figura 1-1 Comparación entre ‘Churn’ y ‘Churn Comercial’ a lo largo del tiempo.....	4
Figura 1-2 Comparación entre ‘Churn’ y ‘Churn Comercial’ Gestión 2024.....	5
Figura 2-1 Clasificación de algoritmos de Machine Learning.....	6
Figura 2-2 Ciclo de vida de un cliente vs el trabajo de Marketing en cada etapa.....	18
Figura 2-3 Estructura de la Arquitectura Medallion	20
Figura 2-4 Grafico de Curva ROC	26
Figura 2-5 Grafico de Curva ROC	26
Figura 2-6 Ejemplo de One Hot Encoding.....	28
Figura 3-1 Mapa de distribución de clientes en Bolivia	29
Figura 3-2 Flujograma metodológico	30
Figura 3-3 Diagrama del ciclo de vida de un cliente en los procesos de la startup.....	32
Figura 3-4 Diagrama de Entidad Relación.....	35
Figura 3-5 Histograma de distribución de la variable ‘Total_Actividades_com’	44
Figura 3-6 Histograma de distribución de la variable ‘Total_Llamadas_com’	44
Figura 3-7 Histograma de distribución de la variable ‘Llamadas_Efectivas_com’	44
Figura 3-8 Histograma de distribución de la variable ‘Llamadas_No_Efectivas_com’	45
Figura 3-9 Histograma de distribución de la variable ‘WA_Seguimiento_com’	45
Figura 3-10 Histograma de distribución de la variable ‘Reuniones_Hechas’	46
Figura 3-11 Histograma de distribución de la variable ‘Reuniones_Canceladas’	46
Figura 3-12 Histograma de distribución de la variable ‘Total_Actividades_com’	46
Figura 3-13 Histograma de distribución de la variable ‘Total_Llamadas_exp’	47
Figura 3-14 Histograma de distribución de la variable ‘Llamadas_Efectivas_exp’	47
Figura 3-15 Histograma de distribución de la variable ‘Llamadas_No_Efectivas_exp’	48
Figura 3-16 Histograma de distribución de la variable ‘WA_Seguimiento_com’	48
Figura 3-17 Histograma de distribución de la variable ‘Kickoff_Hechas’	48
Figura 3-18 Histograma de distribución de la variable ‘Kickoff _Canceladas’	49
Figura 3-19 Histograma de distribución de la variable ‘Capacitaciones_Hechas’	49

Figura 3-20 Histograma de distribución de la variable ‘Capacitaciones_Canceladas’.....	50
Figura 3-21 Grafica de barras de ‘Tipo de cliente’	50
Figura 3-22 Grafica de barras de '(C) (EXP) Plazo y Pago'	51
Figura 3-23 Grafica de barras de ‘Tipo Primer Contacto’	51
Figura 3-24 Grafica de barras de ‘Rango de Contacto’.....	52
Figura 3-25 Grafica de barras de ‘R1yR2’	52
Figura 3-26 Grafica de barras de ‘Tipo Primera Capacitación’	53
Figura 3-27 Grafica de barras de ‘Onboarding’	53
Figura 3-28 Grafica de barras de ‘Churn Comercial’	54
Figura 3-29 Boxplots de ‘Llamadas_Efectivas_com’ vs ‘Churn Comercial’	54
Figura 3-30 Boxplots de ‘Total_Actividades_exp’ vs ‘Churn Comercial’	55
Figura 3-31 Boxplots de ‘Llamadas_No_Efectivas _exp’ vs ‘Churn Comercial’	55
Figura 3-32 Boxplots de Capacitaciones ‘Hechas’ y ‘Canceladas’ vs ‘Churn Comercial’	56
Figura 3-33 Matriz de correlación de Pearson entre variables numéricas.....	56
Figura 3-34 Matriz de correlación de Pearson entre variables numéricas seleccionadas.....	62
Figura 3-35 Comparación de distribución de clases antes y después del balance SMOTE	67
Figura 3-36 Matriz de confusión ComplementNaiveBayes antes y después de aplicar SMOTE	68
Figura 3-37 Matriz de confusión LogisticRegression antes y después de aplicar SMOTE.....	69
Figura 3-38 Matriz de confusión DecisionTreeClassifier antes y después de aplicar SMOTE	71
Figura 3-39 Matriz de confusión RandomForestClassifier antes y después de aplicar SMOTE.....	72
Figura 3-40 Matriz de confusión XGBoostClassifier antes y después de aplicar SMOTE.....	73
Figura 4-1 Comportamiento de ‘Churn Comercial’ en comparación a 'Churn' a lo largo del tiempo.....	79
Figura 4-2 Comportamiento de ‘Churn Comercial’ en comparación a 'Churn' Gestión 2024.....	79
Figura 4-3 Boxplots de total de actividades entre embudos vs Churn Comercial	80
Figura 4-4 Comparación de Exactitud entre modelos antes y después de ajustes.....	81
Figura 4-5 Comparación de Precisión entre modelos antes y después de ajustes.....	82
Figura 4-6 Matriz de Confusión Modelo Complement Naive Bayes.....	83
Figura 4-7 Curvas de aprendizaje Modelo Complement Naive Bayes.....	84
Figura 4-8 Matriz de Confusión Modelo Logistic Regression.....	85

Figura 4-9	Curvas de aprendizaje Modelo Logistic Regression	86
Figura 4-10	Matriz de Confusión Modelo Decision Tree Classifier	87
Figura 4-11	Curvas de aprendizaje Modelo Decision Tree Classifier	88
Figura 4-12	Matriz de Confusión Modelo Random Forest.....	89
Figura 4-13	Curvas de aprendizaje Modelo Random Forest	91
Figura 4-14	Matriz de Confusión Modelo XGBoost.....	92
Figura 4-15	Curvas de aprendizaje Modelo XGBoost Classifier.....	93
Figura 4-16	Precisión Global entre Modelos.....	94
Figura 4-17	Precisión Global entre Modelos.....	94
Figura 4-18	Comparación de AUC-ROC entre modelos	95
Figura 4-19	Comparación de métricas de evaluación entre modelos.....	100
Figura 4-20	Comparación de porcentaje de churn entre proyectos	100
Figura 4-21	Gráfica de barras de estados de cuentas.....	101

Lista de tablas

Tabla 3-1 Descripción de los datos.....	35
Tabla 3-2 Descripción de los campos de la tabla de la subcapa plata de enriquecimiento.	37
Tabla 3-3 Detalle de las variables cualitativas	38
Tabla 3-4 Detalle de las variables cuantitativas.....	38
Tabla 3-5 Detalle de las variables cuantitativas del embudo comercial.....	39
Tabla 3-6 Detalle de las variables cuantitativas del embudo experiencia.....	41
Tabla 3-7 Detalle de las variables cualitativas.....	43
Tabla 3-8 Prueba Chi-Cuadrado para variables cualitativas	57
Tabla 3-9 Prueba ANOVA para variables cuantitativas	59
Tabla 3-10 Métricas del modelo Complement Naive Bayes antes y después de aplicar SMOTE	68
Tabla 3-11 Métricas del modelo Logistic Regression antes y después de aplicar SMOTE	69
Tabla 3-12 Métricas del modelo DecisionTreeClassifier antes y después de aplicar SMOTE	70
Tabla 3-13 Métricas del modelo RandomForestClassifier antes y después de aplicar SMOTE.....	71
Tabla 3-14 Métricas del modelo XGBoostClassifier antes y después de aplicar SMOTE.....	72
Tabla 4-1 Métricas de Evaluación Modelo Naive Bayes	83
Tabla 4-2 Métricas de Evaluación Modelo Logistic Regression.....	85
Tabla 4-3 Mettricas de Evaluación Modelo Decision Tree	88
Tabla 4-4 Métricas de Evaluación Modelo Random Forest	90
Tabla 4-5 Métricas de Evaluación Modelo XGBoost.....	92
Tabla 4-6 Métricas de evaluación de todos los modelos ‘macro avg’.....	96
Tabla 4-7 Métricas de evaluación de todos los modelos ‘weighted avg’.....	97
Tabla 4-8 Comparación de métricas de evaluación entre proyectos	99

1. Introducción

En el entorno empresarial actual, las startups enfrentan el desafío constante de mantener una alta tasa de retención de clientes. Este reto es especialmente relevante en mercados dinámicos, donde los rápidos avances tecnológicos y la alta rotación de clientes exigen estrategias ágiles y efectivas. En este contexto, el fenómeno conocido como ‘churn’, que se refiere a la pérdida de clientes tras una conversión exitosa, representa un obstáculo importante para el crecimiento acelerado, una de las principales características que definen a una startup. Dentro del contexto de la startup sobre la que se desarrolló el proyecto, el ‘Churn Comercial’ se define como la pérdida de clientes que ocurre dentro de los 90 días posteriores a una conversión exitosa.

Comprender las causas del ‘Churn Comercial’ y anticipar su ocurrencia es fundamental para diseñar estrategias que no solo mejoren las tasas de retención, sino que también eleven la calidad de la experiencia del cliente. El objetivo del proyecto es desarrollar un modelo predictivo de ‘Churn Comercial’ basado en técnicas de machine learning, siguiendo los lineamientos de la metodología CRISP-DM. El modelo buscará identificar patrones y variables clave que permitan prevenir el abandono de clientes.

El desarrollo del modelo se enfoca en detectar patrones relacionados con la contactabilidad en el embudo comercial de los clientes, con el propósito de diseñar estrategias específicas que reduzcan el ‘Churn Comercial’ durante la etapa de experiencia. La automatización de este proceso permitirá abordar el problema de forma eficiente, mejorando no solo las tasas de retención, sino también la capacidad de tomar decisiones basadas en datos.

Mediante esta solución, la startup podrá posicionarse como una organización innovadora y centrada en el cliente, lo que fortalecerá la relación con sus consumidores y garantizará un crecimiento sostenible a largo plazo.

1.1. Antecedentes

Vivimos en la era de la revolución del conocimiento, cuando el poder de una nación no se determina por el número de soldados en su ejército, sino por el conocimiento que posee. (Negnevitsky, 2005). Los avances tecnológicos cada vez requieren de personas altamente calificadas para poder desarrollar para poder mejorar la calidad de vida de las personas, sin embargo, en la actualidad, este trabajo se está derivando a las ‘Máquinas Inteligentes’ que a lo largo de los años han logrado adquirir el conocimiento y experiencia de personas altamente calificadas y resolver todo tipo de tareas, desde tareas sencillas hasta tareas bastante específicas y complejas.

El aprendizaje automático, mejor conocido como ‘Machine Learning’, se categoriza como un subcampo de la Inteligencia Artificial. Básicamente el aprendizaje automático implica la construcción de modelos matemáticos para ayudar a comprender los datos (VanderPlas, 2017).

El análisis predictivo emplea modelos estadísticos y algoritmos para analizar datos históricos, con el objetivo de predecir eventos futuros. (IBM, Análisis predictivos, 2024). Actualmente el análisis predictivo ha ganado gran relevancia en múltiples sectores desde el ámbito empresarial y la medicina, hasta el marketing y el turismo entre otras disciplinas, el análisis predictivo se ha convertido en una herramienta esencial para anticipar tendencias, identificar patrones y optimizar la toma de decisiones.

Bolivia, conocida por su cultura conservadora y tradicional, enfrenta desafíos al incorporar tecnologías como la inteligencia artificial en los procesos empresariales debido a una tradición marcada por la desinformación y resistencia al cambio. Sin embargo, en este contexto, el uso innovador del análisis predictivo puede ser un factor clave para anticiparse a las necesidades de los clientes y optimizar servicios, logrando así una ventaja competitiva dentro del mercado. Para ello, es fundamental la comprensión de cómo esta herramienta puede fortalecer su posición en el mercado y adaptarse a un entorno en constante cambio.

El análisis predictivo se ha consolidado como una herramienta esencial para que las startups y empresas de tecnología en Bolivia optimicen sus operaciones y tomen decisiones estratégicas basadas en datos. Su implementación permite no solo anticipar las necesidades de los clientes, sino también mejorar la eficiencia de los servicios y consolidar una ventaja competitiva en el mercado. Para evaluar la efectividad de estos modelos predictivos, es crucial centrarse en las métricas de rendimiento utilizadas.

Un estudio realizado por (Urrelo, 2024) emplea modelos de aprendizaje supervisado para identificar las condiciones que influyen en la decisión de abandono por parte de los clientes en una empresa de alojamiento web. En esta investigación, se destacan métricas como la precisión, el recall y la puntuación F1 para evaluar el rendimiento de los modelos predictivos. Estas métricas proporcionan una base metodológica relevante que puede ser aplicada en el sector tecnológico boliviano, permitiendo a las startups desarrollar estrategias más efectivas para mejorar la retención de usuarios y optimizar su crecimiento.

Asimismo, la investigación de (A. K. Mishra, 2017) analiza el abandono de clientes en una empresa de software como servicio (SaaS), destacando la importancia de identificar patrones de comportamiento que preceden a la pérdida de clientes. Este estudio resalta la utilización de métricas como el área bajo la curva ROC (AUC-ROC) y la precisión para evaluar la efectividad de los modelos predictivos en la identificación de clientes propensos al abandono.

La elección adecuada de estas métricas es fundamental para garantizar que los modelos predictivos sean efectivos y contribuyan al éxito de las estrategias empresariales en el sector tecnológico boliviano.

En este sentido, las startups, reconocidas por su alto potencial y velocidad de crecimiento en relación con la inversión inicial (REPSOL, 2023), representan una gran oportunidad para implementar tecnologías innovadoras dentro de sus procesos de crecimiento. Desde sus primeros pasos, una startup del tipo SaaS (Software as a Service) construye una estructura organizativa flexible y escalable, enfocada en un crecimiento ágil y escalonado, lo que facilita la adopción y aprovechamiento de estas tecnologías para optimizar sus operaciones y decisiones. Las startups SaaS representan un ejemplo clave de cómo el uso

de nuevas tecnologías en el contexto boliviano no solo resulta beneficioso, sino también fundamental para impulsar la competitividad y el desarrollo en un mercado global cada vez más digitalizado.

1.2. Justificación

En una startup, la optimización de recursos es esencial para alcanzar un crecimiento sostenible. El objetivo principal es generar resultados significativos sin desperdiciar recursos como ser tiempo, esfuerzo, talento humano o recursos logísticos. Para lograrlo, resulta fundamental orientar los esfuerzos hacia los clientes con mayor probabilidad de permanencia a largo plazo, evitando aquellos con altas probabilidades de incurrir en ‘churn’. Una estrategia eficaz para lograr esto es el desarrollo de un modelo predictivo basado en patrones de comportamiento a lo largo del ciclo de vida del cliente.

El modelo de análisis predictivo facilitará una mejor gestión de los recursos de la startup, optimizando la eficiencia en la retención de clientes y manteniendo una baja tasa de ‘Churn Comercial’, además de mejorar las estrategias de interacción y contacto.

El uso de datos históricos permitirá a la empresa comprender mejor el comportamiento de sus clientes, identificar sus necesidades y desarrollar estrategias personalizadas para optimizar su experiencia con el servicio o producto. Esto no solo incrementará la retención, sino que también posicionará a la empresa de manera competitiva, permitiéndole anticiparse a las expectativas del mercado y asegurar un crecimiento más sólido y sostenible.

1.3. Planteamiento del problema

Se tiene el conocimiento de que dentro del contexto de la startup se distingue entre ‘churn’ y ‘Churn Comercial’. La diferencia radica en que el ‘Churn Comercial’ se refiere al abandono del cliente dentro de los primeros 90 días tras una conversión exitosa. Por otro lado, el ‘churn’ puede ocurrir en cualquier momento posterior a este período inicial de los 90 días.

En la actualidad, el área de experiencia de la startup enfrenta un desafío en la asignación estratégica de recursos para la interacción y contacto con los clientes. La incertidumbre se genera debido a la dificultad de identificar cuáles clientes tienen más probabilidades de hacer ‘Churn Comercial’ y cuáles, por el contrario, permanecerán. Este problema se refleja en la gestión de los intentos de contacto durante la etapa comercial, en la cual las acciones implementadas no siempre se alinean con el comportamiento real de los clientes. Para abordar este desafío, resulta fundamental analizar los patrones de comportamiento en la interacción, lo que facilitará una asignación más efectiva de los recursos y contribuirá a una reducción significativa en la tasa de ‘Churn Comercial’.

Para realizar un análisis preciso del problema de la startup, se cuenta con datos históricos de ‘churn’ y ‘Churn Comercial’ recopilados a lo largo del tiempo, desde la creación de la empresa hasta la gestión 2024. Estos datos fueron proporcionados por la empresa bajo estrictas condiciones de confidencialidad.

En la Figura 1-1, se puede observar una tendencia creciente en el ‘Churn Comercial’ a lo largo del tiempo, especialmente en los últimos cuatro años. Este patrón indica un aumento progresivo en la cantidad de

clientes que abandonan la empresa durante la etapa de onboarding, la cual forma parte de la etapa de experiencia. Este comportamiento podría estar relacionado con la gestión ineficiente de los recursos destinados al contacto y la interacción con los clientes. La visualización resalta la necesidad urgente de optimizar los esfuerzos de interacción, dirigiéndolos estratégicamente a aquellos clientes que presentan un mayor riesgo de ‘churn’, con el fin de reducir esta tendencia negativa.




Figura 1-1 Comparación entre ‘Churn’ y ‘Churn Comercial’ a lo largo del tiempo.

Fuente: Elaboración propia, (enero, 2025)

En el primer año de operación de la startup, se registró un índice extraordinariamente alto de ‘churn’, destacando la pérdida de 66 clientes en mayo de 2019. De este total, el 21.21% (14 clientes) correspondió a ‘Churn Comercial’. Este fenómeno puede atribuirse al hecho de que fue el primer año en que la empresa comercializó su producto SaaS (Sistema de Gestión de Inventarios). No obstante, se observa una marcada tendencia a la disminución del ‘churn’ desde mayo hasta noviembre de 2019.

En contraste, durante la gestión 2021, la empresa no presentó casos de ‘Churn Comercial’ y mantuvo un promedio mensual de 15 clientes que abandonaron el servicio, lo que representa un índice relativamente bajo. La ausencia de ‘Churn Comercial’ podría estar relacionada con diversas mejoras implementadas en la empresa, tales como optimizaciones en los procesos comerciales o una mayor adaptación del producto a las necesidades del cliente durante ese año.

Dado que las startups se caracterizan por cambios constantes en busca de un crecimiento rápido y escalonado, resulta fundamental analizar el comportamiento del ‘Churn Comercial’ en la gestión más reciente. En la Figura 1-2, se presenta una comparación entre el ‘Churn Comercial’ y el ‘churn’ registrado en los últimos 12 meses, con el objetivo de identificar tendencias actuales y áreas clave de mejora.




Figura 1-2 Comparación entre 'Churn' y 'Churn Comercial' Gestión 2024

Fuente: Elaboración propia, (enero, 2025)

El comportamiento del 'Churn Comercial' a lo largo de la gestión 2024 muestra una clara tendencia ascendente, con una tasa de crecimiento del 20.09% y un promedio mensual de 3.9 clientes que abandonaron el servicio. Este índice de abandono es elevado, lo que representa un desafío significativo para la empresa en su objetivo de crecimiento escalonado y sostenido.

El desafío radica en la identificación de clientes con mayor riesgo de abandonar su suscripción dentro de los primeros 90 días posteriores a una conversión exitosa en la etapa comercial. Este proceso permitirá el desarrollo de estrategias basadas en los resultados obtenidos, optimizando los esfuerzos del área de experiencia y priorizando la asignación de recursos hacia aquellos clientes con menor probabilidad de abandono.

1.4. Objetivo general

Desarrollar un modelo predictivo de clasificación de 'churn' basado en patrones de contacto con los clientes, utilizando técnicas de machine learning, para apoyar a la toma de decisiones basadas en datos en una startup boliviana.

1.4.1. Objetivos específicos

- Comprender las necesidades y objetivos del negocio para mejorar la predicción del churn.
- Extraer datos de los clientes y sus actividades para comprender los patrones de contacto y sus características.
- Analizar y preparar los datos extraídos para su análisis y posterior modelado.
- Entrenar modelos de predicción clasificatorio utilizando técnicas de machine learning.
- Evaluar y seleccionar un modelo predictivo de clasificación efectivo en términos de retención de clientes.

2. Marco teórico

En este capítulo se presentan de manera clara los conceptos, metodologías y elementos clave utilizados en el desarrollo del proyecto. Estos conceptos no solo constituyen la base teórica del enfoque adoptado, sino que también sirven como guía para el análisis y la toma de decisiones a lo largo del proceso..

2.1. Inteligencia Artificial (IA)

Según el Grupo de Expertos de Alto Nivel sobre Inteligencia Artificial (AI HLEG, por sus siglas en inglés), los sistemas de Inteligencia Artificial (IA) son sistemas de software diseñados por humanos que operan en la dimensión física o digital. Estos sistemas perciben su entorno mediante la adquisición de datos, los interpretan, los estructuran o no, razonan sobre ellos y sobre los conocimientos adquiridos, procesan la información derivada y determinan la(s) mejor(es) acción(es) a tomar para alcanzar un objetivo determinado. (HLEG, 2019).

2.2. Machine Learning

El aprendizaje automático (Machine Learning, ML) es un subcampo de la Inteligencia Artificial que se enfoca en el estudio y desarrollo de algoritmos y modelos estadísticos utilizados por los sistemas de computación para ejecutar tareas específicas sin necesidad de una programación explícita. La principal ventaja del uso de algoritmos de ML radica en su capacidad para realizar tareas de manera automática una vez que han sido entrenados. Actualmente se aplica en diversos ámbitos, como la minería de datos, el procesamiento de imágenes, el análisis predictivo, el análisis semántico, el procesamiento del lenguaje natural y la recuperación de información, entre otros. (Mahesh, 2020; Shinde, 2018).




Figura 2-1 Clasificación de algoritmos de Machine Learning

Fuente: (Mahesh, 2020)

Los algoritmos de aprendizaje automático (ML) se caracterizan por ser una forma de "código blando" o soft code, cuyo objetivo es emular la manera en que la mente humana procesa y aprende a partir de señales sensoriales (input data) para cumplir una tarea específica. Para lograrlo, estos algoritmos deben

adaptar su arquitectura de forma automática a través de la repetición y la experiencia. Este proceso de adaptación, conocido como entrenamiento, consiste en proporcionar al algoritmo muestras de datos de entrada junto con los resultados esperados. A partir de esta información, el algoritmo de ML se ajusta de manera que no solo pueda devolver el resultado esperado con los datos de entrada proporcionados, sino que también sea capaz de generalizar y producir resultados precisos a partir de datos nuevos. (El Naqa, 2015).

De manera general, el aprendizaje automático puede ser categorizado en dos tipos (VanderPlas, 2017):

- a) **Aprendizaje supervisado:** Hace referencia al modelaje de la relación entre las características medidas de los datos y alguna etiqueta asociada a los mismos. Se subdivide en tareas de clasificación y tareas de regresión.
- b) **Aprendizaje no supervisado:** Consiste en la modelación de características de un conjunto de datos sin referencia a ninguna etiqueta. Los modelos pertenecientes a este tipo de ML son los agrupación y reducción dimensional.

Machine Learning usa distintos tipos de algoritmos para resolver problemas (Fig. 2-3), entre los frecuentemente utilizados se pueden encontrar: clasificadores lineales, regresiones logísticas, Naive Bayes (NB), redes Bayesianas, Árboles de decisiones, Random Forest, Support Vector Machine (SVM), clusterings (K-means, k-nearest neighbour) y redes neuronales artificiales (Shinde, 2018).

2.3. Modelos predictivos de Machine Learning

Los modelos predictivos son técnicas estadísticas y de Machine Learning que a partir de análisis de datos existentes permiten predecir eventos o comportamientos futuros. Son utilizados en diversos campos, principalmente para mejorar la toma de decisiones y planificar estrategias efectivas. Por ejemplo, en Marketing es frecuentemente utilizado en segmentación de clientes y predicciones de abandono (PredikData, 2025).

De manera general, existen dos tipos de modelos predictivos:

- **Modelos de clasificación:** Son aquellos que permiten predecir la pertenencia a una clase o categoría. En análisis predictivo, estos modelos suelen ser usados para hacer predicciones de tipo binario, y el modelo predice cuál de las dos opciones es la más probable que suceda (Keyrus, 2025)
- **Modelos de regresión:** Son modelos que permiten predecir valores continuos. Suelen ser utilizados para predecir el rendimiento de algo, ya sea un producto, un proceso o un individuo (Bismart, 2025)

2.3.1. Modelos predictivos de clasificación

Entre los modelos clasificatorios más conocidos podemos identificar los siguientes.

2.3.1.1. Modelos clasificatorios de regresión

Los análisis predictivos clasificatorios de regresión relacionan variables entre sí. Pueden ser de tipo logísticas o tipo lineal (Cristianini, 2000)., entre los modelos clasificatorios más utilizados en esta categoría tenemos:

2.3.1.1.1. Naive Bayes

Los modelos Naive Bayes conforman un grupo de algoritmos de clasificación caracterizados por su rapidez y simplicidad, lo que los hace especialmente adecuados para conjuntos de datos de alta dimensión. Gracias a su eficiencia y la baja cantidad de parámetros ajustables, estos modelos resultan útiles como una línea base rápida en problemas de clasificación. (VanderPlas, 2017)

Existen varios tipos de clasificadores Naive Bayes, cada uno diseñado para diferentes tipos de datos y distribuciones. A continuación, se presentan los principales tipos, junto con sus definiciones, usos y limitaciones, respaldados por referencias científicas y documentación oficial de Python:

a) Gaussian Naive Bayes

El modelo Naive Bayes Gaussiano es el mas sencillo de comprender, ya que supone que los datos de cada etiqueta siguen una distribución gaussiana.

- **Usos:** Comúnmente empleado para datos continuos donde se supone una distribución gaussiana, por ejemplo, clasificación de imágenes medicas o análisis de sensores
- **Limitaciones:** En el caso de que los datos no sigan una distribución normal, el rendimiento del clasificador puede verse afectado negativamente (scikit-learn, Naive Bayes, 2025)
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Gaussian Naive Bayes son:
 - `'priors' array (n-classes), default=None:` Este hiperparámetro hace referencia a las prioridades previas de cada clase. Al calcular las probabilidades de las clases durante la clasificación, el modelo considera estas probabilidades iniciales en lugar de derivarlas exclusivamente a partir de los datos.
 - `'var_smoothing' float, default=1e-9:` Este hiperparámetro ajusta un pequeño valor que se suma a la varianza de cada característica para evitar problemas numéricos cuando las probabilidades son muy pequeñas. (scikit-learn, GaussianNB, 2025)

b) Multinomial Naive Bayes

El modelo Naive Bayes Multinomial se utiliza para datos discretos y cuenta la frecuencia de eventos, asumiendo una distribución multinomial de las características. (scikit-learn, Supervised learning, 2025)

- **Usos:** Comúnmente empleado en clasificación de textos, como la categorización de correos electrónicos o análisis de sentimientos, donde se consideran las frecuencias de palabras.
- **Limitaciones:** No es adecuado para datos continuos; además, asume que las características son independientes, lo cual puede no ser cierto en todos los conjuntos de datos. (scikit-learn, Supervised learning, 2025)

- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Multinomial Naive Bayes son:
 - `'alpha' float or array, default=1.0`: Este hiperparámetro es el parámetro de suavizado de Laplace (conocido como Lidstone smoothing)
 - `'class-prior' array, default=None`: Este hiperparámetro hace referencia a las prioridades previas de cada clase. Al calcular las probabilidades de las clases durante la clasificación, el modelo considera estas probabilidades iniciales en lugar de derivarlas exclusivamente a partir de los datos. (scikit-learn, MultinomialNB, 2025)

c) Bernoulli Naïve Bayes

El modelo Naive Bayes Bernoulli se utiliza para datos binarios, donde las características son variables booleanas que indican la presencia o ausencia de una característica. (scikit-learn, Supervised learning, 2025)

- **Usos:** Comúnmente empleado en clasificación binaria, donde se evidencia la presencia o ausencia de características.
- **Limitaciones:** No maneja bien datos continuos o conteos; además, la suposición de independencia entre características puede limitar su aplicabilidad en ciertos contextos. (scikit-learn, Supervised learning, 2025)
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Bernoulli Naive Bayes son:
 - `'alpha' float or array, default=1.0`: Este hiperparámetro es el parámetro de suavizado de Laplace (conocido como Lidstone smoothing)
 - `'norm' bool, default=False`: Este hiperparámetro controla si las probabilidades complementarias deben normalizarse o no. (scikit-learn, ComplementNB, 2025)

d) Complement Naive Bayes

El modelo Complement Naive Bayes es una variante del Multinomial Naïve Bayes, diseñada para corregir las "fuertes suposiciones" del modelo multinomial estándar, especialmente útil en conjuntos de datos desbalanceados. (scikit-learn, Supervised learning, 2025)

- **Usos:** Comúnmente empleado en clasificación de textos con clases desbalanceadas, mejorando la precisión en comparación con el modelo multinomial tradicional.
- **Limitaciones:** Aunque mejora el rendimiento en datos desbalanceados, puede ser más complejo de implementar y requiere un ajuste cuidadoso de los hiperparámetros. (scikit-learn, Supervised learning, 2025)
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Compliment Naive Bayes son:
 - `'alpha' float or array, default=1.0`: Este hiperparámetro es el parámetro de suavizado de Laplace (conocido como Lidstone smoothing)

- `'class-prior' array, default=None`: Este hiperparámetro hace referencia a las prioridades previas de cada clase. Al calcular las probabilidades de las clases durante la clasificación, el modelo considera estas probabilidades iniciales en lugar de derivarlas exclusivamente a partir de los datos. (scikit-learn, BernoulliNB, 2025)

e) Categorical Naive Bayes

El modelo Categorical Naive se aplica a características categóricas que siguen una distribución categórica, manejando variables que representan categorías discretas.. (scikit-learn, Supervised learning, 2025)

- **Usos:** Comúnmente empleado en clasificación de datos categóricos, como la clasificación basada en colores, tipos o categorías nominales, donde las características no tienen un orden intrínseco.
- **Limitaciones:** No es adecuado para datos continuos o donde las categorías tienen un orden; además, la suposición de independencia entre características puede no reflejar la realidad en todos los casos. (scikit-learn, Supervised learning, 2025)
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Categorical Naive Bayes son:
 - `'alpha' float or array, default=1.0`: Este hiperparámetro es el parámetro de suavizado de Laplace (conocido como Lidstone smoothing)
 - `'class-prior' array, default=None`: Este hiperparámetro hace referencia a las prioridades previas de cada clase. Al calcular las probabilidades de las clases durante la clasificación, el modelo considera estas probabilidades iniciales en lugar de derivarlas exclusivamente a partir de los datos.
 - `'min_categories' array, default=None`: Este hiperparámetro hace referencia al Número mínimo de categorías permitidas por cada característica. (scikit-learn, CategoricalNB, 2025)

2.3.1.1.2. Logistic Regression

Es un modelo estadístico utilizado para clasificación binaria, que estima la probabilidad de una clase mediante una función sigmoide. A pesar de su simplicidad, es eficaz en la separación lineal de datos. (Cox, 1958)

Existen varios tipos de regresión logística en Python, cada uno diseñado para diferentes tipos de datos y distribuciones. A continuación, se presentan los principales tipos, junto con sus definiciones, usos y limitaciones, respaldados por referencias científicas y documentación oficial de Python:

a) Binary Logistic Regression

El modelo de regresión binaria se aplica cuando la variable objetivo tiene dos clases (ej. 0 y 1). El modelo estima la probabilidad de que una observación pertenezca a una de las dos categorías utilizando la función sigmoide. (scikit-learn, Supervised learning, 2025)

- **Usos:** Se emplea cuando la variable objetivo es binaria, es decir, solo puede tomar uno de dos valores posibles. Las variables predictoras pueden ser de tipo numérico o categóricas.

- **Limitaciones:** Asume una relación lineal entre las variables predictoras y la variable objetivo. La multicolinealidad (presencia de alta correlación entre variables independientes) puede afectar la estimación de los coeficientes y la estabilidad del modelo. En el caso de clases desbalanceadas el modelo puede inclinarse a la clase mayoritaria, afectando a la precisión de las predicciones. (scikit-learn, Supervised learning, 2025)
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo Binary Logistic Regression son:
 - `'penalty': {'l1', 'l2', 'elasticnet', None}, default='l2', default=1.0`: Este hiperparámetro controla el tipo de regularización para evitar un sobreajuste:
 - a. `'l1'`: parámetro Lasso, elimina características irrelevantes
 - b. `'l2'`: parámetro Ridge, reduce la magnitud de los coeficientes
 - c. `'elasticnet'`: combinación de penalizaciones l1 y l2
 - d. `None`: Sin penalización
 - `'C' float, default=1e-4`: Este controla la inversión de la regularización, a números más grandes menor penalización.
 - `'solver' {'lbfgs', 'liblinear', 'newton-cg', 'newton-cholesky', 'sag', 'saga'}, default='lbfgs'`: Este hiperparámetro define el método para resolver el problema de optimización, el método por defecto 'lbfgs' es adecuado para resolver problemas multiclase.
 - `'max_iter' int, default=100`: Este hiperparámetro define cuántas iteraciones puede realizar el algoritmo antes de converger.
 - `'class_weight' dict or 'balance', default=100`: Este hiperparámetro define el peso de las clases, útil en clases desbalanceadas. (scikit-learn, LogisticRegression, 2025)

b) Multinomial Logistic Regression

El modelo de regresión logística multinomial se aplica cuando la variable objetivo tiene más de dos clases. El modelo usa la generalización softmax en lugar de la función sigmoide para manejar múltiples clases. (scikit-learn, Supervised learning, 2025)

Se deben ajustar el siguiente parámetro para poder utilizar este tipo de regresión logística multinomial:

- `'multi_class'='multinomial'`: el ajuste de este parámetro nos permite utilizar esta regresión logística, se debe ajustar al momento de crear el modelo.

Este ajuste en conjunción al ajuste de los hiperparametros mencionados anteriormente lograran un mejor resultado en el modelo.

c) Ordinal Logistic Regression

El modelo de regresión logística multinomial se aplica cuando la variable objetivo tiene más de dos clases. El modelo usa la generalización softmax en lugar de la función sigmoide para manejar múltiples clases. (scikit-learn, Supervised learning, 2025)

Se deben ajustar el siguiente parámetro para poder utilizar este tipo de regresión logística multinomial:

- `'multi_class'='multinomial'`: el ajuste de este parámetro nos permite utilizar esta regresión logística, se debe ajustar al momento de crear el modelo.

Este ajuste en conjunción al ajuste de los hiperparametros mencionados anteriormente lograran un mejor resultado en el modelo. (scikit-learn, MultinomialNB, 2025)

2.3.1.2. Modelos predictivos de árboles de decisión

Son modelos de clasificación supervisada que tratan de encontrar la variable que permita dividir un dataset en grupos lógicos que son más diferentes entre sí. Entre los modelos clasificatorios más utilizados en esta categoría tenemos:

2.3.1.2.1. Decision Tree

Es un modelo basado en una estructura de árbol, donde cada nodo representa una decisión basada en una característica del conjunto de datos. Se utiliza por su interpretabilidad y facilidad de implementación. (Quinlan, 1986)

Los Árboles de Decisión, o Decision Tree en inglés, son modelos de aprendizaje supervisado utilizados para problemas de clasificación y regresión. Funcionan dividiendo el espacio de características en regiones basadas en preguntas binarias (sí o no), formando una estructura jerárquica similar a un árbol. (scikit-learn, Supervised learning, 2025)

En el contexto de clasificación se emplea el modelo de árbol de decisión clasificatorio o Decision Tree Classifier.

a) Decision Tree Classifier

El Decision Tree Classifier es un modelo de clasificación que aprende reglas de decisión a partir de un conjunto de datos de entrenamiento. Recibe una matriz X con las características de las muestras y una matriz Y con sus etiquetas de clase. Luego, puede predecir la categoría de nuevas muestras basándose en patrones aprendidos.

- **Usos:** Comúnmente utilizados cuando la variable objetivo es numérica continua, este modelo de clasificación es capaz de clasificar variables binarias como multiclase.
- **Limitaciones:** Es propenso al sobreajuste si no es establecen restricciones, volviéndose inestable con datos ruidosos, Además, en conjuntos de datos desbalanceados suele favorecer a la clase mayoritaria, afectando a la precisión. Por otro lado, en datos de alta dimensión, su complejidad aumenta considerablemente, reduciendo su eficiencia e interpretabilidad.

En contraste, los métodos de conjuntos combinan múltiples árboles para disminuir la variabilidad y mejorar la estabilidad del modelo. Asimismo, los árboles de decisión suelen mostrar un menor nivel de precisión en comparación con los modelos basados en conjuntos, los cuales alcanzan un mejor desempeño al emplear técnicas de agregación y potenciación para optimizar sus predicciones (Hastie, 2009)

- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo de Decision Tree Classifier son:
 - `'criterion': {'gini', 'entropy', 'log_loss'}, default='gini'`: Este hiperparámetro define la calidad de una división:
 - a. `'gini'`: parámetro que minimiza la impureza Gini.
 - b. `'entropy'`: parámetro que maximiza la ganancia de información
 - c. `'log_loss'`: métrica que evalúa las predicciones de probabilidades de clase.
 - `'splitter' {'best', 'random'}, default='best'`: Asigna la estrategia utilizada para elegir la división en cada nodo.
 - `'max_depth' int, default=None`: Este hiperparámetro define la profundidad máxima del árbol para evitar sobreajuste.
 - `'min_samples_split' int/float, default=2` Este hiperparámetro define el mínimo número de muestras necesarias para dividir un nodo interno.
 - `'min_samples_leaf' int/float, default=1` Este hiperparámetro define el mínimo número de muestras necesarias para dividir un nodo interno.
 - `'max_features' int/float or {'sqrt', 'log2'}, default=None` Este hiperparámetro define la cantidad máxima de características a tomar en cuenta en cada división
 - `'class_weight' dict or 'balanced', default=None`: Este hiperparámetro define los pesos asociados a cada clase, útil en clases desbalanceadas (scikit-learn, DecisionTreeClassifier, 2025),.

2.3.1.2.2. Random Forest

Es un conjunto de árboles de decisión entrenados con diferentes subconjuntos de datos. Mejora la precisión y reduce el sobreajuste combinando múltiples predicciones. (Breiman, 2001).

En el contexto de clasificación se emplea el modelo bosque aleatorio clasificatorio o Random Forest Classifier.

a) Random Forest Classifier

El Random Forest Classifier es un modelo que combina múltiples árboles de decisión entrenados con diferentes subconjuntos de datos, que promedia sus predicciones para mejorar la precisión y reducir el sobreajuste.

- **Usos:** Se utilizan comúnmente con datos con una variable objetivo de tipo categórica con variables predictoras de tipo numérico o categórico (utilizar one-hot- encoding para variables categóricas)
- **Limitaciones:** Es propenso al sobreajuste si se utilizan demasiados árboles. Además, tiene menor interpretabilidad y su rendimiento no mejora significativamente cuando las características tienen poca relación con la variable objetivo, lo que lo hace menos eficiente en datos muy dispersos. También requiere mayores recursos computacionales para su ejecución.
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo de Decision Tree Classifier son:
 - `'n_estimators': int, default=1.0`: Este hiperparámetro define el número de árboles de decisión del bosque.
 - `'criterion': {'gini', 'entropy', 'log_loss'}, default='gini'`: Este hiperparámetro define la calidad de una división:
 - a. `'gini'`: parámetro que minimiza la impureza Gini.
 - b. `'entropy'`: parámetro que maximiza la ganancia de información
 - c. `'log_loss'`: métrica que evalúa las predicciones de probabilidades de clase.
 - `'max_depth' int, default=None`: Este hiperparámetro define la profundidad máxima del árbol para evitar sobreajuste.
 - `'min_samples_split' int/float, default=2` Este hiperparámetro define el mínimo número de muestras necesarias para dividir un nodo interno.
 - `'min_samples_leaf' int/float, default=1` Este hiperparámetro define el mínimo número de muestras necesarias para dividir un nodo interno.
 - `'max_features' int/float or {'sqrt', 'log2'}, default=None` Este hiperparámetro define la cantidad máxima de características a tomar en cuenta en cada división
 - `'class_weight' dict or 'balanced', default=None`: Este hiperparámetro define los pesos asociados a cada clase, útil en clases desbalanceadas
 - `'bootstrap': bool, default=True`: Este hiperparámetro define si se utilizaran muestras para crear árboles o si se utilizara todo el conjunto de datos para crear cada árbol. (scikit-learn, RandomForestClassifier, 2025)

2.3.1.2.3. XGBoost

Es una implementación optimizada de gradient boosting, que combina múltiples árboles de decisión y utiliza técnicas de regularización para mejorar el rendimiento en tareas de clasificación y regresión. (Chen, 2016) En el contexto de clasificación se emplea el modelo XGBoost Classifier.

a) XGBoost Classifier:

El modelo XGBoostClassifier es una clase de la API de Python de XGBoost que ofrece una interfaz similar a scikit-learn para tareas de clasificación.

- **Usos:** Se utilizan comúnmente con datos con una variable objetivo de tipo categórica con variables predictoras de tipo numérico o categórico. Trabaja con vectores numéricos por lo tanto es necesario utilizar one-hot- encoding para variables categóricas.
- **Limitaciones:** Es propenso al sobreajuste si no se ajustan cuidadosamente sus parámetros. También requiere mayores recursos computacionales para su ejecución.
- **Hiperparámetros:** Los hiperparámetros que se ajustan para mejorar el performance de un modelo de Decision Tree Classifier son:
 - `'n_estimators': int, default=100`: Este hiperparámetro define el número de árboles de decisión del modelo.
 - `'learning_rate': float, default=0.3`: Este hiperparámetro define la tasa de aprendizaje, mientras mas bajo el numero mas conservador es el aprendizaje.
 - `'max_depth' int, default=6`: Este hiperparámetro define la profundidad máxima de cada árbol para evitar sobeajuste.
 - `'min_child_weight' int, default=1` Este hiperparámetro define el mínimo peso de las hojas, ayuda a mejorar la generalización.
 - `'subsample' float, default=1.0` Este hiperparámetro indica la fracción de muestras que se utilizaran para entrenar cada árbol, valores menores a 1 ayudan a reducir el sobreajuste.
 - `'colsample_bytree' float, default=1.0`: Especifica la fracción de características que se seleccionarán de manera aleatoria para entrenar cada árbol.
 - `'reg_alpha' dict or float, default=0.0` Este hiperparámetro defina la complejidad del modelo al penalizar L1.
 - `'reg_lambda' dict or float, default=0.0` Este hiperparámetro defina la complejidad del modelo al penalizar L2.
 - `'gamma': float, default=0.0`: Establece la mejora mínima en la función de pérdida necesaria para que se realice una división adicional en un nodo del árbol. (XGBoost, 2025)

2.3.2. EDA (Exploratory Data Analysis)

El Análisis Exploratorio de Datos (EDA, por sus siglas en inglés) es un proceso y etapa esencial en el análisis de datos donde se examina un determinado dataset en orden de descubrir patrones, anomalías, probar hipótesis y supuestos usando métricas estadísticas. El objetivo de la EDA es el de entender de mejor manera la naturaleza y características del dataset bajo estudio, y de extraer información preliminar antes de realizar un modelamiento de manera formal o previo a la formulación de hipótesis. Entre los componentes clave de un EDA se encuentran el resumen de datos, análisis estadístico y la visualización de datos (Milo, 2020; Mukhiya, 2020).

Según el National Institute of Standards and Technology-NIST (NIST Sematech) (Yu, 2010), los objetivos principales de un EDA son: maximizar la comprensión de los datos, identificar estructuras subyacentes, detectar valores atípicos, probar supuestos, desarrollar modelos parsimoniosos.

2.3.3. Variable destino o etiqueta

Las Variables Destino son esenciales en el ámbito del aprendizaje supervisado, dado que representan los atributos que se desean predecir. Durante el proceso de entrenamiento, el modelo adquiere la capacidad de relacionar dichas variables con las características de entrada a partir de datos que han sido etiquetados. Una vez completado el entrenamiento, el modelo puede aplicar este conocimiento para realizar predicciones precisas sobre nuevas instancias que no han sido etiquetadas. (Pineda Pertuz, 2022).

2.4. Modelo CRISP-DM (Cross Industry Standard Process for Data Mining)

CRISP-DM es un modelo de proceso independiente para el desarrollo de proyectos de minería de datos, siendo una de las más utilizadas en este campo (Espinosa-Zúñiga, 2020)

De acuerdo al resumen expuesto por Schröer (Schröer, 2021), este modelo consta de seis etapas:

1. **Comprensión del problema o negocio:** Etapa en la que se entiende y delimita la problemática que pretende solucionar, así como la identificación de los requisitos, supuestos, restricciones y beneficios del proyecto.
2. **Comprensión de datos:** En esta etapa se obtienen los datos que serán utilizados. Se determina el tipo, formato, volumetría y significado de cada dato, así como en la aplicación de estadísticas básicas que nos permitan conocer las propiedades de los datos.
3. **Preparación de datos:** Etapa que consume más tiempo. Se seleccionan los datos que se transformarán con el fin de utilizarlos en la etapa de modelado. Las tareas que se realizan en este punto son: limpieza de datos, creación de indicadores y transformación de datos.
4. **Modelado:** Consiste en la selección de la técnica de modelado. La elección depende del buen entendimiento de las dos primeras etapas.
5. **Evaluación del modelo:** En esta etapa se determina la calidad del modelo con base en el análisis de ciertas métricas estadísticas del mismo, comparando los resultados con resultados previos, o bien, analizando los resultados con apoyo de expertos en el dominio del problema.
6. **Implementación del modelo:** Esta etapa explota, mediante acciones concretas, el conocimiento adquirido mediante el modelo. Aquí también es importante documentar los resultados de manera clara para el usuario final y asegurarse de que todas las etapas de la metodología se documenten debidamente para hacer una revisión del proyecto a fin de obtener lecciones aprendidas durante el proceso. Asimismo, monitorear las acciones para detectar áreas de oportunidad o incluso nuevos problemas.

2.5. StartUps

Una startup es una empresa con poco tiempo de vida que ofrece productos o servicios basados en tecnologías de la información que basa sus estrategias en la incertidumbre pero tiene gran potencial de crecimiento mediante la innovación (Rojas, 2019).

2.5.1. Características de una startup

Las startups deben seguir ciertas características importantes para poder ser consideradas startups desde sus inicios, algunas de las mas importantes son las siguientes:

1. **Innovación:** siguen un modelo de negocio basado en la innovación y en implementar las ideas en el momento ideal en el mercado para tener éxito.
2. **Altas posibilidades de crecimiento:** siguen una estrategia empresarial que permite el crecimiento rápido y escalonado en el mercado.
3. **Escalabilidad:** tienen una capacidad muy alta de crecimiento y además tienen grandes posibilidades de internacionalizarse, esta característica va muy de la mano con la innovación.
4. **Alto nivel de riesgo:** este es uno de los factores más característicos de las startups, los modelos de negocio de las startups suelen tener altos niveles de riesgo debido a su innovación y que no existe documentación o modelos de negocio previos que demuestren como tener éxito o no.
5. **Experimentación continua:** algo que si es seguro dentro de las startups es la experimentación continua ya que las startups siguen el camino de la innovación se guían por la experimentación. (Rojas, 2019)

2.6. Software As A Service (SaaS)

El modelo de Software como Servicio (SaaS) se define como un modelo de distribución de software en la nube, en el que las aplicaciones se alojan en servidores de un proveedor y los usuarios acceden a ellas a través de Internet, eliminando la necesidad de instalación y mantenimiento local. Este modelo permite a los usuarios consumir servicios bajo demanda, generalmente mediante suscripciones periódicas, y es gestionado de forma centralizada por el proveedor, quien se encarga de actualizaciones, seguridad y soporte (Gupta, Gupta, & Rai, 2024; Laplante, Zhang, & Voas, 2008)

El SaaS se ha convertido en una herramienta clave para la transformación digital de las empresas, permitiéndoles optimizar recursos y centrarse en actividades de alto valor añadido. Entre sus principales características se pueden destacar:

1. **Acceso remoto:** Los usuarios pueden interactuar con el software desde cualquier dispositivo con conexión a Internet, utilizando un navegador o una interfaz específica.
2. **Modelo de suscripción:** Los costos están basados en el uso, similar al pago por servicios públicos como electricidad, lo que reduce inversiones iniciales en infraestructura (Laplante, Zhang, & Voas, 2008)
3. **Escalabilidad:** Los usuarios pueden ajustar recursos como almacenamiento o funcionalidades según las necesidades del negocio (Gupta, Gupta, & Rai, 2024)
4. **Mantenimiento centralizado:** El proveedor gestiona las actualizaciones y parches, garantizando que los usuarios siempre accedan a la versión más reciente (Gupta, Gupta, & Rai, 2024)

De estas características se derivan una serie de beneficios para las empresas que se deciden por utilizar este tipo de servicios. Por ejemplo, ayuda en la reducción de costos, ya que elimina la necesidad de

adquirir hardwares y/o contratar personal técnico especializado. También permite una mayor flexibilidad operativa, ya que los SaaS se adaptan a las dinámicas cambiantes de las empresas, facilitando la expansión o contracción de servicios según sea necesario y acelerando los procesos de adopción tecnológica (Laplante, Zhang, & Voas, 2008)

2.7. Ciclo de vida de un cliente

El Ciclo de Vida de un Cliente (CVC) se refiere a la progresión que un cliente hace a través de la empresa, desde el primer contacto hasta convertirse en un cliente leal e incluso promotor de la marca (Torres, 2018). La comprensión de este ciclo permite optimizar la experiencia del cliente y afianzar relaciones duraderas. De acuerdo a León de Apio (2017), el CVC está constituido por las siguientes fases:

1. **Adquisición:** Se refiere cuando el cliente adquiere el producto por primera vez.
2. **Conversión:** Sucede cuando el cliente ha probado el producto, le ha gustado y pasa de usar el producto de la competencia a usar el de la empresa.
3. **Crecimiento:** Se da cuando la empresa empieza a experimentar un mayor consumo de su producto, debido principalmente a recomendaciones de los clientes ‘convertidos’.
4. **Retención:** El cliente es fiel a la marca, habituándose a consumir los productos de la empresa.
5. **Reactivación:** Esta etapa ocurre cuando el cliente es atraído por la competencia, ya sea por falta de acciones positivas de la empresa o por lanzamientos y campañas atractivas de otras empresas. (León del Apio, 2017)



Figura 2-2 Ciclo de vida de un cliente vs el trabajo de Marketing en cada etapa

Fuente: Thatzad, 2014 en Loaiza-Torres, 2018

2.7.1. Churn

El término *churn* hace referencia a la discontinuación de un contrato por parte de un cliente o de la empresa. Este fenómeno se presenta en diversas industrias y puede clasificarse en tres tipos principales:

1. **Churn activo o deliberado:** ocurre cuando el cliente decide cancelar el contrato voluntariamente para cambiar a otro proveedor. Entre las razones más comunes se encuentran la insatisfacción con la calidad del servicio, costos elevados, falta de beneficios por fidelidad, mala atención al cliente y preocupaciones sobre la privacidad.

2. **Churn rotacional o incidental:** se produce cuando el cliente cancela el contrato sin la intención de cambiar a un competidor, generalmente debido a cambios en su situación personal, como dificultades económicas o un cambio de residencia donde el servicio no está disponible.
3. **Churn pasivo o no voluntario:** en este caso, es la empresa la que decide terminar la relación contractual con el cliente.

Además, el *churn* puede dividirse en tres categorías adicionales según el comportamiento del cliente:

- **Total:** el contrato es cancelado oficialmente.
- **Oculto:** el contrato sigue vigente, pero el cliente no utiliza el servicio por un período prolongado.
- **Parcial:** el cliente mantiene el contrato, pero reduce significativamente su uso y complementa su consumo con un servicio de la competencia.

Desde una perspectiva empresarial, el *churn* representa un desafío significativo, ya que puede afectar la estabilidad financiera y operativa de una compañía. La identificación temprana de clientes en riesgo de abandonar, así como la comprensión de las razones detrás de su decisión, son factores clave para implementar estrategias de retención efectivas. En este sentido, las empresas deben analizar qué clientes representan un valor estratégico y desarrollar iniciativas de fidelización que minimicen las pérdidas y fortalezcan la relación con los consumidores.

Si bien el *churn* es un fenómeno inevitable, su gestión adecuada permite reducir el impacto económico y garantizar la sostenibilidad del negocio a largo plazo. (Lazarov, 2007)

Para las startups, especialmente aquellas que operan bajo modelos de suscripción, el churn es una métrica vital. Un alto churn rate puede significar la pérdida constante de ingresos y la necesidad de gastar más en adquirir nuevos clientes para compensar esas pérdidas. Por el contrario, una tasa baja de abandono indica una base de clientes satisfecha y leal, lo que puede traducirse en crecimiento sostenido y mayores ingresos. (Lacasa, 2024)

2.8. CRM (Customer Relationship Management)

La Gestión de Relaciones con el Cliente, o CRM por sus siglas en inglés, es una estrategia empresarial que tiene como finalidad el construir una cultura de negocio centrada en el cliente. Su objetivo es adquirir, retener y mejorar la rentabilidad de los clientes mediante una combinación de procesos, tecnologías y personas. Para cumplir dicho objetivo, las empresas que implementan esta filosofía de negocio buscan aumentar la satisfacción y lealtad del cliente mediante servicios personalizados, a través de actividades como la identificación de prospectos y la creación de conocimiento sobre los clientes (Rababah, 2011)

2.9. Arquitectura Medallion

La arquitectura Medallion es un enfoque escalonado de procesamiento de datos que sigue un patrón de diseño en capas, que permite organizar, gestionar y procesar información de forma más eficiente. Este tipo de arquitectura incluye tres capas: bronce, plata y oro, cada uno con funciones y grados de refinamiento distintos, permitiendo que los datos atraviesen por procesos de limpieza y transformación

usando data pipelines, mejorando su calidad y adaptabilidad conforme van moviéndose entre las capas. Un patrón de diseño como el de Medallion permite recrear los datos desde la primera capa en cualquier momento, además de facilitar el control de acceso, restringiendo accesos a ciertas capas específicas (Wiselka, 2024).




Figura 2-3 Estructura de la Arquitectura Medallion

Fuente: (Databricks, 2024)

2.9.1. Capas (Bronce, Plata y Oro)

Las etapas por las que pasa la data a través del procesamiento de datos en arquitectura Medallion son las siguientes:

1. **Capa Bronce (Bronze Layer):** Contiene datos, y metadatos, en su forma cruda y sin presentar cambios, iguales a los del sistema fuente del cual fueron recuperados.
2. **Capa Plata (Silver Layer):** Aquí se encuentran los datos conformados, limpios y transformados. Para eso, generalmente se realizan trabajos de eliminación de duplicados, manejo de datos corruptos y/o incorrectos que se encuentran en su formato original en la etapa Bronce.
3. **Capa Oro (Gold Layer):** Esta capa contiene datos diseñados para un determinado uso específico, como ser la elaboración de informes y análisis. Los datos usados se pueden seleccionar de múltiples tablas y también de fuentes externas, además de que se pueden realizar diferentes tipos de agregaciones y transformaciones empresariales específicas. Es en esta capa donde se implementan modelos de datos.

2.10. Descripción estadística

2.10.1. Media

La media, o media aritmética, es la medida de tendencia central más utilizada en el análisis estadístico y representa el promedio de un conjunto de datos. Se calcula a partir de la suma de todos los valores de los datos, dividida entre el número total de datos que componen la muestra observada (Posada Hernández, 2016).

2.10.2. Mediana (Me)

En un conjunto de datos, la mediana representa el lugar central, es decir, es el valor a partir del cual el 50% de las observaciones quedan por debajo de él y el otro 50% por encima. Para calcular la posición de la mediana es necesario ordenar los datos de manera ascendente (Posada Hernández, 2016).

Si bien la media aritmética es la medida de tendencia central más representativa en estadística, para aquellos casos en los que se tienen valores extremos es preferible usar la mediana, ya que no se ve afectada por valores extremos y por tanto no es tan sensible como la media.

2.10.3. Moda (Mo)

La moda es el valor que tiene mayor presencia o frecuencia en un conjunto de datos, puede ser aplicada a las variables cualitativas y cuantitativas discretas o continuas. Para obtener este valor se construyen diagramas de frecuencia y se ubica las características que corresponde a la frecuencia mayor. Un conjunto de datos puede ser unimodal (una moda), bimodal (dos modas) o multimodal (más de dos modas) (Posada Hernández, 2016).

2.10.4. Mínimo (Min) y Máximo (Max)

El valor mínimo de un conjunto de datos hace referencia al valor más bajo. Por el contrario, el máximo estaría representado por el valor más alto. Encontrar estos valores es importante para determinar los límites del rango de distribución de los valores de los datos a utilizar (Posada Hernández, 2016).

2.10.5. Rango

El rango es la medida de dispersión más simple en el análisis de datos. Se lo conoce también como amplitud o recorrido y es la diferencia entre el valor máximo y el valor mínimo de un conjunto de datos. Al estar basada en los valores extremos, no ofrece mucha información sobre la variabilidad de datos, pero puede ser usada como complemento de otras medidas de dispersión (Posada Hernández, 2016).

2.10.6. Varianza

Medida de dispersión que indica que tan alejados están los datos respecto a la media. Está definida como la media de los cuadrados de las diferencias del valor de los datos menos la media aritmética de los mismos. Es empleada junto a la desviación estándar para cuantificar la variabilidad del conjunto en su totalidad. La varianza poblacional (σ^2) se calcula cuando se tiene la totalidad de los datos de la población, mientras que la varianza de la muestra (s^2) tiene como objetivo convertirse en un estimador de la variación para la población (Posada Hernández, 2016).

2.10.7. Desviación estándar

Considerada la medida de dispersión con mayor representatividad para un conjunto de datos e indica la distribución de los datos alrededor de la media aritmética o promedio. Si este valor es bajo, indica que los datos están agrupados cerca de la media; y por el contrario, cuando la desviación estándar es alta indica que los valores están extendidos sobre un rango más amplio de datos. Se calcula como la raíz

cuadrada positiva de la varianza y está denotado por s cuando se estima para la muestra y por σ si es calculado para la población (Posada Hernández, 2016).

2.10.8. Correlación

Medida estadística que indica la relación o dependencia entre dos variables. Es decir, cuando la correlación entre A y B es alta, se sugiere que, si los valores de A aumentan o disminuyen, los valores de B tenderían a sufrir las mismas modificaciones. Empero, cabe destacar que una alta correlación no implica una relación causal directa entre ambas variables (García-Herrero, 2018).

2.10.9. Prueba Chi-Cuadrado

La prueba Chi cuadrado consiste en determinar en una muestra si hay diferencias significativas entre las frecuencias observadas y las especificadas por la ley teórica del modelo con el que se contrasta (frecuencias esperadas). En otras palabras, la prueba de Chi al cuadrado compara entre la tabla observada con una tabla teórica generada a partir del uso de un modelo.

Karl Pearson estableció la siguiente ecuación:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

Donde:

- O_i = Número de casos observados y clasificados en una determinada celda
- E_i = Número de casos esperados correspondientes a cada celda

Como en cualquier prueba de contraste estadístico, se intenta rechazar la hipótesis nula y aceptar en consecuencia, la hipótesis alternativa. La hipótesis nula se corresponde con la independencia de las variables o que las diferencias entre las frecuencias observadas y esperadas son muy pequeñas, y en consecuencia, el estadístico chi cuadrado también obtendrá un valor muy pequeño (Rigatti, 2017)

2.10.10. Prueba ANOVA

El análisis de la varianza (ANOVA) es una prueba estadística para detectar diferencias en las medias de grupos cuando existe una variable dependiente paramétrica y una o más variables independientes. Puede clasificarse en diferentes tipos, como modelos de efectos fijos unidireccionales y bidireccionales, en función del número de factores implicados. La técnica asume datos paramétricos, distribución normal, varianzas de grupo similares e independencia de los sujetos, aunque algunos supuestos pueden incumplirse con muestras de gran tamaño. El ANOVA es especialmente útil cuando se comparan tres o más grupos, ya que evita la complejidad y los posibles errores asociados a las pruebas t múltiples (Sawyer, 2009; Larson, 2008)

2.11. Python en la Ciencia de Datos

Python es un lenguaje de programación de código abierto y de tipo interpretado o de script, es decir, que se ejecuta utilizando un programa intermedio llamado intérprete en lugar de compilar el código a lenguaje máquina. Esto hace de Python un lenguaje más flexible y portable. (González Duque, 2011)

2.11.1. Manipulación de datos con Python

Python es vista como una herramienta destacada para el análisis de datos debido a su amplia variedad de bibliotecas, como NumPy, Pandas y Matplotlib, entre otras, y a sus herramientas creadas específicamente para gestionar, procesar, visualizar y modelar datos. Esto convierte a Python en una opción efectiva para convertir datos en información valiosa, facilitando la toma de decisiones a través del análisis de datos en diversas áreas industriales y científicas. (Pineda Pertuz, 2022)

2.11.1.1. Numpy

Abreviatura de Numerical Python, NumPy contiene las estructuras de datos, algoritmos y bibliotecas necesarias para múltiples aplicaciones científicas que involucren datos numéricos, entre los que destacan arreglos multidimensionales (ndarray), funciones para realizar cálculos matriciales, operaciones de álgebra lineal, entre otros. Las matrices NumPy son más eficientes para almacenar y manipular datos que otras estructuras de datos incorporadas en Python. (McKinney, 2022)

2.11.1.2. Pandas

Esta biblioteca combina las ideas de cálculo de arreglos de NumPy con los tipos de capacidades de manipulación de datos que se encuentran en las hojas de cálculo y bases de datos relacionales (como SQL). También permite remodelar, trocear, realizar agregaciones y seleccionar subconjuntos de datos. Pandas es una biblioteca que permite que la manipulación, preparación y limpieza de datos sea más flexible y fluido. (McKinney, 2022)

2.11.1.3. Matplotlib

Matplotlib es la biblioteca de Python más reconocida para generar gráficos y visualizaciones de datos bidimensionales. Su diseño se orientó hacia la creación de gráficos aptos para su publicación. Aunque existen otras bibliotecas de visualización para programadores Python, Matplotlib sigue siendo ampliamente utilizada y se integra de manera adecuada con el resto del ecosistema. (McKinney, 2022)

2.11.2. Aprendizaje Automático con Python

Para desarrollar operaciones de aprendizaje automático con Python, se emplean las siguientes librerías.

2.11.2.1. Scikit-learn

Es una biblioteca de código abierto para aprendizaje automático, que contiene una gran cantidad de algoritmos de clasificación, regresión, agrupamiento, reducción, selección de modelos y preprocesamiento de datos. Estos algoritmos y funciones generalmente están agrupados en submódulos dentro de la biblioteca. (Pineda Pertuz, 2022)

2.11.2.2. XGBoost

XGBoost es una librería avanzada de boosting mediante gradientes distribuidos, diseñada para ser altamente eficiente, adaptable y fácil de usar en diferentes plataformas. Implementa algoritmos de aprendizaje automático bajo el marco de Gradient Boosting, ofreciendo un método paralelo para el boosting de árboles que es conocido por resolver eficazmente muchos problemas en ciencia de datos de manera rápida y precisa. (xgboost, 2022)

2.11.3. Métricas de Evaluación

La evaluación del rendimiento de un modelo de aprendizaje automático es fundamental para determinar su capacidad de generalización y precisión en la clasificación de nuevos datos. Entre las métricas más utilizadas en la evaluación de modelos de clasificación se encuentran la exactitud, la precisión, la sensibilidad y la curva ROC, todas ellas derivadas de los conceptos fundamentales de probabilidad y estadística. (Bishop, 2006)

2.11.3.1. Exactitud (Accuracy)

La exactitud mide la proporción de predicciones correctas con respecto al total de observaciones evaluadas. Matemáticamente, se define como:

$$Exactitud = \frac{TP + TN}{TP + TN + FP + FN}$$

donde:

- TP (True Positives): Casos positivos correctamente clasificados.
- TN (True Negatives): Casos negativos correctamente clasificados.
- FP (False Positives): Casos negativos clasificados erróneamente como positivos.
- FN (False Negatives): Casos positivos clasificados erróneamente como negativos.

Sin embargo, esta métrica puede no ser adecuada en problemas de clases desbalanceadas, ya que puede generar una falsa sensación de buen desempeño si la clase mayoritaria domina la distribución de datos. (Bishop, 2006)

Esta es la métrica por defecto en los algoritmos de Python, utilizando su biblioteca SciKit-Learn, y puede ser evaluada mediante la función `score()`. También está disponible la función `accuracy_score()` del submódulo `metrics` para obtener la exactitud en problemas de clasificación (Pineda Pertuz, 2022)

2.11.3.2. Precisión (Precision)

La precisión indica la proporción de casos clasificados como positivos que realmente pertenecen a la clase positiva. Matemáticamente se define como:

$$Precisión = \frac{TP}{TP + FP}$$

Esta métrica es especialmente útil en problemas donde los falsos positivos tienen un alto costo, como en la detección de fraudes o en diagnósticos médicos, donde una clasificación incorrecta puede generar consecuencias graves. (Bishop, 2006)

En Python, se puede calcular utilizando la librería SciKit-Learn a través de la función `precision_score()` del submódulo `metrics`. Esta métrica es clave para evaluar la efectividad del modelo en la identificación de instancias positivas, ofreciendo información relevante sobre la fiabilidad de sus predicciones afirmativas (Pineda Pertuz, 2022)

2.11.3.3. Sensibilidad (*Recall*)

La sensibilidad, también conocida como recall o tasa de verdaderos positivos, mide la capacidad del modelo para detectar correctamente los casos positivos. Matemáticamente se define como:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

Esta métrica es crítica en aplicaciones donde los falsos negativos son costosos, como en la detección de enfermedades o en sistemas de seguridad, donde omitir un caso positivo puede tener repercusiones significativas. (Bishop, 2006)

En Python, se puede calcular con la librería SciKit-Learn mediante la función `recall_score()` del submódulo `metrics`. Esta métrica es fundamental para medir la capacidad del modelo en la detección efectiva de instancias positivas, brindando información clave sobre su desempeño en la identificación de casos afirmativos (Pineda Pertuz, 2022)

2.11.3.4. F1-Score

El F1-score es una métrica que combina la precisión y la sensibilidad en un solo valor, proporcionando una medida equilibrada cuando hay un desbalance entre clases. Matemáticamente se define como:

$$F1 = 2 \times \frac{\text{Precisión} \times \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

Este indicador es útil cuando es necesario evaluar conjuntamente ambas métricas y se busca un equilibrio entre la identificación correcta de casos positivos y la minimización de falsos positivos. (Bishop, 2006)

En Python, se puede calcular utilizando la librería SciKit-Learn a través de la función `f1_score()` del submódulo `metrics`. (Pineda Pertuz, 2022)

2.11.3.5. Curvas ROC (*Receiver Operating Characteristic*)

La Curva ROC evalúa la capacidad del modelo para distinguir entre clases, mostrando la relación entre la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR):

$$TPR = \frac{TP}{TP + FN}, \quad FDR = \frac{FP}{FP + TN}$$

Este indicador es útil cuando es necesario evaluar conjuntamente ambas métricas y se busca un equilibrio entre la identificación correcta de casos positivos y la minimización de falsos positivos. (Bishop, 2006)

Las Curvas Características Operativas del Receptor (ROC) permiten realizar comparaciones entre distintos clasificadores a partir de los puntajes de sus predicciones, los que se pueden interpretar como probabilidades, variando entre 0 y 1. La curva ROC tiene la estructura mostrada en la Figura 2-4.




Figura 2-4 Grafico de Curva ROC

Fuente: (Redondo, 2025)

El objetivo es generar modelos cuyo rendimiento se sitúe entre los segmentos $[0, 0] - [0, 1]$ y $[0, 1] - [1, 1]$. Estas curvas pueden generarse en Python utilizando la librería Scikit-Learn con la función `roc_curve()` del submódulo `metrics`. (Pineda Pertuz, 2022)

2.11.3.6. Matriz de confusión

Una matriz de confusión es una herramienta visual que evalúa el rendimiento de un modelo de clasificación, mostrando aciertos y errores entre los valores reales y las predicciones. Usando la librería Scikit-Learn, esta matriz puede generarse usando el método `confusion_matrix()` del submódulo `metrics`. Es muy útil para clasificaciones binarias, donde se asigna un valor 0 a la clase negativa y 1 a la clase positiva. Una matriz de confusión clásica se puede ver en la Figura 2-5. (Pineda Pertuz, 2022)

		Actual	
		0	1
Predicción	0	VN	FN
	1	FP	VP

Figura 2-5 Grafico de Curva ROC

Fuente: (Pineda Pertuz, 2022)

Donde:

- (VP): Verdaderos Positivos. El modelo predice correctamente la salida como positiva.
- (FN): Falsos Negativos. El modelo predice incorrectamente la salida como negativa
- (FP): Falsos Positivos, El modelo predice incorrectamente la salida como positiva
- (VN): Verdaderos Negativos. El modelo predice correctamente la salida como negativa.

Estos elementos permiten que el algoritmo de clasificación tenga una evaluación más completa de su desempeño, analizando tanto los aciertos como los errores en la predicción de cada clase (Pineda Pertuz, 2022)

2.11.4. Métodos de ajuste y optimización de modelos

2.11.4.1. Validación Cruzada por k-iteraciones

La validación cruzada con k iteraciones es un método que divide aleatoriamente los datos en k pliegues. En cada iteración, se entrenan el modelo con k-1 pliegues y se prueba con el pliegue restante, repitiendo el proceso k veces para asegurar que cada parte se utilice tanto para entrenar como para probar el modelo.

Matemáticamente, el error de validación cruzada se calcula como el promedio de los errores obtenidos en cada iteración:

$$E_{CV} = \frac{1}{k} \sum_{i=1}^k E_i$$

Donde E_i es el error de la validación en la i-ésima iteración.

Bishop (2006) enfatiza que la validación cruzada ayuda a reducir la varianza en la evaluación del modelo y es particularmente útil cuando los datos son limitados. Además, menciona que elegir un valor adecuado de k es crucial: valores pequeños pueden generar una estimación con alta varianza, mientras que valores grandes aumentan el costo computacional.

En Python, este procedimiento se puede implementar con el método `StratifiedKFold`, el cual es particularmente efectivo para conjuntos de datos desbalanceados, ya que mantiene la proporción de clases en cada porción. (Pineda Pertuz, 2022)

2.11.4.2. SMOTE

En problemas de clasificación con conjuntos de datos desbalanceados, donde una o más clases están subrepresentadas, los modelos pueden inclinarse a favor de las clases mayoritarias, ignorando las minoritarias. SMOTE es una técnica diseñada para abordar este desequilibrio mediante la generación de nuevas instancias sintéticas de la clase minoritaria. El proceso implica seleccionar muestras de la clase minoritaria y, para cada una, identificar sus vecinos más cercanos en el espacio de características. Luego, se generan nuevas muestras creando puntos en el segmento de línea que conecta la muestra original con sus vecinos seleccionados al azar. Esta interpolación ayuda a aumentar la representación de la clase

minoritaria, permitiendo que el modelo aprenda mejor sus características y mejore su rendimiento en la clasificación de estas instancias. Esta técnica fue introducida por (Chawla, 2002)

El procedimiento de SMOTE se describe en Bishop (2006) dentro del contexto de métodos de remuestreo y expansión de datos sintéticos:

1. Para cada muestra de la clase minoritaria, se seleccionan aleatoriamente k vecinos más cercanos en el espacio de características.
2. Se elige uno de estos vecinos y se genera un nuevo punto en la línea entre la muestra original y el vecino seleccionado.
3. Este proceso se repite hasta alcanzar el nivel de balance deseado.

Matemáticamente, si x es una instancia de la clase minoritaria y x' es uno de sus vecinos más cercanos, la nueva muestra sintética x_{new} se obtiene como:

$$x_{new} = x + \lambda(x' - x), \quad \text{donde } \lambda \sim U(0,1)$$

donde $U(0,1)$ representa una distribución uniforme entre 0 y 1.

2.11.4.3. One-Hot-Encoding

One Hot Encoding es un método para convertir variables categóricas en un formato binario, creando columnas separadas para cada categoría con valores de 0 y 1. Un valor de 1 indica la presencia de la categoría y 0 su ausencia. Este proceso permite que las variables categóricas sean utilizadas eficazmente en modelos de aprendizaje automático, ayudando a capturar relaciones complejas y mejorando el rendimiento de los modelos. Muchos algoritmos requieren entradas numéricas, lo que hace que One Hot Encoding sea esencial. En Python, se puede implementar usando las bibliotecas Pandas o Scikit-learn. (geekforgeeks, 2025)

Según Bishop (2006), el proceso de One-Hot Encoding se puede describir de la siguiente manera:

1. Se asigna un vector de ceros de tamaño N, donde N es el número de categorías únicas.
2. Se establece en 1 la posición correspondiente a la categoría presente en la observación.

Se puede observar un ejemplo del resultado de la aplicación de One-Hot Encoding a variables categóricas en la Figura 2-6.




Figura 2-6 Ejemplo de One Hot Encoding

Fuente: (Pramoditha, 2021)

3. Marco metodológico

El marco metodológico de este proyecto define el enfoque adoptado para analizar la tasa de "Churn Comercial" en una startup boliviana. A lo largo del estudio, se presentan las estrategias utilizadas para la recopilación, comprensión y procesamiento de los datos, así como el diseño de los modelos de Machine Learning. La metodología establecida resulta fundamental para alcanzar los objetivos planteados en la investigación.

3.1. Área de estudio

El presente estudio se enfoca en el territorio de Bolivia, considerando todas sus ciudades y regiones dentro del análisis. Bolivia se sitúa en el centro de América del Sur, entre los 57°26' y 69°38' de longitud occidental del meridiano de Greenwich y los paralelos 9°38' y 22°53' de latitud sur (INE, 2020)




Figura 3-1 Mapa de distribución de clientes en Bolivia

Fuente: Elaboración propia, noviembre 2024

El objetivo final es proporcionar a la startup boliviana una herramienta clave para la predicción de "Churn Comercial", permitiendo la toma de decisiones fundamentadas en datos.

3.2. Flujograma metodológico

El desarrollo del proyecto sigue la secuencia de pasos descritos en el flujograma presentado en la Figura 3-2, el cual se basa en la metodología CRISP-DM y en la arquitectura Medallion.




Figura 3-2 Flujograma metodológico

Fuente: Elaboración propia en base a CRISP-DM y Arquitectura Medallion (diciembre, 2024)

3.3. Fuentes de información

3.3.1. Fuente de datos primaria: PipeDrive CRM

Los datos utilizados en este análisis provienen de la base de datos de la startup, específicamente de PipeDrive, el CRM en el que se registran y almacenan todas las interacciones y datos relacionados con sus clientes. La información abarca el período comprendido entre los años 2021 y 2024 y se extrae en formato JSON como metadata a través de la librería ‘requests’ en Python desde la API de PipeDrive. (Anexo 1).

Los datos cuentan con un total de cuatro tablas los cuales se dividen en dos tipos de tablas:

- a) **Deals:** Contiene información sobre los negocios creados en PipeDrive, incluyendo datos clave sobre los clientes y sus características.
- b) **Activities:** Registra todas las actividades realizadas con los clientes a lo largo de todo su ciclo de vida, reflejando el seguimiento y la interacción con los clientes.

Esta estructura permite un análisis detallado del comportamiento de los clientes y las dinámicas comerciales dentro de la startup boliviana.

3.3.2. Fuentes de datos secundarias

- **Documentación técnica:** Se utilizarán manuales y guías técnicas.
- **Estudios de casos:** Se analizarán proyectos previos con el mismo enfoque.
- **Literatura académica:** Artículos y documentación sobre análisis de datos se usarán para enriquecer el proyecto con un enfoque académico.

3.4. Comprensión del negocio

En esta fase, el objetivo principal es comprender a fondo el negocio, incluyendo su misión, visión y objetivos estratégicos. Esto permite establecer las bases que guiarán el desarrollo del proyecto, asegurando su alineación con las necesidades y metas de la empresa. Es fundamental considerar que la startup boliviana opera bajo un modelo Business to Business (B2B), dirigido específicamente a pequeñas y medianas empresas del país. Además, dentro del contexto de la startup, el ‘Churn Comercial’ se define como el abandono del cliente dentro de los primeros 90 días tras una conversión exitosa.

3.4.1. Objetivos del negocio

- Prevenir casos de ‘Churn Comercial’.
- Optimizar recursos en la etapa de experiencia.
- Conocer características de los clientes que hacen ‘Churn Comercial’.

3.4.2. Situación actual de la startup

La startup boliviana, con seis años de trayectoria en el mercado y especializada en un producto SaaS enfocado en la gestión de inventarios, opera con un equipo de menos de cincuenta profesionales. Su estructura organizativa se compone de las áreas de Marketing, Comercial, Experiencia, Tecnología, Data, People & Happiness, Legal y Contabilidad. A pesar de contar con un equipo reducido y una trayectoria relativamente corta, la empresa se encuentra sólidamente estructurada y orientada hacia un crecimiento rápido y escalable. Su visión a largo plazo contempla la expansión en Latinoamérica, con un enfoque inicial en México y Perú. Su presencia en un nicho innovador la posiciona como pionera en el sector dentro de Bolivia.

La empresa clasifica a sus clientes en tres categorías: ‘A’, ‘B’ y ‘C’. Esta segmentación fue definida en un estudio previo a la elaboración del presente proyecto, por lo que la inclusión de esta variable resulta de gran importancia para la empresa.

Luego de un análisis previo sobre la composición de los clientes que realizan ‘Churn Comercial’ por ciudad, no se identifica una cifra alarmante que sugiera que el ‘Churn Comercial’ sea característico de una región en particular. En promedio, la tasa de ‘Churn Comercial’ por ciudad es del 11.2%, concentrándose principalmente en las ciudades metropolitanas de Bolivia: Cochabamba, La Paz y Santa Cruz de la Sierra. Esto se explica por la alta concentración de clientes en estas tres ciudades clave del país. Por lo tanto, la variable ‘Ciudad’ no será considerada relevante para la realización de este proyecto.

3.4.3. Procesos actuales de la empresa




Figura 3-3 Diagrama del ciclo de vida de un cliente en los procesos de la startup

Fuente: Elaboración propia, (enero, 2025)

La empresa actualmente dispone de embudos que forman parte del ciclo de vida de sus clientes. Para comprender con precisión las actividades y eventos que ocurren en cada embudo, se ha elaborado un diagrama. Resulta fundamental el entendimiento de estos procesos, ya que proporcionará información clave para realizar los cálculos pertinentes y seleccionar los campos más relevantes para el modelo predictivo. A continuación, en la Figura 3-3, se presenta el proceso que será objeto de estudio.

La empresa actualmente dispone de embudos que forman parte del ciclo de vida de sus clientes. Para comprender con precisión las actividades y eventos que ocurren en cada embudo, se ha elaborado un diagrama. Resulta fundamental el entendimiento de estos procesos, ya que proporcionará información clave para realizar los cálculos pertinentes y seleccionar los campos más relevantes para el modelo predictivo. A continuación, en la Figura 3-3, se presenta el proceso que será objeto de estudio.

Una vez que los clientes ingresan al proceso comercial, deben atravesar distintas etapas. La primera de ellas es la Reunión R1, la cual requiere ser agendada y concretada. Para lograrlo, es necesario contactar a los clientes a través de llamadas de prospección.

3.4.4. Recursos y Restricciones

- a) **Recursos:** La startup dispone de una base de datos histórica de sus clientes, así como de herramientas de software gratuitas para la extracción, procesamiento y almacenamiento de información. Además, cuenta con un equipo dedicado exclusivamente al análisis de datos dentro de la empresa.
- b) **Restricciones:** Debido a su reciente incursión en el mercado, la cantidad de información histórica es limitada, ya que aún no dispone de un volumen significativo de clientes y datos acumulados.

3.5. Extracción de datos

La extracción de datos se realizó a través de una conexión a la API del CRM PipeDrive, empleado por la startup para registrar información clave sobre sus clientes. Este proceso permitió recopilar datos a lo largo de todo el ciclo de vida del cliente, desde su incorporación en la base de datos hasta el momento en que es considerado como perdido. La estructura de extracción de datos Medallion utilizada en este proyecto se encuentra detallada en el Anexo 1.

Es importante destacar que la base de datos a la que se tiene acceso es de naturaleza privada y confidencial. La obtención de estos datos se realizó bajo un acuerdo previo con la empresa, que incluyó la autorización y los permisos necesarios, así como el cumplimiento de condiciones y términos de seguridad establecidos para garantizar la protección de la información.

3.5.1. Capas de la arquitectura Medallion

Los datos fueron extraídos y estructurados conforme a la arquitectura Medallion, lo que permitió un procesamiento eficiente mediante sus capas de bronce, plata y oro.

3.5.1.1. Capa Bronce (Bronze Layer)

Inicialmente, se crearon filtros en la API del CRM Pipedrive para extraer los datos relevantes para el proyecto. Posteriormente, se estableció la conexión con la API para llevar a cabo la extracción de datos, utilizando el lenguaje de programación Python y la librería ‘requests’ en la consola ‘Visual Studio Code (VS Code)’. Como resultado, se obtuvo una base de datos en bruto en formato JSON. (Anexo 2).

3.5.1.2. Capa Plata (Silver Layer)

La capa Plata está conformada por subcapas diseñadas para llevar a cabo funciones específicas en el procesamiento y transformación de los datos obtenidos en la etapa anterior. Durante esta fase, los datos fueron estandarizados, filtrados y enriquecidos mediante el uso del lenguaje de programación Python, empleando las librerías ‘Numpy’ y ‘Pandas’, las cuales son ampliamente utilizadas en el ámbito de la ciencia de datos:

1. **Subcapa plata estandarización (Silver standardized sub-layer):** Una vez obtenidos los datos en la capa Bronce, se llevó a cabo el proceso de mapeo y estandarización. En esta subcapa, se asignaron los valores correspondientes a cada elemento extraído como metadata, garantizando que la información contara con una estructura coherente y adecuada para su posterior análisis. (Anexo 3).
2. **Subcapa plata filtrado (Silver filtered sub-layer):** Con la información ya estandarizada, se realizó un filtrado de columnas para identificar aquellas relevantes para el desarrollo del proyecto. Este proceso permitió seleccionar únicamente las variables con valor significativo para el análisis, descartando aquellas que no aportaban información útil para el modelo predictivo de ‘Churn Comercial’. (Anexo 4).
3. **Subcapa plata enriquecimiento (Silver enriched sub-layer):** En esta subcapa, se realizó la integración de las tablas mediante la llave principal, asegurando una unificación completa de la información. Asimismo, se llevaron a cabo transformaciones de variables, la generación de nuevas variables categóricas y numéricas, y otras operaciones necesarias para enriquecer los datos y prepararlos para un análisis exploratorio. (Anexo 5).

3.5.1.3. Capa Oro (Gold Layer)

Finalmente, en la capa Oro se llevaron a cabo las agregaciones necesarias y el procesamiento final, obteniendo una base de datos limpia y estructurada, adecuada para el entrenamiento del Modelo Predictivo de ‘Churn Comercial’. (Anexo 6).

3.5.2. Entendimiento de los datos

Para lograr un entendimiento completo de los datos, se llevó a cabo un análisis exhaustivo mediante el uso de herramientas clave que permitieron explorar y comprender la estructura, los patrones y las relaciones entre los datos disponibles. Además, se realizaron consultas constantes a las partes interesadas dentro de la startup, quienes aportaron información valiosa para mejorar la comprensión de los datos. Este proceso de análisis inicial estableció las bases para el desarrollo de modelos predictivos precisos y

eficaces, asegurando que los datos fueran interpretados correctamente y utilizados de manera óptima para la toma de decisiones.

Inicialmente, se realizó la búsqueda y selección de los datos necesarios que contienen la información fundamental para el proyecto. Luego, se efectuó un análisis de la organización de cada conjunto de datos, cuyas características se detallan en la Tabla 3-1. Para facilitar la comprensión de las interrelaciones entre las diversas tablas, se incluye un diagrama entidad relación de los datos en la Figura 3-4.




Figura 3-4 Diagrama de Entidad Relación

Fuente: Elaboración propia, (enero, 2025)

Nombre de la tabla	Descripción
'deals_com'	Contiene información sobre características de los clientes 'ganados' correspondientes al embudo comercial
'deals_exp'	Contiene información sobre características de los clientes 'ganados' correspondientes al embudo de experiencia
'activities_com'	Contiene información sobre todas las acciones realizadas con los clientes 'ganados' correspondientes a las etapas dentro del embudo comercial
'activities_exp'	Contiene información sobre todas las acciones realizadas con los clientes 'ganados' correspondientes a las etapas dentro del embudo de experiencia

Tabla 3-1 Descripción de los datos

Fuente: Elaboración propia, (enero, 2025)

Después de tener identificadas y comprendidas las tablas que serían útiles para el desarrollo de este proyecto (extraídas en la Capa Bronce), se procedió a la correspondiente estandarización y filtrado de los campos que serían relevantes para el modelo (datos obtenidos en las subcapas plata: estandarización y filtrado) y finalmente se llevó a cabo la integración de todas las tablas en una resultante, los cálculos de nuevos campos, transformación de campos y finalmente la selección de los campos relevantes para el Análisis Exploratorio de Datos (EDA) correspondiente. A continuación, en la Tabla 3-2, se detallan los campos que fueron finalmente seleccionados como relevantes de la capa plata

Variable	Descripción	Tipo
'org_id.value'	identificador único de cada organización	integer
'Tipo de cliente'	clasificación de clientes tipo ABC	string
'(C) (EXP) Plazo y Pago'	plan de pago del cliente	string
'Total_Actividades_com'	conteo del total de actividades en etapa comercial	integer
'Total_Llamadas_com'	llamadas totales hechos en etapa comercial	integer
'Llamadas_Efectivas_com'	llamadas efectivas hechos en etapa comercial	integer
'Llamadas_No_Efectivas_com'	llamadas no efectivas hechos en etapa comercial	integer
'WA_Seguimiento_com'	seguimientos por WhatsApp en etapa comercial	integer
'Reuniones_Hechas'	reuniones hechas	integer
'Reuniones_Canceladas'	reuniones canceladas	integer
'Tipo Primer Contacto'	tipo de primer contacto	string
'Rango de Contacto'	primer contacto dentro o fuera de rango	string
'R1yR2'	dummie de si tuvo R1 y R2	string
'Total_Actividades_exp'	conteo del total de actividades en etapa experiencia	integer
'Total_Llamadas_exp'	llamadas totales hechas en etapa experiencia	integer
'Llamadas_Efectivas_exp'	llamadas efectivas hechos en etapa experiencia	integer
'Llamadas_No_Efectivas_exp'	llamadas no efectivas hechos en etapa experiencia	integer
'WA_Seguimiento_exp'	seguimientos por WhatsApp en etapa comercial	integer
'Kickoff_Hechas'	Kick Off hechas	integer

Variable	Descripción	Tipo
'Kickoff_Canceladas'	Kick Off canceladas	integer
'Capacitaciones_Hechas'	capacitaciones ERP hechas	integer
'Capacitaciones_Canceladas'	capacitaciones ERP canceladas	integer
'Tipo Primera Capacitación'	tipo de primera Capacitacion ERP	string
'Onboarding',	estado de Onboarding	string
'New Categories'	quiebre estructural desde abril 2024	integer

Tabla 3-2 Descripción de los campos de la tabla de la subcapa plata de enriquecimiento.

Fuente: Elaboración propia, (enero, 2025)

Es importante mencionar que los datos con los que se están trabajando en este proyecto no se tratan de datos poblacionales. Esto se debe a que algunos negocios ya existían antes de enero del 2021 y su historial de interacciones comenzó antes de esa fecha, por lo que no todos los clientes creados en el embudo comercial desde 2021 forman parte de la tabla de experiencia.

3.6. Análisis y preparación de los datos

Se realizó un análisis exhaustivo de los datos y una preparación adecuada para garantizar su efectividad en el entrenamiento de los modelos predictivos.

3.6.1. Análisis Exploratorio de Datos (EDA)

En esta etapa, se realizó un análisis exhaustivo para identificar tendencias, patrones y correlaciones dentro de los datos. Se clasificaron las variables en cualitativas y cuantitativas, lo que permitió una mejor comprensión de la estructura de los datos y facilitó el análisis posterior. Los detalles sobre las variables cualitativas pueden encontrarse en la Tabla 3-3.

Variable	Tipo	Valores
'Tipo de cliente'	nominal	'A', 'B', 'C'
'(C) (EXP) Plazo y Pago'	nominal	'Anual', 'Mensual', 'Otros'
'Tipo Primer Contacto'	nominal	'Efectiva', 'No Efectiva', 'No tuvo', 'Sin Avance'
'Rango de Contacto'	nominal	'Dentro del rango', 'Fuera del rango', 'Sin Llamada de primero contacto'
'R1yR2'	binaria	0: No tuvo R1 y R2, 1: Tuvo R1 y R2
'Tipo Primera Capacitación'	nominal	'Hecha', 'No tuvo'

Variable	Tipo	Valores
'Onboarding',	nominal	Finalizado
'New Categories'	binaria	quiebre estructural desde abril 2024
'Churn Comercial'	nominal	quiebre estructural desde abril 2024

Tabla 3-3 Detalle de las variables cualitativas

Fuente: Elaboración propia, (enero, 2025)

Los detalles sobre las variables cuantitativas pueden encontrarse en la Tabla 3-4.

Variable	Tipo
'Total_Actividades_com'	discreto
'Total_Llamadas_com'	discreto
'Llamadas_Efectivas_com'	discreto
'Llamadas_No_Efectivas_com'	discreto
'WA_Seguimiento_com'	discreto
'Reuniones_Hechas'	discreto
'Reuniones_Canceladas'	discreto
'Total_Actividades_exp'	discreto
'Total_Llamadas_exp'	discreto
'Llamadas_Efectivas_exp'	discreto
'Llamadas_No_Efectivas_exp'	discreto
'WA_Seguimiento_exp'	discreto
'Kickoff_Hechas'	discreto
'Kickoff_Canceladas'	discreto
'Capitaciones_Hechas'	discreto
'Capitaciones_Canceladas'	discreto

Tabla 3-4 Detalle de las variables cuantitativas

Fuente: Elaboración propia, (enero, 2025)

3.6.1.1. Descripción Estadística

La descripción estadística es el resumen de un conjunto de datos mediante medidas numéricas que representan sus características principales.

Se presentan las variables cuantitativas de acuerdo a los embudos a los que pertenecen, la simbología sigue la siguiente descripción:

- n : Recuento
- $\bar{x}$: Media
- $\tilde{x}$: Mediana
- Mín. : Valor mínimo
- Max. : Valor máximo
- Rango : Rango
- IQR : Rango Intercuartílico
- Q1 : Valor del primer cuartil (25%)
- Q2 : Valor del segundo cuartil (50%)
- Q3 : Valor del tercer cuartil (75%)
- σ : Desviación estándar
- σ^2 : Varianza

3.6.1.1.1. Variables del Embudo Comercial

1. Se puede observar las medidas estadísticas de los datos correspondientes al embudo comercial en la Tabla 3-5.

Variable	n	$\bar{x}$	$\tilde{x}$	Mín.	Max	Rango	IQR	Q1	Q2	Q3	σ	σ^2
1	373	12.93	10	1	42	41	11	6	10	17	10.20	104.04
2	373	6.40	4	0	21	21	7	2	4	9	5.77	33.30
3	373	4.23	3	0	13	13	4	2	3	6	3.57	12.74
4	373	2.12	1	0	10	10	3	0	1	3	2.85	8.12
5	373	4.96	4	0	15	15	5	2	4	7	4.08	16.65
6	373	1.13	1	0	3	3	1	1	1	2	0.72	0.52
7	373	0.16	0	0	3	3	0	0	0	0	0.51	0.26

Tabla 3-5 Detalle de las variables cuantitativas del embudo comercial

Fuente: Elaboración propia, (enero, 2025)

El total de observaciones para todas las variables de la etapa comercial es de 373, lo que indica que no hay valores faltantes (NaN).

Las variables corresponden a la siguiente numeración:

1. **'Total_Actividades_com'**: La media es de 12.93, lo que sugiere que, en promedio, los clientes completan 12 actividades. La mediana es de 10, lo que significa que la mitad de los clientes realizan 10 actividades o menos. El valor mínimo es 1 y el máximo es 42, indicando que los clientes completan entre 1 y 42 actividades. El rango intercuartílico es de 11, lo que implica que el 50% de los clientes completan entre 6 y 17 actividades. La varianza y la desviación estándar de las actividades son significativas, lo que sugiere una gran variabilidad.
2. **'Total_Llamadas_com'**: La media es de 6.40, lo que sugiere que, en promedio, los clientes reciben 6 llamadas. La mediana es de 4, lo que significa que la mitad de los clientes reciben 4 llamadas o menos. El valor mínimo es 0 y el máximo es 21, lo que indica que algunos clientes no reciben llamadas, mientras que otros pueden recibir hasta 21 llamadas. El rango intercuartílico es de 7, lo que implica que el 50% de los clientes reciben entre 2 y 9 llamadas. Además, la varianza y la desviación estándar son significativas, lo que indica que hay una considerable variabilidad.
3. **'Llamadas_Efectivas_com'**: La media es de 4.23, lo que sugiere que, en promedio, se logran 4 llamadas efectivas. La mediana es de 3, lo que significa que se logran 3 o menos llamadas efectivas con la mitad de los clientes. El valor mínimo es 0 y el máximo es 13, lo que indica que con algunos clientes no se logran llamadas efectivas, mientras que con otros se pueden lograr hasta 13 llamadas efectivas. El rango intercuartílico es de 4, lo que implica que con el 50% de los clientes se logran entre 2 y 6 llamadas efectivas. La varianza y la desviación estándar indican que hay una baja variabilidad.
4. **'Llamadas_No_Efectivas_com'**: La media es de 2.12, lo que sugiere que, en promedio, se tienen 2 llamadas no efectiva. La mediana es de 1, lo que significa que se tiene 1 llamada no efectiva con la mitad de los clientes. El valor mínimo es 0 y el máximo es 10, lo que indica que con algunos clientes no se tienen llamadas no efectivas, mientras que con otros se pueden alcanzar a tener hasta 10 llamadas no efectivas. El rango intercuartílico es de 3, lo que implica que con el 50% de los clientes se tienen entre 0 y 3 llamadas no efectivas. La varianza y la desviación estándar indican que hay una baja variabilidad.
5. **'WA_Seguimiento_com'**: La media es de 4.96, lo que sugiere que, en promedio, se mandan 4 mensajes de seguimiento. La mediana es de 4, lo que significa que se mandan 4 o menos mensajes a la mitad de los clientes. El valor mínimo es 0 y el máximo es 15, lo que indica que a algunos clientes no se le mandan ningún mensaje de seguimiento, mientras que a otros se pueden mandar hasta 15 mensajes. El rango intercuartílico es de 5, lo que implica que al 50% de los clientes se mandan entre 2 y 7 mensajes de seguimiento. La varianza y la desviación estándar indican que hay una baja variabilidad.
6. **'Reuniones_Hechas'**: La media es de 1.13, lo que sugiere que, en promedio, se tiene 1 reunión efectiva. La mediana es de 1, lo que significa que se tiene 1 o ninguna reunión con la mitad de los clientes. El valor mínimo es 0 y el máximo es 3, lo que indica que con algunos clientes no se tiene ninguna reunión, mientras que con otros se pueden tener hasta 3 reuniones, comprendidas entre R1 y R2. El rango intercuartílico es de 1, lo que implica que con el 50% de los clientes se

tienen entre 1 y 2 reuniones. La varianza y la desviación estándar indican que hay una baja variabilidad.

7. **'Reuniones_Canceladas'**: La media es de 0.16, lo que sugiere que, en promedio, los clientes no cancelan ninguna reunión. La mediana es de 0, lo que significa la mitad de los clientes no suelen cancelar reuniones. El valor mínimo es 0 y el máximo es 3, lo que indica que algunos clientes no cancelan reuniones, mientras que otros pueden cancelar hasta 3 reuniones, comprendidas entre R1 y R2. El rango intercuartílico es de 0, lo que implica que el 50% de los clientes no cancela reuniones. La varianza y la desviación estándar indican que hay una baja variabilidad.

3.6.1.1.2. Variables del Embudo Experiencia

Se puede observar las medidas estadísticas de los datos correspondientes al embudo de experiencia en la Tabla 3-6.

Variable	n	$\bar{x}$	$\tilde{x}$	Mín.	Max	Rango	IQR	Q1	Q2	Q3	σ	σ^2
1	373	5.62	4	1	17	16	6	2	4	8	4.59	21.07
2	373	1.66	1	0	7	7	3	0	1	3	2.11	4.45
3	373	0.74	0	0	3	3	1	0	0	1	0.97	0.94
4	373	0.88	0	0	5	5	1	0	0	1	1.48	2.19
5	373	2.09	1	0	9	9	3	0	1	3	2.74	7.50
6	373	0.78	0	0	3	3	1	0	0	1	1.01	1.02
7	373	0.26	0	0	2	2	0	0	0	0	0.54	0.29

Tabla 3-6 Detalle de las variables cuantitativas del embudo experiencia

Fuente: Elaboración propia, (enero, 2025)

El total de observaciones para todas las variables de la etapa comercial es de 373, lo que indica que no hay valores faltantes (NaN).

Las variables corresponden a la siguiente numeración:

1. **'Total_Actividades_exp'**: La media es de 5.62, lo que sugiere que, en promedio, los clientes completan 5 actividades. La mediana es de 4, lo que significa que la mitad de los clientes realizan 4 actividades o menos. El valor mínimo es 1 y el máximo es 17, indicando que los clientes completan entre 1 y 17 actividades. El rango intercuartílico es de 6, lo que implica que el 50% de los clientes completan entre 2 y 8 actividades. La varianza y la desviación estándar de las actividades son moderadas, lo que sugiere una gran variabilidad.
2. **'Total_Llamadas_exp'**: La media es de 1.66, lo que sugiere que, en promedio, los clientes reciben 1 llamada. La mediana es de 1, lo que significa que la mitad de los clientes reciben 1 llamadas o ninguna. El valor mínimo es 0 y el máximo es 7, lo que indica que algunos clientes no

reciben llamadas, mientras que otros pueden recibir hasta 7 llamadas. El rango intercuartílico es de 3, lo que implica que el 50% de los clientes reciben entre 0 y 3 llamadas. La varianza y la desviación estándar son significativas, lo que indica que hay una considerable variabilidad.

3. **'Llamadas_Efectivas_exp'**: La media es de 0.74, lo que sugiere que, en promedio, se logran 0 llamadas efectivas. La mediana es de 0, lo que significa que no se logran llamadas efectivas con la mitad de los clientes. El valor mínimo es 0 y el máximo es 3, lo que indica que con algunos clientes no se logran llamadas efectivas, mientras que con otros se pueden lograr hasta 3 llamadas efectivas. El rango intercuartílico es de 1, lo que implica que con el 50% de los clientes se logran entre 0 y 1 llamadas efectivas. La varianza y la desviación estándar indican que hay una baja variabilidad.
4. **'Llamadas_No_Efectivas_exp'**: La media es de 0.88, lo que sugiere que, en promedio, no se tienen llamadas no efectivas. La mediana es de 0, lo que significa que no se tienen llamadas no efectiva con la mitad de los clientes. El valor mínimo es 0 y el máximo es 5, lo que indica que con algunos clientes no se tienen llamadas no efectivas, mientras que con otros se pueden alcanzar a tener hasta 5 llamadas no efectivas. El rango intercuartílico es de 1, lo que implica que con el 50% de los clientes se tienen entre 0 y 1 llamadas no efectivas. La varianza y la desviación estándar indican que hay una variabilidad moderada.
5. **'WA_Seguimiento_exp'**: La media es de 2.09, lo que sugiere que, en promedio, se mandan 2 mensajes de seguimiento. La mediana es de 1, lo que significa que se mandan 1 o ningún mensaje a la mitad de los clientes. El valor mínimo es 0 y el máximo es 9, lo que indica que a algunos clientes no se le mandan ningún mensaje de seguimiento, mientras que a otros se pueden mandar hasta 9 mensajes. El rango intercuartílico es de 3, lo que implica que al 50% de los clientes se mandan entre 0 y 3 mensajes de seguimiento. La varianza y la desviación estándar indican que hay alta variabilidad.
6. **'Capacitaciones_Hechas'**: La media es de 0.78, lo que sugiere que, en promedio, no se tiene una Capacitación ERP efectiva. La mediana es de 0, lo que significa que no se tiene ninguna Capacitación con la mitad de los clientes. El valor mínimo es 0 y el máximo es 3, lo que indica que con algunos clientes no se tiene ninguna capacitación, mientras que con otros se pueden tener hasta 3 capacitaciones. El rango intercuartílico es de 1, lo que implica que con el 50% de los clientes se tienen entre 0 y 1 capacitaciones. La varianza y la desviación estándar indican que hay una baja variabilidad.
7. **'Capacitaciones_Canceladas'**: La media es de 0.26, lo que sugiere que, en promedio, los clientes no cancelan ninguna Capacitación ERP. La mediana es de 0, lo que significa la mitad de los clientes no suelen cancelar capacitaciones. El valor mínimo es 0 y el máximo es 2, lo que indica que algunos clientes no cancelan capacitaciones, mientras que otros pueden cancelar hasta 2 capacitaciones. El rango intercuartílico es de 0, lo que implica que el 50% de los clientes no cancela capacitaciones. La varianza y la desviación estándar indican que hay una baja variabilidad.

3.6.1.1.3. Variables Cualitativas

Se puede observar las medidas estadísticas de los datos correspondientes al embudo de experiencia en la tabla 3-7.

Variable	n	Valores Únicos	Moda	Frecuencia	%
'Tipo de cliente'	373	3	'B'	235	63.00
'(C) (EXP) Plazo y Pago'	373	3	'Anual'	285	76.41
'Tipo Primer Contacto'	373	4	'Efectiva'	222	59.52
'Rango de Contacto'	373	3	'Fuera de Rango'	224	60.05
'R1yR2'	373	2	'0'	310	83.11
'Tipo Primera Capacitación'	373	2	'Hecha'	202	54.16
'Onboarding'	373	2	'No Finalizado'	276	74.00
'Churn Comercial'	373	2	0	338	90.62

Tabla 3-7 Detalle de las variables cualitativas

Fuente: Elaboración propia, (enero, 2025)

La mayoría de los clientes ganados pertenecen al tipo B, representando el 63% del total. La mayor parte de los clientes está suscrita a un plan de pago anual, lo que equivale al 76.41% del total. En cuanto al primer contacto, este suele ser efectivo en un 59.52% de los casos. Un 60.05% de los clientes son contactados fuera del rango establecido de los seis minutos. Además, una gran mayoría, específicamente el 83.11%, no realiza las reuniones R1 y R2 durante su proceso en el embudo comercial. La primera capacitación se lleva a cabo en el 54.16% de los casos. Asimismo, la mayoría de los clientes no ha completado el proceso de onboarding. Finalmente, un 90.62% de los clientes se mantienen activos o han generado un 'churn' después de más de 90 días.

3.6.1.2. Análisis Univariante

Se realizó un análisis por cada variable numérica y categórica. (Anexo 7.)

3.6.1.2.1. Variables del Embudo Comercial

En el histograma de la variable 'Total_Actividades_com' (Figura 3-5), se observa que la mayoría de los clientes completan entre 4 y 10 actividades, con una disminución en la cantidad de clientes a medida que aumentan las actividades, lo que sugiere que hay pocos clientes con seguimiento continuo.




Figura 3-5 Histograma de distribución de la variable 'Total_Actividades_com'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable 'Total_Llamadas_com' (Figura 3-6), se observa que la mayoría de los clientes reciben entre 1 y 3 llamadas, con una disminución en la cantidad de clientes a medida que aumentan las llamadas, lo que sugiere que hay pocos clientes con los que se tiene una persecución.




Figura 3-6 Histograma de distribución de la variable 'Total_Llamadas_com'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable 'Llamadas_Efectivas_com' (Figura 3-7), se observa que la mayoría de los clientes reciben entre 1 y 4 llamadas efectivas. A medida que aumenta el número de llamadas, la cantidad de clientes disminuye, lo que sugiere que solo un pequeño grupo de clientes requiere un seguimiento intensivo con altas cantidades de llamadas efectivas en la etapa comercial.



Figura 3-7 Histograma de distribución de la variable 'Llamadas_Efectivas_com'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘WA_Seguimiento_com’ (Figura 3-9), se observa que la mayoría de los clientes reciben entre 2 y 4 mensajes de seguimiento por WhatsApp, lo que sugiere que la mayoría de los clientes tienen un número moderado de seguimientos. A medida que aumenta la cantidad de mensajes, la frecuencia de clientes disminuye, indicando que son pocos los clientes que reciben más de 4 mensajes de seguimiento.




Figura 3-8 Histograma de distribución de la variable ‘Llamadas_No_Efectivas_com’

Fuente: Elaboración propia, (enero, 2025)




Figura 3-9 Histograma de distribución de la variable ‘WA_Seguimiento_com’

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Reuniones_Hechas’ (Figura 3-10), se observa que la mayoría de los clientes tienen al menos 1 reunión efectiva. Son muy pocos los clientes que no tienen ningún tipo de reunión al igual que los que tienen 2 reuniones, son muy pocos los clientes que tienen más de 2 reuniones.




Figura 3-10 Histograma de distribución de la variable 'Reuniones_Hechas'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable 'Reuniones_Canceladas' (Figura 3-11), se observa que la mayoría de los clientes no han cancelado reuniones. Solo un pequeño grupo ha realizado al menos una cancelación, y en casos excepcionales, algunos clientes han cancelado hasta tres reuniones.




Figura 3-11 Histograma de distribución de la variable 'Reuniones_Canceladas'

Fuente: Elaboración propia, (enero, 2025)

3.6.1.2.2. Variables del Embudo Experiencia

En el histograma de la variable 'Total_Actividades_exp' (Figura 3-12), se observa que la mayoría de los clientes completan entre 1 y 5 actividades. A medida que aumenta el número de actividades, la cantidad de clientes disminuye considerablemente, lo que sugiere que solo un pequeño grupo alcanza hasta 17 actividades.




Figura 3-12 Histograma de distribución de la variable 'Total_Actividades_com'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Total_Llamadas_exp’ (Figura 3-13), se observa que la mayoría de los clientes reciben entre 0 y 1 llamada. A medida que aumenta el número de llamadas, la cantidad de clientes disminuye notablemente, lo que sugiere que las llamadas no son frecuentes en la etapa de experiencia.




Figura 3-13 Histograma de distribución de la variable ‘Total_Llamadas_exp’

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Llamadas_Efectivas_exp’ (Figura 3-14), se observa que las llamadas efectivas en la etapa de experiencia son poco frecuentes. La cantidad de clientes que reciben al menos una llamada es reducida, y a medida que aumenta el número de llamadas, la cantidad de clientes disminuye aún más.




Figura 3-14 Histograma de distribución de la variable ‘Llamadas_Efectivas_exp’

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Llamadas_No_Efectivas_exp’ (Figura 3-15), se observa que la mayoría de los clientes no reciben llamadas no efectivas, lo que sugiere que este tipo de interacción es poco común en la etapa de experiencia. A medida que aumenta el número de llamadas no efectivas, la cantidad de clientes disminuye, indicando que solo una minoría llega a recibir hasta 5 llamadas de este tipo.





Figura 3-15 Histograma de distribución de la variable 'Llamadas_No_Efectivas_exp'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable 'WA_Seguimiento_exp' (Figura 3-16), se observa que la mayoría de los clientes no reciben mensajes de seguimiento por WhatsApp durante la etapa de experiencia, lo que sugiere que este tipo de contacto no es una práctica común en dicha fase.



4

Figura 3-16 Histograma de distribución de la variable 'WA_Seguimiento_com'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable 'Kickoff_Hechas' (Figura 3-17), se observa que la cantidad de clientes que han tenido al menos un Kickoff es igual a la de aquellos que no lo han realizado. En otras palabras, existe una distribución equilibrada entre ambos grupos. Según lo conversado con los encargados del área de experiencia, esta situación podría deberse a un error en el registro de datos.




Figura 3-17 Histograma de distribución de la variable 'Kickoff_Hechas'

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Kickoff_Canceladas’ (Figura 3-18), se observa que la mayoría de los clientes no cancelan la Kickoff, lo que no tiene consistencia con la distribución de la variable ‘Kickoff_Hechas’. Son muy pocos los clientes que cancelan la Kickoff. esto también puede deberse a un error en el llenado de datos.




Figura 3-18 Histograma de distribución de la variable ‘Kickoff _Canceladas’

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Capacitaciones_Hechas’ (Figura 3-19), se observa que la mayoría de los clientes no llegan a tener capacitaciones ERP, se ve que son muy poco frecuentes los clientes que cancelan hasta 3 reuniones.




Figura 3-19 Histograma de distribución de la variable ‘Capacitaciones_Hechas’

Fuente: Elaboración propia, (enero, 2025)

En el histograma de la variable ‘Capacitaciones_Canceladas’ (Figura 3-20), se observa que la mayoría de los clientes no cancelan las capacitaciones ERP, se ve que son muy poco frecuentes los clientes que cancelan hasta 3 reuniones.




Figura 3-20 Histograma de distribución de la variable 'Capacitaciones_Canceladas'

Fuente: Elaboración propia, (enero, 2025)

3.6.1.2.3. Variables Cualitativas

El tipo de clientes se clasifica en 3 categorías: 'A', 'B' y 'C'. Como se muestra en la Figura 3-21, esta categorización fue realizada en un estudio previo dentro de la startup, el cual agrupa diversas características de los clientes. Se observa que la mayoría de los clientes (63.02%) corresponden a la categoría B.




Figura 3-21 Grafica de barras de 'Tipo de cliente'

Fuente: Elaboración propia, (enero, 2025)

Los clientes se suscriben con un plan de pago que puede ser 'Bianual', 'Anual', 'Semestral', 'Trimestral', 'Mensual' u 'Otros'. Como se muestra en la Figura 3-22, Se observa que la mayoría de los clientes (76.41%) están suscritos un plan de pago 'Anual'.




Figura 3-22 Grafica de barras de '(C) (EXP) Plazo y Pago'

Fuente: Elaboración propia, (enero, 2025)

El primer contacto se clasifica en: ‘Efectivo’, ‘No Efectivo’, ‘Sin Avance’ o ‘No tuvo’. Como se observa en la Figura 3-23, la mayoría de los clientes tienen un primer contacto ‘Efectivo’ (59.52%) de los clientes de la empresa.




Figura 3-23 Grafica de barras de ‘Tipo Primer Contacto’

Fuente: Elaboración propia, (enero, 2025)

El tiempo transcurrido desde la creación del negocio en el CRM hasta el primer contacto en la etapa comercial puede clasificarse en Dentro de rango, Fuera de rango o Sin llamada de primer contacto. Como se observa en la Figura 3-24, en la mayoría de los casos (60.05% de los clientes), este primer contacto ocurre fuera del rango de los 6 minutos establecidos como métrica previa en la startup.




Figura 3-24 Grafica de barras de 'Rango de Contacto'

Fuente: Elaboración propia, (enero, 2025)

El hecho de haber tenido R1 y R2 en la etapa comercial se clasifica en 0 (No) y 1 (Sí). Como se muestra en la Figura 3-25, la mayoría de los clientes (83.10%) no completan ambas reuniones, lo que indica que son pocos los casos en los que se cumplen todas las etapas de la fase comercial.




Figura 3-25 Grafica de barras de 'R1yR2'

Fuente: Elaboración propia, (enero, 2025)

En la Figura 3-26, se muestra la clasificación del tipo de primera capacitación en tres categorías: 'Hecha', 'Cancelada' y 'No tuvo'. La mayoría de los clientes (54.15%) tiene su primera capacitación registrada como 'Hecha'. Además, la distribución es casi equitativa entre quienes realizaron la capacitación y quienes no la tuvieron. No se registran casos en la categoría de 'Cancelada', lo que indica que los clientes que no la completaron simplemente no llegaron a agendarla.




Figura 3-26 Grafica de barras de ‘Tipo Primera Capacitación’

Fuente: Elaboración propia, (enero, 2025)

En la Figura 3-27, se presenta la clasificación del estado de Onboarding en dos categorías: ‘Finalizado’ y ‘No Finalizado’. La mayoría de los clientes (74%) no llega a completar este proceso, lo que sugiere que existen barreras o dificultades que impiden su finalización.




Figura 3-27 Grafica de barras de ‘Onboarding’

Fuente: Elaboración propia, (enero, 2025)

El estado de ‘Churn Comercial’ se clasifica en 0 (No) y 1 (Sí). Como se muestra en la Figura 3-28, solo el 9.38% de los clientes (35 casos) presentan ‘Churn Comercial’, mientras que el resto permanece suscrito por más de 90 días. Esto indica un desbalance en los datos, con un marcado sesgo hacia la categoría de No Churn Comercial. Como se puede observar en el grafico nuestros datos se encuentran desbalanceados teniendo como clase minoritaria a la clase 1: ‘Churn Comercial’.




Figura 3-28 Grafica de barras de 'Churn Comercial'

Fuente: Elaboración propia, (enero, 2025)

3.6.1.3. Análisis Bivariado

Se realizó el cruce de datos entre las variables cuantitativas de las etapas comercial y de experiencia con la variable de interés 'Churn Comercial', identificando diferencias significativas en algunas variables.

En particular, la variable 'Llamadas Efectivas' del embudo comercial (Figura 3-29) muestra una diferencia notable en los rangos intercuartílicos entre los grupos. Además, se observa una diferencia significativa en los promedios, con un valor de 4.30 para el grupo 'No Churn' y 3.49 para el grupo 'Churn Comercial'.




Figura 3-29 Boxplots de 'Llamadas_Efectivas_com' vs 'Churn Comercial'

Fuente: Elaboración propia, (enero, 2025)

Se puede evidenciar una diferencia significativa en los rangos intercuartílicos entre los grupos para la variable 'Total_Actividades_exp' del embudo de experiencia (Figura 3-30), además de una diferencia destacada en los cuartiles Q2 entre los grupos. Asimismo, se observa una diferencia significativa en los promedios, con un valor de 5.55 para el grupo 'No Churn' y 6.29 para el grupo 'Churn Comercial'.




Figura 3-30 Boxplots de 'Total_Actividades_exp' vs 'Churn Comercial'

Fuente: Elaboración propia, (enero, 2025)

Se puede evidenciar una diferencia significativa en los rangos intercuartílicos entre los grupos para la variable 'Llamadas_No_Efectivas_exp' del embudo de experiencia (Figura 3-31), además de una diferencia destacada en los cuartiles Q2 entre los grupos. Asimismo, se observa una diferencia significativa en los promedios, con un valor de 0.78 para el grupo 'No Churn' y 1.91 para el grupo 'Churn Comercial'.




Figura 3-31 Boxplots de 'Llamadas_No_Efectivas_exp' vs 'Churn Comercial'

Fuente: Elaboración propia, (enero, 2025)

Se puede evidenciar una diferencia significativa en los rangos intercuartílicos entre los grupos para las variables 'Capacitaciones_Hechas' y 'Capacitaciones_Canceladas' en el embudo de experiencia ((a) y (b) de la Figura 3-32), además de una diferencia notable en los cuartiles Q2 entre los grupos. Esto sugiere que la cancelación de una capacitación podría aumentar la probabilidad de 'Churn Comercial', mientras que la realización de una capacitación favorecería la retención del cliente.




Figura 3-32 Boxplots de Capacitaciones ‘Hechas’ y ‘Canceladas’ vs ‘Churn Comercial’

Fuente: Elaboración propia, (enero, 2025)

3.6.1.4. Correlación entre variables

El análisis de correlación de Pearson revela una fuerte relación positiva entre las variables de la etapa comercial y aquellas de la etapa de experiencia, como se muestra en la Figura 3-33. Los coeficientes superiores a 0.80 indican una asociación positiva muy fuerte, lo que sugiere una alta correlación lineal y, por ende, una notable redundancia en los datos. Esta correlación podría generar problemas de multicolinealidad en el modelo, dado que las variables derivan de cálculos entre distintos campos.




Figura 3-33 Matriz de correlación de Pearson entre variables numéricas.

Fuente: Elaboración propia, (enero, 2025)

3.6.1.5. Prueba Chi-cuadrado para Variables Cualitativas

Se emplea la prueba de Chi-cuadrado para evaluar la relación entre las variables cualitativas y la variable de interés ‘Churn Comercial’ dentro del conjunto de datos. Esta prueba permite determinar si existe una asociación estadísticamente significativa entre dichas variables, lo que contribuye a identificar factores relevantes en la predicción del churn.

- Hipótesis Nula (H0): No existe asociación entre las dos variables.
- Hipótesis Alternativa (H1): Existe una asociación entre las dos variables.

Variable	Estadístico Chi-Cuadrado	<i>p-value</i>	Grados de Libertad
'Tipo de cliente'	0.0031	0.9985	2
'(C) (EXP) Plazo y Pago'	126.9717	2.6819e-28	2
'Tipo Primer Contacto'	3.9511	0.2668	3
'Rango de Contacto'	0.9011	0.6373	2
'R1yR2'	0.0081	0.0081	1
'Tipo Primera Capacitación'	2.5199	0.1124	1
'Onboarding'	0.4205	0.5167	1
'New Categories'	0.4802	0.4883	1

Tabla 3-8 Prueba Chi-Cuadrado para variables cualitativas

Fuente: Elaboración propia, (enero, 2025)

El análisis de Chi-cuadrado no revela una asociación significativa entre la variable ‘Tipo de cliente’ y la variable de interés ‘Churn Comercial’. Con un estadístico de 0.0031 y un p-valor de 0.9985 para 2 grados de libertad, se concluye que las distribuciones de ‘Tipo de cliente’ son similares entre los grupos, lo que sugiere que esta variable no tiene un impacto relevante en la variable de interés.

El análisis de Chi-cuadrado para la variable ‘Tipo Primer Contacto’ arroja un estadístico de 3.9511 y un p-valor de 0.2668 con 3 grados de libertad, lo que indica que no hay diferencias significativas en las distribuciones entre sus categorías. De manera similar, la prueba para la variable ‘Rango de Contacto’ muestra un estadístico de 0.9011 y un p-valor de 0.6373 con 2 grados de libertad, confirmando la ausencia de una relación significativa con la variable de interés ‘Churn Comercial’.

Por otro lado, las variables ‘R1yR2’ y ‘(C) (EXP) Plazo y Pago’ muestran una asociación significativa con la variable de interés ‘Churn Comercial’. La prueba de Chi-cuadrado para ‘R1yR2’ arroja un estadístico de 0.0081 y un p-valor de 0.0081 con 1 grado de libertad, lo que indica una relación relevante. Asimismo, la variable ‘(C) (EXP) Plazo y Pago’ presenta un estadístico de 126.9717 y un p-valor de 2.6819e-28 con 2 grados de libertad, lo que sugiere una fuerte influencia sobre la variable de interés.

En el caso de la variable ‘Tipo Primera Capacitación’, el análisis arroja un estadístico de 2.5199 con un p-valor de 0.1124 para 1 grado de libertad, lo que indica que no se alcanza significancia estadística. De manera similar, las pruebas realizadas para ‘Onboarding’ y ‘New Categories’ presentan estadísticos de 0.4205 y 0.4802, respectivamente, con p-valores de 0.5167 y 0.4883, lo que sugiere que no existen diferencias significativas en la distribución de estas variables con respecto a la variable de interés ‘Churn Comercial’.

En resumen, con excepción de ‘R1yR2’ y ‘(C) (EXP) Plazo y Pago’, ninguna de las variables categóricas presenta una asociación significativa con la variable de interés ‘Churn Comercial’. Esto sugiere que la mayoría de las variables cualitativas evaluadas no tienen un impacto relevante en la predicción del churn.

3.6.1.6. Prueba ANOVA para variables cuantitativas

La prueba ANOVA se utiliza para determinar si existen diferencias significativas entre las medias de los grupos de la variable de interés ‘Churn Comercial’. Esta técnica estadística permite evaluar si las variaciones observadas en las variables cuantitativas están relacionadas con la presencia o ausencia de churn en los clientes:

- Hipótesis Nula (H0): No existe diferencias significativas entre las medias de los grupos.
- Hipótesis Alternativa (H1): Existe diferencias significativas entre las medias de los grupos.

Variable	Estadístico F	<i>p-value</i>
'Total_Actividades_com'	0.963	0.3255
'Total_Llamadas_com'	0.9741	0.3243
'Llamadas_Efectivas_com'	1.6567	0.1989
'Llamadas_No_Efectivas_com'	0.2014	0.6539
'WA_Seguimiento_com'	1.2422	0.2658
'Reuniones_Hechas'	0.7119	0.3994
'Reuniones_Canceladas'	0.2622	0.6089
'Total_Actividades_exp'	0.8213	0.3654
'Total_Llamadas_exp'	16.9395	4.7585e-05
'Llamadas_Efectivas_exp'	4.8926	0.0276
'Llamadas_No_Efectivas_exp'	19.5968	1.2593e-05
'WA_Seguimiento_exp'	0.1172	0.7323
'Kickoff_Hechas'	2.5044	0.1144

Variable	Estadístico F	<i>p-value</i>
'Kickoff_Canceladas'	0.0036	0.9520
'Capacitaciones_Hechas'	8.5273	0.0037
'Capacitaciones_Canceladas'	3.7444	0.0537

Tabla 3-9 Prueba ANOVA para variables cuantitativas

Fuente: Elaboración propia, (enero, 2025)

El análisis ANOVA revela que las variables:

- 'Total_Actividades_com',
- 'Total_Llamadas_com',
- 'Llamadas_Efectivas_com',
- 'Llamadas_No_Efectivas_com',
- 'WA_Seguimiento_com',
- 'Reuniones_Hechas',
- 'Reuniones_Canceladas'
- 'Total_Actividades_exp'

no presentan diferencias significativas entre las medias de grupos.

Por otro lado:

- 'Total_Llamadas_exp',
- 'Llamadas_Efectivas_exp',
- 'Llamadas_No_Efectivas_exp' y
- 'Capacitaciones_Hechas'

presentan diferencias significativas, sugiriendo una relación con la variable de interés.

Finalmente, 'Capacitaciones_Canceladas' muestra un valor cercano a la significancia, mientras que 'Kickoff_Hechas' y 'Kickoff_Canceladas' no presentan resultados significativos.

En resumen, las variables:

- 'Total_Llamadas_exp',
- 'Llamadas_Efectivas_exp',
- 'Llamadas_No_Efectivas_exp',
- 'Capacitaciones_Hechas'
- 'Capacitaciones_Canceladas' (en menor medida,)

presentan diferencias significativas con la variable de interés. El resto de las variables no muestran una relación significativa.

3.6.2. Preparación de los datos

3.6.2.1. Tratamiento de valores nulos

El conjunto de datos, al estar compuesto principalmente por conteos de ocurrencias de eventos (Actividades), no presenta valores nulos. Esto se debe a que, durante el proceso de extracción y transformación en las etapas y subetapas de la capa intermedia (Silver Layer), los valores reflejan el número de actividades realizadas tanto en la etapa comercial como en la de experiencia, asegurando que no existan registros vacíos en estas variables.

3.6.2.2. Tratamiento de valores atípicos

Para mitigar el impacto de los valores atípicos en los datos, estos fueron reemplazados por valores más cercanos a los percentiles comprendidos entre el 95 y 99. Este ajuste permitió suavizar la influencia de los valores extremos, proporcionando una distribución más equilibrada y estable para los análisis y modelos posteriores. Al ajustar los outliers hacia el rango de las observaciones más frecuentes, se redujo la distorsión en los resultados, lo que mejoró la robustez del análisis y permitió una interpretación más precisa. Además, esta técnica conservó la mayor cantidad de datos posible, optimizando el entrenamiento del modelo y mejorando su capacidad de generalización, lo que favorece decisiones basadas en datos más sólidos.

3.6.2.3. Preparación de variables cualitativas

Las variables cualitativas, con excepción de la variable objetivo, fueron transformadas mediante la técnica de codificación one-hot (one-hot encoding). Esta metodología convierte las categorías de una variable cualitativa en un conjunto de variables binarias (0 o 1), donde cada nueva variable indica la presencia o ausencia de una categoría específica. De esta manera, el conjunto de datos se adapta a un formato más fácilmente interpretable por los modelos de machine learning, permitiendo que las variables cualitativas sean procesadas numéricamente sin perder su información esencial. Esta transformación mejora la eficiencia del análisis y evita posibles sesgos derivados de la asignación de valores numéricos arbitrarios a categorías.

3.6.2.4. Selección preliminar de variables relevantes

La selección preliminar de variables para el entrenamiento del modelo se realizó con base en criterios y análisis estadísticos. Se inició con un análisis de correlación, seguido de pruebas como Chi-Cuadrado para variables cualitativas y ANOVA para variables cuantitativas. Este proceso resulta fundamental en el desarrollo de modelos de Machine Learning, ya que optimiza su rendimiento al mejorar la precisión, reducir el tiempo de entrenamiento y facilitar su interpretación. Al eliminar variables irrelevantes o redundantes, se mitiga el riesgo de sobreajuste, permitiendo que el modelo se enfoque en los factores más relevantes y acelerando su proceso de entrenamiento. Esto contribuye a la generación de modelos más eficientes, comprensibles y robustos.

Además, la selección de variables ayuda a prevenir la multicolinealidad, un problema identificado en el análisis de correlación lineal de Pearson, que puede afectar negativamente a modelos como la regresión

logística o los árboles de decisión. Reducir la multicolinealidad mejora la estabilidad del modelo y evita redundancias en la información, lo que contribuye a la creación de un modelo más robusto y eficiente. Esto, a su vez, maximiza la calidad de las predicciones y facilita la toma de decisiones basadas en datos confiables.

3.7. Entrenamiento de Modelos

Para este propósito, se entrenaron múltiples modelos de clasificación, incluyendo Naive Bayes Logistic Regression, Decision Tree, Random Forest, y XGBoost. Cada modelo fue evaluado en función de métricas clave como la precisión, y el área bajo la curva ROC (AUC-ROC). Esto permitió identificar cuál de ellos ofrecía el mejor equilibrio entre capacidad predictiva y generalización, asegurando un desempeño óptimo en la predicción de ‘Churn Comercial’.

3.7.1. Análisis del problema

Dada la naturaleza del problema de ‘Churn Comercial’ en la startup, se determina que los modelos predictivos de clasificación son ideales para predecir el abandono dentro de los primeros 90 días (métrica de interés). Estos modelos permiten identificar patrones en los datos históricos y predecir cuándo un cliente tiene más probabilidad de abandonar, facilitando la implementación de estrategias personalizadas para mejorar la retención de clientes.

3.7.2. Selección de Algoritmos

Se opta por seleccionar una variedad de algoritmos que incluyen modelos de regresión y modelos de árboles. Entre los elegidos se encuentran Complement Naive Bayes, Decision Tree Classifier, Random Forest Classifier, Binary Logistic Regression y XGBoost Classifier. (Anexo 8).

La selección de los algoritmos se basa en la cantidad de datos disponibles, lo cual es un factor determinante para elegir aquellos que mejor puedan predecir la variable objetivo, considerando las limitaciones de los datos con los que se cuenta.

3.7.3. Etapa Preliminar de Implementación

En esta etapa del proyecto, se presenta la estructura básica utilizada para el análisis de modelos de machine learning del proyecto. La estructura se divide en 7 secciones:

Sección 1: Importación de Bibliotecas

```
import pandas as pd
from sklearn.model_selection
import train_test_split
from sklearn.metrics
from xgboost import XGBClassifier
import accuracy_score, classification_report, confusion_matrix
```

```
import matplotlib.pyplot as plt
import seaborn as sns
```

Se importan las bibliotecas necesarias para el análisis y modelado de datos, incluyendo pandas para la manipulación de datos, Scikit-Learn para la división del conjunto de datos y la evaluación del modelo, XGBoost como algoritmo de clasificación, y las bibliotecas de visualización matplotlib y seaborn.

Sección 2: Carga de Datos

```
df = pd.read_csv(r'..\data\output_silver\contact_metrics_clean.csv')
```

La tabla resultante de la capa plata se importa desde un archivo CSV y se convierte en un DataFrame, un formato optimizado para su manipulación con pandas. Gracias a la estructura Medallion, los datos han sido tratados y depurados, obteniendo una versión limpia y lista para el entrenamiento de modelos de Machine Learning.

Sección 4: Selección de Variables

Se realizó una selección de variables antes del entrenamiento de los modelos, basándose en un análisis estadístico de su importancia.

a) Análisis de Correlación Lineal

Se conservaron las variables con una correlación fuera del rango de -0.05 a 0.05 respecto a la variable de interés (ver Figura 3-34), descartando aquellas con alta correlación entre sí (rango superior a ± 0.8). Las variables seleccionadas en este análisis fueron las siguientes: 'Llamadas_Efectivas_com', 'WA_Seguimiento_com', 'Llamadas_Efectivas_exp', 'Llamadas_No_Efectivas_exp', 'Capacitaciones_Hechas', 'Capacitaciones_Canceladas'.




Figura 3-34 Matriz de correlación de Pearson entre variables numéricas seleccionadas.

Fuente: Elaboración propia, (enero, 2025)

b) Prueba de Chi-Cuadrado

Se realizó la prueba Chi-Cuadrado debido a que se están tratando con datos muestrales. Se mantuvieron las variables cualitativas con significancia estadística en la prueba de chi-cuadrado. Las variables seleccionadas en este análisis fueron las siguientes:

- 'R1yR2'
- '(C) (EXP) Plazo y Pago'

c) Prueba ANOVA

Se conservaron las variables cuantitativas con significancia en la prueba ANOVA. Las variables seleccionadas en este análisis fueron las siguientes:

- 'Total_Llamadas_exp'
- 'Llamadas_Efectivas_exp'
- 'Llamadas_No_Efectivas_exp'
- 'Capacitaciones_Hechas' (significancia moderada)

d) Contexto del Negocio

Se incluyó la variable 'Tipo de cliente', considerada esencial para el análisis en el contexto empresarial. La clasificación de los clientes se basó en un conjunto de características definidas previamente por la empresa a partir de estudios previos.

Sección 4: Preprocesamiento

```
features = [
    '(C) (EXP) Plazo y Pago',
    'Tipo de cliente'
]
dummies = pd.get_dummies(df_subset[features])
df_encoded = pd.concat([df_subset.drop(features, axis=1), dummies], axis=1)
```

Se aplicó One-Hot Encoding a las variables cualitativas antes del entrenamiento del modelo, transformándolas en una representación numérica adecuada. Este proceso es esencial para garantizar que los algoritmos de Machine Learning puedan interpretar correctamente la información categórica.

```
# Separar features y target
X = df_encoded.drop(columns=['Churn Comercial'])
y = df_encoded['Churn Comercial']
```

Los datos se dividen en dos conjuntos: 'x', que contiene todas las columnas excepto 'Churn Comercial' (variable objetivo), y 'y', que almacena 'Churn Comercial'. Esta división es fundamental para el entrenamiento y evaluación de los modelos predictivos de clasificación.

Sección 5: Creación de Conjuntos de Entrenamiento y Prueba

```
# Dividir datos en train y test
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20,
random_state=42, stratify=y)
```

Los datos se dividen en conjuntos de entrenamiento (X_train, y_train) y prueba (X_test, y_test) utilizando la función `train_test_split` de Scikit-Learn. Se asigna el 20% de los datos al conjunto de prueba, asegurando la reproducibilidad mediante una semilla aleatoria. El parámetro `stratify=y` en `train_test_split()` asegura que las clases se distribuyan proporcionalmente en los conjuntos de entrenamiento y prueba, manteniendo la misma proporción de clases en ambos.

Sección 6: Entrenamiento de Modelos

```
# Crear y entrenar el modelo de Regresión Logística
```

```
logistic_regression = LogisticRegression()
```

```
logistic_regression.fit(X_train, y_train)
```

En esta sección se importan los clasificadores de sklearn y el clasificador de XGBoost, se crea un modelo y se entrena con los datos de entrenamiento. Se prueban distintos algoritmos, como Decision Tree, Random Forest, Logistic Regression y Naive Bayes, para comparar su rendimiento y determinar el más adecuado.

Sección 7: Predicción

```
# Realizar predicciones en el conjunto de prueba
```

```
y_pred = logistic_regression.predict(X_test)
```

Se generan las predicciones sobre el conjunto de prueba ('X_test') utilizando el modelo entrenado y se almacenan los resultados en 'y_pred'.

Sección 8: Evaluación

En esta sección se calculan las métricas de evaluación del modelo, como la precisión, el informe de clasificación y la matriz de confusión. Además, se analizan otras métricas de rendimiento, como recall, F1-score, entre otras, para obtener una visión más detallada del desempeño del modelo. A continuación, se presentarán los resultados de estas métricas de evaluación.

3.8. Evaluación y selección del modelo

Se evalúan las métricas obtenidas tras un entrenamiento preliminar de los modelos, lo que permite proceder con ajustes y optimizaciones para mejorar su rendimiento.

3.8.1. Evaluación preliminar de modelos

La sección de Evaluación del código representa la estructura estándar para la evaluación de modelos de aprendizaje automático en este proyecto, y se divide en 4 partes clave.

Sección 1: Cálculo de Exactitud y Precisión global

```
# Calcular la exactitud
accuracy = accuracy_score(y_test, y_pred)
print(f"Exactitud del modelo Naive Bayes: {accuracy:.4f}")
# Calcular la precisión
precision = precision_score(y_test, y_pred, average='macro')
print(f"Precisión del modelo Naive Bayes: {precision:.4f}")
```

La exactitud y la precisión del modelo miden su rendimiento general, representando la proporción de predicciones correctas en relación con el total de predicciones realizadas. Para calcularla, utilizamos la función ‘accuracy_score’ y la función ‘precision_score’ de Python. En este caso por tratarse de clases desbalanceadas optamos por evaluar la precisión ya que el modelo puede simplemente predecir la clase mayoritaria y obtener un alto puntaje.

Sección 2: Informe de Clasificación

```
# Calcular el informe de clasificación
report = classification_report(y_test, y_pred, target_names=target_names)
```

El Informe de Clasificación, producido a través de la función ‘classification_report’ en Python, resume las métricas más importantes, tales como precisión, recall, F1-score y soporte, proporcionando un análisis detallado del desempeño del modelo para cada clase. Esto permite una evaluación más exhaustiva del rendimiento del modelo en distintas categorías.

Sección 3: Matriz de Confusión

```
# Calcular y mostrar la matriz de confusión en texto
confusion_df = pd.DataFrame(confusion_matrix(y_test, y_pred,
labels=logistic_regression.classes_),
                           index=logistic_regression.classes_,
                           columns=logistic_regression.classes_)
```

El código crea una matriz de confusión para evaluar el desempeño del modelo de clasificación, comparando las predicciones realizadas (y_pred) con las etiquetas reales del conjunto de prueba (y_test). La matriz se organiza en un DataFrame, lo que permite interpretar fácilmente el rendimiento del modelo, mostrando las clasificaciones correctas e incorrectas por cada clase.

Sección 4: Área bajo la Curva ROC (AUC-ROC)

```
# Calcular el AUC-ROC para cada clase
auc_roc_scores = {}
for i in range(len(logistic_regression.classes_)):
    auc_roc_scores[logistic_regression.classes_[i]] =
        roc_auc_score(y_test == logistic_regression.classes_[i],
                      y_pred == logistic_regression.classes_[i])
```

El código calcula el Área bajo la Curva ROC (AUC-ROC) para cada clase en un modelo de clasificación, utilizando la función ‘roc_auc_score’ de Scikit-Learn para evaluar la capacidad del modelo para distinguir entre las clases. El resultado es un diccionario llamado ‘auc_roc_scores’, que contiene las puntuaciones AUC-ROC para cada clase. Este análisis ayuda a comprender cómo el modelo equilibra la tasa de verdaderos positivos y falsos positivos en cada clase, ofreciendo información sobre su sensibilidad y especificidad.

3.8.1.1. Ajuste de Modelos

Los procesos de optimización de modelos tienen como objetivo encontrar la configuración más adecuada de los hiperparámetros para maximizar la precisión de los algoritmos de Machine Learning. Antes de este proceso, se llevó a cabo el balanceo de datos mediante el método SMOTE para abordar el problema de clases desbalanceadas. Posteriormente, se emplearon estrategias como Grid Search y Random Search, combinadas con validación cruzada (cross-validation), para evaluar y ajustar continuamente el rendimiento del modelo. Este enfoque busca lograr un equilibrio óptimo entre ajuste y generalización, permitiendo así el desarrollo de modelos más precisos y eficientes.

3.8.1.1.1. Balanceo de modelos con método SMOTE

Como fue mencionado y observado en el Análisis Exploratorio de Datos univariado para la variable de interés ‘Churn Comercial’, el conjunto de datos presenta dos obstáculos relevantes para el desarrollo de este proyecto, por un lado, la cantidad limitada de datos (373 observaciones) y, por otro lado, el desbalance de las clases en la variable de interés (ver Figura 3-27). Ambos factores pueden afectar el rendimiento y la precisión de los modelos predictivos, ya que un conjunto de datos pequeño limita la capacidad de generalización del modelo, mientras que el desbalance puede llevar a que el modelo se sesgue hacia la clase mayoritaria, reduciendo su efectividad para predecir la clase minoritaria.

Para abordar el desbalanceo en los datos, se utilizó la técnica SMOTE (Synthetic Minority Over-sampling Technique) previo al entrenamiento de todos los modelos, que consiste en generar muestras sintéticas de la clase minoritaria para equilibrar la distribución entre las clases. Esta técnica crea nuevas instancias basadas en los puntos cercanos de la clase minoritaria, lo que ayuda a mejorar la capacidad predictiva del modelo, evitando que el algoritmo se sesgue hacia la clase mayoritaria. Al aplicar SMOTE, se optimiza la representación de ambas clases en el conjunto de entrenamiento, lo que mejora la precisión y robustez del modelo, especialmente en escenarios con un desbalance significativo en las clases de salida.

Se llevó a cabo una evaluación del impacto del método SMOTE en cada modelo y se realizó una comparación del desempeño de los modelos antes y después de aplicar el balanceo de clases con dicho método.

```
# Realizar SMOTE para balancear las clases
smote = SMOTE(sampling_strategy='auto', random_state=42)
X_train_bal, y_train_bal = smote.fit_resample(X_train, y_train)
```




Figura 3-35 Comparación de distribución de clases antes y después del balance SMOTE

Fuente: Elaboración propia, (enero, 2025)

Se puede observar en la Figura 3-35 cómo el uso del balance de clases en escenarios con distribución desigual impacta positivamente al equilibrar la cantidad de instancias en cada categoría.

A continuación, se presentan los resultados obtenidos para cada uno de los cinco modelos, tanto antes como después de aplicar SMOTE. Se analizarán las métricas de evaluación, permitiendo evaluar el impacto del balanceo en el desempeño de cada modelo y su capacidad para mejorar la clasificación en presencia de datos desbalanceados.

a) Modelo Complement Naive Bayes

El modelo Complement Naive Bayes presentó mejoras significativas tras la aplicación de SMOTE como se puede evidenciar en los resultados mostrados en la Tabla 3-10. En primer lugar, la exactitud general del modelo aumentó de 0.84 a 0.88, reflejando un mejor desempeño en la clasificación global. Además, la precisión del modelo pasó de 0.3529 a 0.4286, indicando una mejor capacidad para evitar falsas alarmas.

El Recall de la clase minoritaria se mantuvo constante en 0.86, lo que indica que la aplicación de SMOTE no afectó la sensibilidad del modelo en la detección de esta clase. Sin embargo, la precisión y el F1-score aumentaron, lo que sugiere una reducción de falsos positivos y una mejor capacidad del modelo para clasificar correctamente ambas clases.

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
Exactitud (Accuracy)	0.8400	0.8800
Precision Clase 1	0.3529	0.4286
Recall Clase 1	0.8600	0.8600

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
F1-Score Clase 1	0.5000	0.5700
AUC-ROC	0.9265	0.9328

Tabla 3-10 Métricas del modelo Complement Naive Bayes antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

El área bajo la curva ROC (AUC-ROC) también mostró una ligera mejora, aumentando de 0.9265 a 0.9328, lo que indica una mejor capacidad de discriminación entre clases. Finalmente, se observa que el número de falsos negativos en la clase minoritaria se mantuvo, mientras que los falsos positivos en la clase mayoritaria disminuyeron, lo que contribuyó al aumento de la precisión.

Antes de aplicar SMOTE, el modelo presentó 11 falsos negativos y 1 falso positivo, como se puede observar en la comparativa de la Figura 3-36, lo que indica dificultades en la detección de la clase minoritaria. Tras aplicar SMOTE, el número de falsos negativos se mantuvo en 1, mientras que los falsos positivos se redujeron de 11 a 8, mejorando la identificación de la clase minoritaria sin afectar significativamente la clasificación de la clase mayoritaria.




Figura 3-36 Matriz de confusión ComplementNaiveBayes antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

b) Modelo Logistic Regression

El modelo de Regresión Logística experimentó una notable mejora tras la aplicación de SMOTE, como se observa en los resultados de la Tabla 3-11. En primer lugar, la exactitud del modelo aumentó de 0.88 a 0.92, reflejando un mejor desempeño en la clasificación global. Un cambio significativo se evidenció en la precisión, que pasó de 0.00 a 0.5385, indicando una drástica reducción en la cantidad de falsas alarmas y una mayor capacidad del modelo para identificar correctamente la clase minoritaria.

El Recall de la clase minoritaria mostró una mejora importante, incrementándose de 0.00 a 1.00, lo que sugiere que, antes de aplicar SMOTE, el modelo era incapaz de detectar casos positivos, mientras que después pudo identificarlos en su totalidad. En consecuencia, el F1-score de la clase minoritaria aumentó significativamente, reflejando una mejor capacidad del modelo para equilibrar precisión y sensibilidad.

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
Exactitud (Accuracy)	0.8800	0.9200
Precision Clase 1	0.000	0.5385
Recall Clase 1	0.000	1.0000
F1-Score Clase 1	0.000	0.7000
AUC-ROC	0.9454	0.9370

Tabla 3-11 Métricas del modelo Logistic Regression antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

Por otro lado, el AUC-ROC mostró una leve disminución de 0.9454 a 0.9370, lo que indica que, si bien el modelo mejoró su capacidad de detección de la clase minoritaria, su capacidad de discriminación general entre ambas clases se redujo ligeramente.




Figura 3-37 Matriz de confusión LogisticRegression antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

En cuanto a la matriz de confusión, se observa que el número de falsos negativos en la clase minoritaria disminuyó de 7 a 0, lo que indica una mejora en la detección de esta clase, como se puede observar en la comparativa de la Figura 3-37. Sin embargo, el número de falsos positivos en la clase mayoritaria aumentó de 2 a 6, lo que sugiere que el modelo logró capturar más instancias de la clase minoritaria, aunque a costa de una ligera reducción en la especificidad.

c) Modelo Decision Tree Classifier

El modelo de DecisionTreeClassifier presentó mejoras notables tras la aplicación de SMOTE, como se observa en los resultados de la Tabla 3-12. En primer lugar, la exactitud del modelo aumentó de 0.92 a 0.93, lo que indica una ligera mejora en su capacidad de clasificación global. Asimismo, la precisión del modelo mostró un leve incremento de 0.5714 a 0.5833, lo que sugiere una reducción de los falsos positivos y una mayor confianza en las predicciones de la clase minoritaria.

El Recall de la clase minoritaria experimentó una mejora significativa, pasando de 0.57 a 1.00, lo que indica que, tras aplicar SMOTE, el modelo fue capaz de identificar correctamente todos los casos positivos, mientras que antes dejaba de detectar el 43% de ellos. En consecuencia, el F1-score de la clase minoritaria aumentó de 0.57 a 0.74, reflejando un mejor equilibrio entre precisión y sensibilidad.

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
Exactitud (Accuracy)	0.8800	0.9200
Precision Clase 1	0.000	0.5385
Recall Clase 1	0.000	1.0000
F1-Score Clase 1	0.000	0.7000
AUC-ROC	0.9454	0.9370

Tabla 3-12 Métricas del modelo DecisionTreeClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

Por otro lado, el AUC-ROC evidenció una mejora significativa, aumentando de 0.7637 a 0.9706, lo que indica que el modelo mejoró considerablemente su capacidad para diferenciar entre ambas clases. En general, la aplicación de SMOTE permitió un mejor equilibrio en el rendimiento del modelo, logrando una mayor sensibilidad sin afectar drásticamente la precisión general del clasificador.

La matriz de confusión muestra que el número de falsos negativos en la clase minoritaria disminuyó de 3 a 0, lo que indica una mejora en la detección de esta clase, como se puede observar en la comparativa de la Figura 3-38. Sin embargo, el número de falsos positivos en la clase mayoritaria aumentó de 3 a 5, lo que sugiere que el modelo, si bien ahora identifica correctamente todos los casos de la clase minoritaria, lo hace a costa de una leve disminución en la especificidad.




Figura 3-38 Matriz de confusión DecisionTreeClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

d) Random Forest Classifier

El modelo Random Forest mostró cambios en su desempeño tras la aplicación de SMOTE, como se observa en los resultados de la Tabla 3-13. En primer lugar, la exactitud general del modelo presentó una ligera disminución, pasando de 0.92 a 0.91, lo que indica que el balanceo de clases afectó marginalmente la capacidad del modelo para clasificar correctamente todas las observaciones.

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
Exactitud (Accuracy)	0.9200	0.9067
Precision Clase 1	0.6000	0.5000
Recall Clase 1	0.4300	0.7100
F1-Score Clase 1	0.5000	0.5100
AUC-ROC	0.9317	0.9401

Tabla 3-13 Métricas del modelo RandomForestClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

En términos de precisión, se observó una disminución de 0.60 a 0.50, lo que sugiere un aumento en la tasa de falsos positivos. Sin embargo, el recall de la clase minoritaria aumentó de 0.43 a 0.71, lo que indica una mejora en la detección de la clase menos representada. Esto se tradujo en un incremento del F1-score de esta clase, mejorando su equilibrio entre precisión y recall.

El área bajo la curva ROC (AUC-ROC) también reflejó un leve incremento, pasando de 0.9317 a 0.9401, lo que indica una mejora en la capacidad del modelo para distinguir entre las dos clases.




Figura 3-39 Matriz de confusión RandomForestClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

En cuanto a la matriz de confusión, antes de aplicar SMOTE, el modelo presentó 4 falsos negativos y 2 falsos positivos como se puede observar en la Figura 3-39. Tras la aplicación de SMOTE, los falsos negativos se redujeron a 2, aunque los falsos positivos aumentaron a 5, lo que evidencia un mejor desempeño en la identificación de la clase minoritaria, pero con un costo en la precisión de la clase mayoritaria.

e) XGBoost Classifier

El modelo XGBoost presentó mejoras en su rendimiento tras la aplicación de SMOTE, como se observa en los resultados de la Tabla 3-14. Inicialmente, la exactitud general del modelo fue de 0.88, aumentando a 0.91 después de la aplicación de SMOTE, lo que indica un mejor desempeño en la clasificación global. La precisión del modelo también mostró una mejora, pasando de 0.3333 a 0.5000, reflejando una mayor capacidad para reducir los falsos positivos.

Métrica	Sin balance de clases	Con balance de clases (SMOTE)
Exactitud (Accuracy)	0.8800	0.9067
Precision Clase 1	0.3333	0.5000
Recall Clase 1	0.2900	0.7100
F1-Score Clase 1	0.3100	0.5900
AUC-ROC	0.9328	0.9307

Tabla 3-14 Métricas del modelo XGBoostClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

El Recall de la clase minoritaria se incrementó de 0.29 a 0.71, lo que indica que la aplicación de SMOTE ayudó al modelo a detectar mejor esta clase. Además, el F1-score aumentó de 0.31 a 0.59, evidenciando un mejor equilibrio entre precisión y recall en la predicción de la clase minoritaria.

El área bajo la curva ROC (AUC-ROC) se mantuvo estable, con valores de 0.9328 en el modelo preliminar y 0.9307 tras aplicar SMOTE, lo que sugiere que la capacidad de discriminación del modelo entre clases no se vio significativamente afectada.




Figura 3-40 Matriz de confusión XGBoostClassifier antes y después de aplicar SMOTE

Fuente: Elaboración propia, (enero, 2025)

En términos de errores de clasificación, antes de aplicar SMOTE, el modelo presentó 5 falsos negativos y 4 falsos positivos, como se observa en la Figura 3-40. Posteriormente, el número de falsos negativos se redujo a 2, mientras que los falsos positivos aumentaron ligeramente a 5, evidenciando una mejor detección de la clase minoritaria sin una penalización excesiva en la precisión del modelo.

3.8.1.1.2. Ajuste de hiperparámetros

El ajuste de modelos con hiperparámetros es un proceso fundamental en Machine Learning para mejorar el desempeño de los algoritmos y optimizar su capacidad de generalización. Antes de este ajuste, se realizó un preprocesamiento de los datos, incluyendo el balanceo mediante el método SMOTE para corregir el problema de clases desbalanceadas. Posteriormente, se implementaron técnicas de optimización como Grid Search, junto con validación cruzada, para explorar distintas configuraciones de hiperparámetros y seleccionar la combinación que maximiza el rendimiento del modelo. Este enfoque permite afinar los parámetros de los algoritmos y obtener modelos más robustos, precisos y adaptados a los datos disponibles.

a) Modelo Complement Naive Bayes

Los parámetros ajustados para mejorar el modelo Naive Bayes fueron los siguientes

```
# Realizar SMOTE para balancear las clases
smote = SMOTE(sampling_strategy=0.6, random_state=42)
```

Se ajustó el parámetro `sampling_strategy` con el valor de 0.6 lo que indica que la clase minoritaria será aumentada hasta alcanzar el 60% de la cantidad de la clase mayoritaria después de aplicar la técnica de sobremuestreo.

```
# Definir el modelo Complement Naive Bayes
complement_nb = ComplementNB(class_prior=[0.1, 0.9])
```

Se ajustó el parámetro `class_priors`, que establece que la primera clase tiene una probabilidad previa del 10% y la segunda clase tiene una probabilidad previa del 90%.

```
# Definir los hiperparámetros a ajustar
param_grid = {
    'alpha': [0.01, 0.1, 0.5, 1.0, 2.0, 5.0],
    'norm': [True, False]
}
```

Se definen los hiperparámetros, donde:

- **‘alpha’:** Se prueban los distintos valores y se selecciona el mejor.
- **‘norm’:** Se evalúan ambas opciones (True y False) para encontrar la mejor configuración.

```
# Configurar la estrategia de validación cruzada
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Se configura la validación cruzada para optimizar los hiperparámetros del modelo, manteniendo el equilibrio de clases y reduciendo el sesgo mediante el reordenamiento de datos.

```
# Realizar la búsqueda de hiperparámetros con validación cruzada
grid_search = GridSearchCV(complement_nb, param_grid, scoring='precision', cv=cv)
```

Se realiza una búsqueda de hiperparámetros mediante validación cruzada utilizando `GridSearchCV` para optimizar el modelo `ComplementNB`, evaluándolo con la métrica de precisión (`precision`) y dividiendo los datos en `cv` particiones.

b) Modelo Logistic Regression

Los parámetros ajustados para el modelo de regresión logística fueron:

```
# Definir el modelo de Regresión Logística con parámetros ajustados
logistic_regression = LogisticRegression(max_iter=700,
                                         class_weight = {0: 1, 1: 20},
                                         random_state=42)
```

Se ajusta el parámetro `class_weight` para manejar el desbalance de clases, se define `max_iter=700` para establecer un número máximo de iteraciones para la convergencia del modelo, además se establece `random_state` para hacer el modelo reproducible.

```
# Definición de hiperparámetros
param_grid = {
    'C': [0.01, 0.1, 1, 10, 100, 1000, 10000],
    'penalty': ['l1', 'l2'],
}
```

```
'solver': ['liblinear', 'saga']
}
```

Se definen los hiperparámetros, donde:

- **C:** se consideran los valores especificados para buscar la mejor combinación
- **penalty:** define el tipo de regularización L1 o L2 para evitar coeficientes grandes.
- **solver:** se consideran los solvers 'liblinear' y 'saga'

```
# Configurar la estrategia de validación cruzada
```

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Se configura la validación cruzada para optimizar los hiperparámetros del modelo, manteniendo el equilibrio de clases y reduciendo el sesgo mediante el reordenamiento de datos.

```
# Realizar la búsqueda de hiperparámetros con validación cruzada
```

```
grid_search = GridSearchCV(logistic_regression, param_grid, scoring='precision',
cv=cv)
```

Se realiza una búsqueda de hiperparámetros mediante validación cruzada utilizando GridSearchCV para optimizar el modelo LogisticRegression, evaluándolo con la métrica de precisión (precision) y dividiendo los datos en cv particiones.

c) Modelo Decision Tree Classifier

Los parámetros ajustados para el modelo de árbol de decisión fueron los siguientes:

```
# Definir el modelo de DecisionTreeClassifier con parámetros ajustados
```

```
decision_tree = DecisionTreeClassifier(random_state=42)
```

Se define un árbol de decisión sin parámetros previamente ajustados, además de random_state para asegurar la reproducibilidad del proyecto.

```
# Definición de hiperparámetros
```

```
param_grid = {
    'criterion': ['entropy', 'log_loss'],
    'max_depth': list(range(3, 15, 2)),
    'min_samples_split': list(range(5, 20, 5)),
    'min_samples_leaf': list(range(2, 10, 2)),
    'class_weight': [None, 'balanced'],
    'max_features': ['sqrt', 'log2']
}
```

Se definen los hiperparámetros, donde:

- **criterion:** se consideran 'entropy', o 'log_loss' para seleccionar la división de nodos de mejor calidad.
- **max_depth:** se ajusta la profundidad del árbol en un rango de 3 a 13 con un paso de 2.

- **min_samples_split**: se ajusta el número mínimo de muestras necesarias para dividir un nodo será entre 5 y 15, con un paso de 5.
- **min_samples_leaf**: se ajusta el número mínimo de muestras en una hoja será entre 2 y 8, con un paso de 2.
- **min_impurity_decrease**: Disminución mínima de la impureza para hacer una división. Sirve para regularizar el árbol.
- **class_weight**: se ajusta el peso de las clases a None (sin ponderación) o balanced (ajustado para balancear las clases).
- **max_features**: se ajusta el número de características considerado al dividir un nodo, puede ser 'sqrt' o 'log2'

Estos parámetros controlan la complejidad del modelo y cómo se maneja la división de los nodos.

Configurar la estrategia de validación cruzada

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Se configura la validación cruzada para optimizar los hiperparámetros del modelo, manteniendo el equilibrio de clases y reduciendo el sesgo mediante el reordenamiento de datos.

Realizar la búsqueda de hiperparámetros con validación cruzada

```
grid_search = GridSearchCV(decision_tree, param_grid, scoring='precision', cv=cv)
```

Se realiza una búsqueda de hiperparámetros mediante validación cruzada utilizando GridSearchCV para optimizar el modelo DecisionTreeClassifier, evaluándolo con la métrica de precisión (precision) y dividiendo los datos en cv particiones.

d) Random Forest Classifier

Los ajustes realizados al modelo de RandomForest son los siguientes:

Definir el modelo RandomForestClassifier con parámetros ajustados

```
random_forest = RandomForestClassifier(random_state=42, class_weight={0: 1, 1: 20})
```

Se ajustó el parámetro class_weight, asignando un peso mayor a la clase minoritaria, el peso de la clase 0 es 1, y el de la clase 1 es 20, lo que favorece la correcta clasificación de la clase minoritaria. Este ajuste busca reducir el sobreajuste y mejorar el rendimiento del modelo con clases desbalanceadas.

Definición de hiperparámetros

```
param_dist = {
    'n_estimators': [50, 100, 200, 300],
    'max_features': ['sqrt', 'log2', None],
    'bootstrap': [True, False],
    'max_depth': [3, 5],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2]}
```

Se definen los hiperparámetros, donde:

- **n_estimators**: se prueba entre 50, 100, 200 y 300 número de árboles

- **max_features:** se ajusta el número de características considerado al dividir un nodo, puede ser 'sqrt', 'log2' o None
- **bootstrap:** considera si se deben usar muestras con reemplazo (True) o sin reemplazo (False) al construir cada árbol.
- **max_depth:** se prueba la profundidad máxima de cada árbol entre 3 y 5.
- **min_samples_split:** se ajusta el mínimo de muestras necesarias para dividir un nodo será 2 o 5.
- **min_samples_leaf:** se ajusta el número mínimo de muestras en una hoja será entre 1 y 2.

Este conjunto de parámetros controla la complejidad y la capacidad del modelo para ajustarse a los datos, especialmente para problemas con clases desbalanceadas, como en este caso.

```
# Configurar la estrategia de validación cruzada
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Se configura la validación cruzada para optimizar los hiperparámetros del modelo, manteniendo el equilibrio de clases y reduciendo el sesgo mediante el reordenamiento de datos.

```
# Realizar la búsqueda de hiperparámetros con validación cruzada
grid_search = GridSearchCV(random_forest, param_grid, scoring='precision', cv=cv)
```

Se realiza una búsqueda de hiperparámetros mediante validación cruzada utilizando GridSearchCV para optimizar el modelo RandomForestClassifier, evaluándolo con la métrica de precisión (precision) y dividiendo los datos en cv particiones.

e) XGBoost Classifier

Los ajustes realizados al modelo de XGBoost son los siguientes:

```
# Crear el modelo de XGBoost con parámetros ajustados
xgboost_model = XGBClassifier(
    scale_pos_weight=6,
    objective='binary:logistic',
    eval_metric='logloss',
)
```

Los parámetros ajustados para el modelo de XGBoost fueron:

- **scale_pos_weight:** ajusta el peso de la clase positiva a 6 lo que indica que le dará un peso mayor a la clase minoritaria.
- **objective:** se determina que el modelo se utilizará para una tarea de clasificación binaria.
- **eval_metric:** utiliza la pérdida logarítmica como métrica de evaluación.

En conjunto, estos parámetros mejoran la precisión y la capacidad del modelo para generalizar, reduciendo el sobreajuste y manejando clases desbalanceadas.

```
# Definición de hiperparámetros
```

```
param_dist = {
    'learning_rate': [0.01, 0.05, 0.1],
    'n_estimators': [30, 50, 100],
    'max_depth': [4, 5, 6],
    'subsample': [0.7, 0.8, 0.9],
    'colsample_bytree': [0.7, 0.8],
    'gamma': [0, 0.1],
    'reg_alpha': [0, 0.1],
    'reg_lambda': [1, 1.1],
}
```

Se ajusta el espacio de hiperparámetros para incluir opciones para:

- **learning_rate**: se ajusta la tasa de aprendizaje considerando los valores de 0.01, 0.05 y 0.1.
- **n_estimators**: se define el numero de arboles en el modelo, se consideran 30, 50 y 100.
- **max_depth**: se define la profundidad máxima de cada árbol, se consideran 4, 5 y 6.
- **subsample**: se define las proporciones de muestras se consideran los valores 0.7, 0.8 y 0.9.
- **colsample_bytree**: se define las proporciones de características para construir cada árbol, se consideran los valores 0.7 y 0.8
- **gamma**: se define la regularización para la poda de árboles, se consideran los valores 0 y 0.1
- **reg_alpha**: Regula la penalización L1 , se consideran 0 y 0.1
- **reg_lambda**: Regula la penalización L2 se consideran 1 y 1.1

Configurar la estrategia de validación cruzada

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Se configura la validación cruzada para optimizar los hiperparámetros del modelo, manteniendo el equilibrio de clases y reduciendo el sesgo mediante el reordenamiento de datos.

Realizar la búsqueda de hiperparámetros con validación cruzada

```
grid_search = GridSearchCV(xgboost_model, param_grid, scoring='precision', cv=cv)
```

Se realiza una búsqueda de hiperparámetros mediante validación cruzada utilizando GridSearchCV para optimizar el modelo XGBClassifier, evaluándolo con la métrica de precisión (precision) y dividiendo los datos en cv particiones.

3.8.2. Selección del modelo

Se realizó una comparativa exhaustiva de las métricas de evaluación de los modelos predictivos de clasificación, los cuales fueron entrenados, ajustados y optimizados previamente. Este análisis permitió evaluar el rendimiento de cada modelo, teniendo en cuenta métricas como precisión, Recall, F1-Score y AUC-ROC, para seleccionar el más adecuado. La comparación de las métricas permitió identificar el modelo más adecuado para predecir eficientemente el 'Churn Comercial', asegurando la selección del modelo con mejor capacidad de discriminación y ajuste a las características del conjunto de datos. El análisis y evaluación de los resultados se presentarán en la siguiente sección de resultados y discusión.

4. Resultados y Discusión

En esta sección se detalla el análisis del estudio, incluyendo los datos clave y los resultados obtenidos a lo largo de todo el proyecto.

4.1. Entendimiento de las necesidades y objetivos

Con el objetivo de comprender las necesidades del negocio, se generaron visualizaciones que reflejan el comportamiento del ‘churn’ en comparación con el ‘Churn Comercial’ a lo largo del tiempo.

En sus inicios (2019) la startup, registró un alto índice de ‘churn’, con 66 clientes anulando su suscripción, de los cuales el 21.21% (14 leads) correspondieron a ‘churn comercial’ como se puede observar en la Figura 4-1. Sin embargo, desde medio año se observó una disminución significativa. La gestión 2021, la empresa no experimentó ‘Churn Comercial’, manteniendo un promedio de 15 clientes perdidos mensualmente, lo que representó una tasa de abandono relativamente baja.




Figura 4-1 Comportamiento de ‘Churn Comercial’ en comparación a ‘Churn’ a lo largo del tiempo.

Fuente: Elaboración propia, (enero, 2025)

En la gestión 2024, el ‘Churn Comercial’ mostró una tendencia ascendente como se puede observar en la Figura 4-2., con un crecimiento del 20.09% y un promedio mensual de 3.9 clientes perdidos.




Figura 4-2 Comportamiento de ‘Churn Comercial’ en comparación a ‘Churn’ Gestión 2024

Fuente: Elaboración propia, (enero, 2025)

Este incremento es crucial para la startup, ya que un aumento en el ‘churn comercial’ indica problemas en la retención de clientes durante la etapa de onboarding, lo que afecta el crecimiento rápido y escalado

de la empresa. Es vital abordar este desafío identificando a los clientes con mayor riesgo de abandono dentro de los primeros 90 días para optimizar los recursos y reducir el ‘Churn Comercial’




Figura 4-3 Boxplots de total de actividades entre embudos vs Churn Comercial

Fuente: Elaboración propia, (enero, 2025)

Se observa una diferencia significativa en el total de actividades entre los embudos, con una diferencia en las medias de 6 a 10 en el grupo que experimenta ‘Churn Comercial’. Esto podría indicar que se dedica más seguimiento y recursos a la etapa comercial, mientras que la etapa de experiencia no recibe la misma atención en términos de interacción con los clientes.

4.2. Extracción y comprensión de los datos

La extracción y análisis de datos se realizaron en VSCode, utilizando librerías como pandas, requests, numpy y matplotlib para la manipulación, visualización y agrupamiento de la información. Esto permitió la construcción de un DataFrame final, listo para su exploración y posterior uso en el entrenamiento de modelos predictivos de clasificación en Machine Learning (Ver Anexo 9). Sin embargo, uno de los principales desafíos fue la comprensión de la API del CRM Pipedrive, debido a su estructura y documentación, lo que dificultó la integración de los datos en las primeras etapas del proceso. Finalmente en esta etapa se obtuvo información relevante sobre clientes y sus interacciones, permitiendo identificar patrones de contacto asociados a la retención o pérdida de clientes

4.3. Análisis y proceso de datos

Se llevó a cabo un proceso de limpieza y transformación de datos para garantizar su calidad y adecuación al modelado. Esto incluyó el manejo de valores nulos mediante imputación estratégica (percentiles 95 al 99), la estandarización de variables para mejorar la estabilidad de los modelos y la creación de nuevas características relevantes basadas en patrones de interacción de los clientes. Además, se identificó un desbalance significativo en la variable objetivo ‘Churn Comercial’, lo que afectó el rendimiento de los modelos predictivos.

4.4. Entrenamiento de Modelos

En esta fase del proyecto, se completó la preparación de datos y el entrenamiento de modelos para predecir el ‘Churn Comercial’. Los datos fueron limpiados y se seleccionaron variables clave mediante análisis estadísticos, transformándolas con One-Hot Encoding. Posteriormente, los datos fueron divididos en conjuntos de entrenamiento y prueba, aplicando SMOTE para balancear las clases. Se entrenaron modelos como regresión logística, Naive Bayes y árboles de decisión, evaluándolos con métricas como precisión y AUC-ROC. Finalmente, se ajustaron los hiperparámetros con Grid Search, optimizando el rendimiento para seleccionar el mejor modelo predictivo. El análisis y evaluación de los resultados se detallarán en la siguiente sección de resultados y discusión.

El ajuste de hiperparámetros en el entrenamiento de modelos de machine learning juega un papel clave en su rendimiento predictivo. Los modelos optimizados, que han pasado por procesos ajuste de hiperparametros y ajustes por validación cruzada, han mostrado mejoras significativas en comparación con sus versiones preliminares.

Se observa una mejora en la exactitud después del ajuste en los modelos de Logistic Regression (88% a 92%), Decision Tree (92% a 93.33%) y XGBoost (88.00% a 92.00%). Esta mejora sugiere que la elección cuidadosa de los hiperparámetros puede optimizar un modelo de forma efectiva, como en el caso de Logistic Regression, con una mejora del 5.33% en la exactitud. Sin embargo, este efecto no se observó en el modelo de Random Forest, donde la exactitud disminuyó de 92% a 90.67%, lo que indica que el ajuste de hiperparámetros no siempre garantiza una mejora en el rendimiento. Estos resultados destacan la importancia de ajustar los hiperparámetros y optimizar los modelos en la construcción de modelos predictivos para mejorar su rendimiento y confiabilidad. (ver Figura 4-4).




Figura 4-4 Comparación de Exactitud entre modelos antes y después de ajustes

Fuente: Elaboración propia, (enero, 2025)

Se observa una notable mejora en la precisión después del ajuste en los modelos de Naive Bayes (35.29% a 43.75%), Logistic Regression (0.0% a 60.00%), Decision Tree (57.14% a 62.50%) y XGBoost (33.33%

a 53.85%). Esta mejora sugiere que la elección cuidadosa de los hiperparámetros puede optimizar un modelo de forma efectiva, como en el caso de Logistic Regression, con una mejora del 60% en la precisión. Sin embargo, este comportamiento no se observó en el modelo de Random Forest, donde la precisión disminuyó de 60% a 50%, lo que indica que el ajuste de hiperparámetros no siempre garantiza una mejora en el rendimiento. Estos resultados destacan la importancia de ajustar los hiperparámetros y optimizar los modelos en la construcción de modelos predictivos para mejorar su rendimiento y confiabilidad. (ver Figura 4-5).




Figura 4-5 Comparación de Precisión entre modelos antes y después de ajustes

Fuente: Elaboración propia, (enero, 2025)

La precisión alcanzada refleja la capacidad del modelo para identificar correctamente un 'Churn comercial', lo cual es un aspecto fundamental en el contexto empresarial, ya que permite tomar decisiones estratégicas para reducir la pérdida de clientes y mejorar la retención.

4.4.1. Resultados de la Evaluación: Modelo Complement Naive Bayes

Los resultados de la evaluación del modelo Naive Bayes contempla el análisis e interpretación de las siguientes métricas:

Matriz de Confusión

La matriz de confusión del modelo Naive Byes para la clasificación de 'Churn Comercial', presentada en la Figura 4-6, se interpreta de la siguiente manera:

- 59 casos fueron correctamente clasificados como 'No Churn Comercial' (0), clientes que no abandonan y fueron identificados de forma correcta.
- 7 casos fueron correctamente clasificados como 'Churn Comercial' (1), clientes que abandonan y fueron identificados de forma correcta
- 9 casos fueron falsos positivos, el modelo predijo que sería un caso de 'Churn Comercial' pero en realidad los clientes no abandonaron.

- No se obtuvieron falsos negativos.

El modelo tiene un buen desempeño identificando clientes que no abandonan (59 aciertos), pero tiene dificultades al predecir correctamente los clientes que sí abandonan, ya que solo detecta 7 casos de ‘Churn Comercial’, mientras que comete 9 falsos positivos. Esto sugiere que el modelo puede estar sesgado hacia la clase mayoritaria (‘No Churn Comercial’), lo que podría afectar su utilidad para predecir ‘Churn Comercial’ con precisión.




Figura 4-6 Matriz de Confusión Modelo Complement Naive Bayes

Fuente: Elaboración propia, (enero, 2025)

Métricas de Clasificación

Como se puede observar en la Tabla 4-1, el modelo Complement Naive Bayes ajustado alcanza una exactitud global del 88%, pero una precisión de apenas 43.75%, con un buen desempeño en la clase ‘No Churn Comercial’ (0) (100% precisión, 87% Recall, 93% F1-score). Sin embargo, presenta limitaciones en la detección de ‘Churn Comercial’ (1), con una precisión del 44%, un Recall del 100% y F1-Score de 61%, lo que indica dificultades para identificar clientes que abandonan. El AUC-ROC de 0.9328 sugiere que logra diferenciar entre clases efectivamente.

Clase	Precisión	Recall	F1-Score	AUC-ROC
0	1.00	0.87	0.93	0.9328
1	0.44	1.00	0.61	0.9328

Tabla 4-1 Métricas de Evaluación Modelo Naive Bayes

Fuente: Elaboración propia, (enero, 2025)

Curva de Aprendizaje

En la evaluación del modelo preliminar, se observa que la precisión del conjunto de entrenamiento es inicialmente inferior a la del conjunto de prueba, lo que sugiere un posible subajuste en las primeras

etapas del entrenamiento. A medida que el tamaño del conjunto de entrenamiento aumenta, la brecha entre ambas curvas se reduce, y aunque la precisión de prueba se mantiene relativamente estable en torno al 85%-87%, la del entrenamiento varía sin lograr una convergencia clara. Este comportamiento indica que el modelo inicial tiene dificultades para mejorar su capacidad de generalización y puede estar afectado por una falta de complejidad en su configuración.

Después de los ajustes, el modelo muestra un comportamiento más estable y una mejor convergencia entre la precisión de entrenamiento y prueba. Inicialmente, la precisión del conjunto de entrenamiento es muy alta (96.52%) en comparación con la de prueba (90.62%), lo que sugiere un posible sobreajuste en etapas tempranas. Sin embargo, a medida que aumenta el tamaño del conjunto de entrenamiento, la brecha entre ambas curvas se reduce, alcanzando valores más cercanos y estabilizándose en torno a 86.81% en entrenamiento y 86.60% en prueba. Esto indica que el modelo ajustado ha mejorado su capacidad de generalización, reduciendo el sobreajuste presente en las primeras iteraciones y logrando un mejor equilibrio entre aprendizaje y desempeño en datos no vistos. (Ver Figura 4-7).




Figura 4-7 Curvas de aprendizaje Modelo Complement Naive Bayes

Fuente: Elaboración propia, (enero, 2025)

4.4.2. Resultados de Evaluación: Modelo Logistic Regression

La matriz de confusión del modelo Logistic Regression para la clasificación de 'Churn Comercial', presentada en la Figura 4-8, se interpreta de la siguiente manera:

- 66 casos fueron correctamente clasificados como 'No Churn Comercial' (0), clientes que no abandonan y fueron identificados de forma correcta.
- 3 casos fueron correctamente clasificados como 'Churn Comercial' (1), clientes que abandonan y fueron identificados de forma correcta
- 2 casos fueron falsos positivos, el modelo predijo que sería un caso de 'Churn Comercial' pero en realidad los clientes no abandonaron.
- 4 casos fueron falsos negativos, el modelo predijo que no serían un caso de 'Churn comercial' pero en realidad los clientes si abandonaron.

El modelo tiene un buen desempeño identificando clientes que no abandonan (66 aciertos), pero tiene dificultades al predecir correctamente los clientes que sí abandonan, ya que solo detecta 3 casos de ‘Churn Comercial’, mientras que comete apenas 2 falsos positivos pero 4 falsos negativos. Esto sugiere que el modelo puede estar sesgado hacia la clase mayoritaria (‘No Churn Comercial’), sin embargo, logra identificar correctamente una mayor proporción de casos de ‘Churn Comercial’ en comparación con los falsos positivos, lo que indica un buen equilibrio en la clasificación de la clase minoritaria.




Figura 4-8 Matriz de Confusión Modelo Logistic Regression

Fuente: Elaboración propia, (enero, 2025)

Métricas de Clasificación

Como se puede observar en la Tabla 4-2, el modelo Logistic Regression ajustado alcanza una exactitud global del 92%, pero una precisión de apenas 60%, con un buen desempeño en la clase ‘No Churn Comercial’ (0) (94% precisión, 97% Recall, 96% F1-score). Sin embargo, presenta limitaciones en la detección de ‘Churn Comercial’ (1), con una precisión del 60%, un Recall del 43% y F1-Score de 50%, lo que indica dificultades para identificar clientes que abandonan, pero una mejora significativa en el balanceo de clasificación de clases. El AUC-ROC de 93.91% significa que logra apenas diferenciar entre clases. (Ver Tabla 4-2).

Clase	Precisión	Recall	F1-Score	AUC-ROC
0	0.94	0.97	0.96	0.9391
1	0.60	0.43	0.50	0.9391

Tabla 4-2 Métricas de Evaluación Modelo Logistic Regression

Fuente: Elaboración propia, (enero, 2025)

Curva de Aprendizaje

En la evaluación del modelo preliminar, se observa que la precisión del conjunto de entrenamiento se mantiene constantemente alta, con valores superiores al 94%, mientras que la precisión en el conjunto de prueba fluctúa en torno al 91%. La diferencia entre ambas curvas sugiere un posible sobreajuste, ya que el modelo muestra un desempeño significativamente mejor en los datos de entrenamiento que en los datos de prueba. Aunque la precisión de prueba presenta cierta estabilidad, la brecha con la precisión de entrenamiento indica que el modelo podría estar aprendiendo patrones específicos del conjunto de entrenamiento en lugar de generalizar de manera efectiva.

Después de los ajustes, se evidencia una reducción en la brecha entre la precisión de entrenamiento y prueba, reflejando una mejor capacidad de generalización. Inicialmente, el modelo ajustado mantiene una precisión alta en el conjunto de entrenamiento (97.39%), aunque la de prueba es menor (88.94%), lo que aún indica cierto sobreajuste en las primeras etapas. Sin embargo, a medida que aumenta el tamaño del conjunto de entrenamiento, la precisión en prueba mejora progresivamente y se acerca a la de entrenamiento, estabilizándose en torno al 88.24% en entrenamiento y 87.93% en prueba. Este comportamiento sugiere que el modelo ha logrado reducir el sobreajuste y mejorar su capacidad de generalización, alcanzando un mejor equilibrio entre aprendizaje y desempeño en datos no vistos. (Ver Figura 4-9).




Figura 4-9 Curvas de aprendizaje Modelo Logistic Regression

Fuente: Elaboración propia, (enero, 2025)

4.4.3. Resultados de la Evaluación: Modelo Decision Tree Classifier

Los resultados de la evaluación del modelo Decision Tree Classifier contempla el análisis e interpretación de las siguientes métricas:

Matriz de Confusión

La matriz de confusión del modelo Decision Tree Classifier para la clasificación de 'Churn comercial', presentada en la Figura 4-10, se interpreta de la siguiente manera:

- 65 casos fueron correctamente clasificados como ‘No Churn Comercial’ (0), clientes que no abandonan y fueron identificados de forma correcta.
- 5 casos fueron correctamente clasificados como ‘Churn Comercial’ (1), clientes que abandonan y fueron identificados de forma correcta
- 3 casos fueron falsos positivos, el modelo predijo que sería un caso de ‘Churn Comercial’ pero en realidad los clientes no abandonaron.
- 2 casos fueron falsos negativos, el modelo predijo que no sería un caso de ‘Churn Comercial’ pero en realidad los clientes si abandonaron.

El modelo tiene un buen desempeño, similar al de Logistic Regression identificando clientes que no abandonan (65 aciertos), pero tiene dificultades al predecir correctamente los clientes que sí abandonan, ya que solo detecta 5 casos de ‘Churn Comercial’, mientras que comete 3 falsos positivos y 2 falsos negativos. Esto sugiere que el modelo puede estar sesgado hacia la clase mayoritaria (‘No Churn Comercial’), lo que podría afectar su utilidad para predecir ‘Churn Comercial’ con precisión.




Figura 4-10 Matriz de Confusión Modelo Decision Tree Classifier

Fuente: Elaboración propia, (enero, 2025)

Métricas de Clasificación

Como se puede observar en la Tabla 4-3, el modelo Decision Tree Classifier ajustado alcanza una exactitud global del 93.33%, pero una precisión de apenas 62.50%, con un buen desempeño en la clase ‘No Churn Comercial’ (0) (97% precisión, 96% Recall, 96% F1-score). Sin embargo, presenta limitaciones en la detección de ‘Churn Comercial’ (1), con una precisión del 62%, un Recall del 71% y F1-Score de 67%, lo que indica dificultades para identificar clientes que abandonan. El AUC-ROC del 97.06% sugiere que logra diferenciar entre clases efectivamente. En general, el modelo presenta un rendimiento equilibrado en cuanto a las métricas entre las diferentes clases. (Ver Tabla 4-3).

Clase	Precisión	Recall	F1-Score	AUC-ROC
0	0.98	0.94	0.96	0.8992
1	0.60	0.86	0.71	0.8992

Tabla 4-3 Métricas de Evaluación Modelo Decision Tree

Fuente: Elaboración propia, (enero, 2025)

Curva de Aprendizaje

En el modelo preliminar, la precisión en el conjunto de entrenamiento es perfecta (1.0000) en todos los tamaños de conjunto de entrenamiento, lo que sugiere que el modelo ha memorizado los datos. Sin embargo, la precisión en el conjunto de prueba muestra una ligera variabilidad, comenzando en 0.8462 y disminuyendo gradualmente hasta alcanzar 0.8859 a medida que aumenta el tamaño del conjunto de entrenamiento. Estas fluctuaciones indican que el modelo está sufriendo de sobreajuste, ya que su rendimiento en el conjunto de prueba no mejora de manera consistente con el aumento de los datos, lo que implica que no está generalizando de manera efectiva.

Por otro lado, en el modelo ajustado, la precisión en el conjunto de entrenamiento es considerablemente más baja que en el modelo preliminar, comenzando en 0.7230 y manteniéndose por debajo de 1.0 a lo largo de todas las iteraciones. La precisión en el conjunto de prueba también presenta una mejora constante en comparación con el modelo preliminar, comenzando en 0.5874 y aumentando gradualmente hasta estabilizarse cerca de 0.7004 al final. Aunque la precisión en el conjunto de entrenamiento no alcanza los niveles perfectos del modelo preliminar, la mejora en la precisión del conjunto de prueba sugiere que el ajuste ha permitido una mejor generalización del modelo, reduciendo el riesgo de sobreajuste y mejorando su capacidad para desempeñarse de manera más estable en datos no vistos. (Ver Figura 4-11).




Figura 4-11 Curvas de aprendizaje Modelo Decision Tree Classifier

Fuente: Elaboración propia, (enero, 2025)

4.4.4. Resultados de la Evaluación: Modelo Random Forest Classifier

Los resultados de la evaluación del modelo Random Forest Classifier contempla el análisis e interpretación de las siguientes métricas:

Matriz de Confusión

La matriz de confusión del modelo Random Forest para la clasificación de 'Churn Comercial', presentada en la Figura 4-12, se interpreta de la siguiente manera:

- 61 casos fueron correctamente clasificados como 'No Churn Comercial' (0), clientes que no abandonan y fueron identificados de forma correcta.
- 7 casos fueron correctamente clasificados como 'Churn Comercial' (1), clientes que abandonan y fueron identificados de forma correcta
- 7 casos fueron falsos positivos, el modelo predijo que sería un caso de 'Churn Comercial' pero en realidad los clientes no abandonaron.
- No se clasificaron casos de falsos negativos

El modelo tiene un buen desempeño identificando clientes que no abandonan (61 aciertos), pero tiene dificultades al predecir correctamente los clientes que sí abandonan, ya que solo detecta 7 casos de 'Churn Comercial', mientras que comete 7 falsos positivos. Esto sugiere que el modelo puede estar sesgado hacia la clase mayoritaria ('No Churn Comercial'), lo que podría afectar su utilidad para predecir churn con precisión. Esto indica que el modelo podría estar inclinado hacia la clase mayoritaria ('No Churn Comercial'), pero a su vez, es capaz de identificar correctamente una mayor proporción de casos de 'Churn Comercial' en relación con los falsos positivos, lo que refleja un buen equilibrio en la clasificación de la clase minoritaria.




Figura 4-12 Matriz de Confusión Modelo Random Forest

Fuente: Elaboración propia, (enero, 2025)

Métricas de Clasificación

Como se puede observar en la Tabla 4-4, el modelo Random Forest Classifier ajustado alcanza una exactitud global del 90.67%, pero una precisión de apenas 50%, con un buen desempeño en la clase ‘No Churn Comercial’ (0) (100% precisión, 90% Recall, 95% F1-score). Sin embargo, presenta limitaciones en la detección de ‘Churn Comercial’ (1), con una precisión del 50%, un Recall del 100% y F1-Score de 67%, lo que indica dificultades para identificar clientes que abandonan. El AUC-ROC de 93.07% sugiere que logra diferenciar entre clases efectivamente. (Ver Tabla 4-4).

Clase	Precisión	Recall	F1-Score	AUC-ROC
0	1.00	0.90	0.95	0.8918
1	0.50	1.00	0.67	0.8918

Tabla 4-4 Métricas de Evaluación Modelo Random Forest

Fuente: Elaboración propia, (enero, 2025)

Curva de Aprendizaje

En el modelo preliminar, la precisión en el conjunto de entrenamiento es perfecta (1.0000) en todos los tamaños de conjunto de entrenamiento, lo que indica que el modelo ha memorizado los datos, pero la precisión en el conjunto de prueba presenta fluctuaciones a lo largo de los diferentes tamaños de entrenamiento. Comienza en 0.7223 y, aunque muestra una ligera mejora hasta 0.8786 en ciertos puntos, se observa una caída significativa hacia el final, alcanzando solo 0.6135. Estas fluctuaciones sugieren que el modelo sufre de sobreajuste, ya que su rendimiento en el conjunto de prueba no mejora consistentemente con el aumento del tamaño del conjunto de entrenamiento y pierde capacidad de generalización en los últimos tamaños de muestra.

En el modelo ajustado, la precisión en el conjunto de entrenamiento es inicialmente baja, comenzando en valores como nan y luego aumentando progresivamente, con un valor final de 0.8638. La precisión en el conjunto de prueba también mejora gradualmente desde 0.6267 hasta 0.7237, aunque nunca alcanza los niveles ideales de precisión del conjunto de entrenamiento. Sin embargo, a diferencia del modelo preliminar, el modelo ajustado muestra una tendencia de mejora constante en la precisión en el conjunto de prueba, lo que indica que los ajustes realizados han permitido una mejor generalización, aunque aún hay espacio para mejorar en la capacidad del modelo para predecir de manera estable en datos no vistos. Este comportamiento refleja una reducción del sobreajuste, aunque todavía no se ha alcanzado un equilibrio perfecto entre precisión en el entrenamiento y la prueba (Ver Figura 4-14).




Figura 4-13 Curvas de aprendizaje Modelo Random Forest

Fuente: Elaboración propia, (enero, 2025)

4.4.5. Resultados de la Evaluación: Modelo XGBoost

Los resultados de la evaluación del modelo XGBoost contempla el análisis e interpretación de las siguientes métricas:

Matriz de Confusión

La matriz de confusión del modelo XGBoost para la clasificación de 'Churn Comercial', presentada en la Figura 4-15, se interpreta de la siguiente manera:

- 62 casos fueron correctamente clasificados como 'No Churn Comercial' (0), clientes que no abandonan y fueron identificados de forma correcta.
- 7 casos fueron correctamente clasificados como 'Churn Comercial' (1), clientes que abandonan y fueron identificados de forma correcta
- 6 casos fueron falsos positivos, el modelo predijo que sería un caso de 'Churn Comercial' pero en realidad los clientes no abandonaron.
- Ningún caso fue falso negativo.}

El modelo tiene un buen desempeño identificando clientes que no abandonan (62 aciertos), pero tiene dificultades al predecir correctamente los clientes que sí abandonan, ya que solo detecta 7 casos de 'Churn Comercial', mientras que comete 6 falsos positivos. Esto sugiere que el modelo puede estar sesgado hacia la clase mayoritaria ('No Churn Comercial'), lo que podría afectar su utilidad para predecir 'Churn Comercial' con precisión.




Figura 4-14 Matriz de Confusión Modelo XGBoost

Fuente: Elaboración propia, (Enero, 2025)

Métricas de Clasificación

Como se puede observar en la Tabla 4-5, el modelo XGBoost Classifier ajustado alcanza una exactitud global del 92%, pero una precisión de apenas 53.85%, con un buen desempeño en la clase 'No Churn Comercial' (0) (100% precisión, 91% Recall, 95% F1-score). Sin embargo, presenta limitaciones en la detección de 'Churn Comercial' (1), con una precisión del 54%, un Recall del 100% y F1-Score de 70%, lo que indica dificultades para identificar clientes que abandonan. El AUC-ROC de 95.59% sugiere que logra diferenciar entre clases efectivamente. (Ver Tabla 4-5).

Clase	Precisión	Recall	F1-Score	AUC-ROC
0	1.00	0.91	0.95	0.8351
1	0.54	1.00	0.70	0.8351

Tabla 4-5 Métricas de Evaluación Modelo XGBoost

Fuente: Elaboración propia, (enero, 2025)

Curva de Aprendizaje

En el modelo preliminar, la precisión en el conjunto de entrenamiento comienza en valores cercanos a 0.9217 y aumenta progresivamente a medida que crece el tamaño del conjunto de entrenamiento, alcanzando un valor máximo de 1.0000. La precisión en el conjunto de prueba sigue una tendencia similar, comenzando en 0.9028 y mostrando pequeñas fluctuaciones, pero manteniéndose generalmente por encima del 0.90. Estas fluctuaciones indican que, aunque el modelo sigue un comportamiento bastante consistente en términos de rendimiento, la diferencia de precisión entre el entrenamiento y la prueba se mantiene reducida, sugiriendo que el modelo no está sufriendo un sobreajuste significativo.

En el modelo ajustado, la precisión en el conjunto de entrenamiento comienza en valores más bajos (0.9815) y aumenta de manera más estable a medida que crece el conjunto de entrenamiento, alcanzando 0.9846 en el último tamaño de muestra. La precisión en el conjunto de prueba comienza en 0.6074, mostrando una mejora gradual a medida que aumenta el tamaño del conjunto de entrenamiento, alcanzando finalmente 0.9389. Este comportamiento sugiere que los ajustes realizados han mejorado la capacidad de generalización del modelo, ya que la precisión en el conjunto de prueba se estabiliza y mejora de manera constante, logrando un rendimiento mucho más consistente en datos no vistos. Esta mejora en la capacidad de generalización también refleja una reducción en el sobreajuste, lo que implica que el modelo ajustado es más robusto y confiable en la predicción de nuevos datos. (Ver Figura 4-15).




Figura 4-15 Curvas de aprendizaje Modelo XGBoost Classifier

Fuente: Elaboración propia, (enero, 2025)

4.4.6. Resultados globales del entrenamiento

En esta sección se presentan los resultados obtenidos del entrenamiento de los modelos predictivos de clasificación, evaluados según diversas métricas globales de desempeño clave para determinar la capacidad predictiva de cada modelo en la tarea de predicción de ‘Churn Comercial’

4.4.6.1. Exactitud Global de Modelos

Los valores de Accuracy (exactitud global) reflejan la capacidad de cada modelo para clasificar correctamente las muestras en el conjunto de prueba. Los resultados del entrenamiento de los distintos modelos para este proyecto dieron los resultados observados en la Figura 4-16.

- **Decision Tree Classifier:** lidera en el mayor índice de exactitud entre modelos con un 93.33% de precisión. Esto significa que logra clasificar correctamente el 93% de las muestras de manera efectiva.
- **XGBoost Classifier y Logistic Regression::** demuestran una sólida exactitud en la clasificación, alcanzando un 92%. Esto lo convierte en una opción bastante efectiva.
- **Random Forest Classifier:** demuestra una buena exactitud en la clasificación, alcanzando un 90.67%. Esto lo convierte en una buena opción para la clasificación.

- **Complement Naive Bayes:** alcanzando el 88% de exactitud, indica un rendimiento significativamente inferior en comparación al resto, esto significa que el modelo Naive Bayes logra apenas clasificar correctamente el 88% de los casos.




Figura 4-16 Precisión Global entre Modelos

Fuente: Elaboración propia, (enero, 2025)

4.4.6.2. Exactitud Global de Modelos

Los valores de Precisión reflejan la capacidad de cada modelo para clasificar correctamente los casos de 'Churn Comercial'. Los resultados del entrenamiento de los distintos modelos para este proyecto dieron los resultados observados en la Figura 4-17.




Figura 4-17 Precisión Global entre Modelos

Fuente: Elaboración propia, (enero, 2025)

- **Decision Tree Classifier:** lidera en el mayor índice de precisión entre modelos con un 62.50% de precisión. Esto significa que logra identificar correctamente el 62.50% de los casos de 'Churn Comercial'
- **Logistic Regression:** demuestra un buen rendimiento alcanzando una precisión del 60%

- **XGBoost Classifier y Random Forest Classifier:** demuestran una precisión moderada en la clasificación, logrando superar ligeramente el 50%.
- **Complement Naive Bayes:** alcanzando el 43.75% de precisión, indica un rendimiento bastante inferior en comparación al resto, esto significa que el modelo Complement Naive Bayes logra apenas clasificar correctamente el 43.75% de los casos de 'Churn Comercial'.

4.4.6.3. Área bajo la Curva ROC de los modelos (AUC-ROC)

Los valores de AUC-ROC reflejan la capacidad de cada modelo para diferenciar entre las clases positivas y negativas en el conjunto de prueba. La Figura 4-18 muestra los resultados obtenidos tras el entrenamiento y ajuste de los modelos en este proyecto:




Figura 4-18 Comparación de AUC-ROC entre modelos

Fuente: Elaboración propia, (enero, 2025)

- **Decision Tree Classifier:** Este modelo tiene el mayor valor de AUC-ROC, alcanzando un 97.06%. Esto indica una alta capacidad de discriminación entre clases, convirtiéndolo en la opción más robusta.
- **XGBoost Classifier:** Este modelo tiene el segundo valor más alto de AUC-ROC, alcanzando un 95.59%. Esto indica una alta capacidad de discriminación entre clases, convirtiéndolo en una opción eficiente.
- **Logistic Regression y Naive Bayes Classifier y Random Forest Classifier :** Obtienen un AUC-ROC de 93.91%, 93.28% y 93.07%, respectivamente, lo que refleja una precisión comparable a la del XGBoost Classifier, con una leve mejora en términos de estabilidad.

4.4.6.4. Métricas 'macro_avg'

Los resultados generales de las métricas de evaluación, considerando el 'macro avg' de todos los modelos empleados en este proyecto, se resumen en la Tabla 4-6. El 'macro avg' calcula las métricas de manera independiente para cada clase, lo que significa que no se ve influenciado por la distribución de las clases.

Modelo	Precisión	Recall	F1-Score	AUC-ROC
Complement Naive Bayes	0.72	0.93	0.77	0.93
Logistic Regression	0.77	0.70	0.73	0.94
Decision Tree Classifier	0.80	0.84	0.81	0.97
Random Forest Classifier	0.75	0.95	0.81	0.93
XGBoost Classifier	0.77	0.96	0.83	0.95

Tabla 4-6 Métricas de evaluación de todos los modelos ‘macro avg’

Fuente: Elaboración propia, (enero, 2025)

En la evaluación comparativa de los modelos basada en métricas clave ‘macro avg’, el modelo XGBoost se destaca por su alto Recall de 96%, lo que refleja su sobresaliente capacidad para identificar correctamente los casos de la clase minoritaria. Su AUC-ROC de 95% también indica una excelente capacidad de discriminación entre las clases, lo que lo posiciona como un modelo robusto en términos de clasificación. Aunque su precisión (77%) es similar a la de otros modelos como Logistic Regression (77%) y Random Forest (75%), su F1-Score de 83% demuestra un buen equilibrio entre precisión y Recall.

El modelo Decision Tree Classifier, con una precisión de 80%, un Recall de 84% y un F1-Score de 81%, ofrece un rendimiento sólido. A pesar de su buen desempeño, no alcanza el nivel de discriminación y el Recall del modelo XGBoost, aunque su AUC-ROC de 97% lo coloca entre los mejores en cuanto a la capacidad de discriminación.

Por otro lado, el Random Forest Classifier, con una precisión de 75%, un Recall de 95% y un F1-Score de 81%, muestra un excelente desempeño en cuanto a la identificación de la clase minoritaria, pero su AUC-ROC de 93% y su precisión relativamente baja no lo colocan al nivel de XGBoost o Decision Tree.

El Logistic Regression, con una precisión de 77%, un Recall de solo 70%, un F1-Score de 73% y un AUC-ROC de 94%, presenta un rendimiento limitado, especialmente en su capacidad para identificar correctamente la clase minoritaria. A pesar de su AUC-ROC relativamente alto, su bajo Recall limita su efectividad en el manejo de la clase minoritaria.

Finalmente, el Complement Naive Bayes, con una precisión de 72%, un Recall de 93%, un F1-Score de 77% y un AUC-ROC de 93%, presenta un rendimiento relativamente bueno, especialmente en Recall. Sin embargo, su precisión y F1-Score lo sitúan por debajo de los demás modelos en términos de efectividad general.

En conclusión, el modelo XGBoost es el más equilibrado en términos de precisión, Recall y discriminación entre clases, destacándose como la mejor opción cuando se prioriza la identificación de la clase minoritaria y la capacidad general del modelo.

4.4.6.5. Métricas 'weighted_avg'

Los resultados generales de las métricas de evaluación, considerando el 'weighted avg' de todos los modelos empleados en este proyecto, se resumen en la Tabla 4-7. El "weighted avg" tomando en cuenta la distribución de clases en el conjunto de datos, lo que significa que se ve influenciado por la distribución de las clases.

Modelo	Precisión	Recall	F1-Score	AUC-ROC
Complement Naive Bayes	0.95	0.88	0.90	0.93
Logistic Regression	0.91	0.92	0.91	0.94
Decision Tree Classifier	0.94	0.93	0.94	0.97
Random Forest Classifier	0.95	0.91	0.92	0.93
XGBoost Classifier	0.96	0.92	0.93	0.95

Tabla 4-7 Métricas de evaluación de todos los modelos 'weighted_avg'

Fuente: Elaboración propia, (enero, 2025)

En la evaluación comparativa de los modelos basada en las métricas 'weighted avg', el modelo Decision Tree Classifier se destaca con un F1-Score del 94%, lo que refleja un excelente equilibrio entre precisión y Recall, especialmente considerando su capacidad para identificar adecuadamente tanto la clase mayoritaria como la minoritaria. Además, su AUC-ROC de 97% lo posiciona como el modelo con la mejor capacidad discriminatoria, destacándose claramente por encima de otros modelos.

Por otro lado, los modelos XGBoost Classifier y Random Forest Classifier muestran un rendimiento igualmente sólido, con F1-Scores de 93% y 92%, respectivamente. Ambos presentan una alta precisión, con valores de 96% y 95%, pero no alcanzan el nivel de discriminación del Decision Tree Classifier en cuanto al AUC-ROC. El modelo XGBoost, con un AUC-ROC de 95%, sobresale en la capacidad de clasificación, mientras que el Random Forest, con un AUC-ROC de 93%, muestra un rendimiento comparable, aunque ligeramente inferior.

El Complement Naive Bayes, a pesar de obtener una precisión elevada de 95%, muestra un Recall de 88%, lo que indica que es ligeramente menos efectivo para identificar correctamente la clase minoritaria en comparación con los otros modelos. Su F1-Score de 90% y AUC-ROC de 93% reflejan un rendimiento decente, pero en términos de estabilidad y equilibrio general, no supera a los modelos más complejos como el Decision Tree.

Finalmente, Logistic Regression presenta una precisión de 91%, un Recall de 92%, un F1-Score de 91% y un AUC-ROC de 94%. Aunque ofrece buenos resultados en términos de precisión y Recall, su

desempeño global en comparación con los otros modelos, especialmente en cuanto a la capacidad de discriminación (AUC-ROC), es más limitado.

En conclusión, el modelo Decision Tree se destaca como el más equilibrado y el de mejor desempeño general, seguido de cerca por XGBoost y Random Forest, que también ofrecen un rendimiento sólido. Logistic Regression y Complement Naive Bayes muestran un rendimiento más modesto, con ciertas limitaciones en términos de discriminación y capacidad de identificar la clase minoritaria.

4.5. Selección del modelo predictivo

Finalmente, podemos concluir que el modelo más adecuado para las características de los datos en este proyecto es Decision Tree Classifier. Este modelo destaca por su rendimiento equilibrado y robusto, especialmente en escenarios con clases desbalanceadas. En las métricas 'weighted avg', el Decision Tree sobresale con un F1-Score de 94% y un AUC-ROC de 97%, lo que indica una excelente capacidad para identificar tanto la clase mayoritaria como la minoritaria. Aunque en 'macro avg' el XGBoost muestra un rendimiento destacado en términos de Recall y AUC-ROC, el Decision Tree se muestra más equilibrado y eficaz en la discriminación entre clases en este caso. En resumen, el Decision Tree es el modelo más robusto y adecuado para el conjunto de datos utilizado, proporcionando un excelente equilibrio entre precisión, Recall y capacidad discriminatoria.

4.5.1. Importancia de Variables

Según los resultados obtenidos en cuanto a importancia de las variables en el modelo seleccionado Decision Tree Classifier, las variables mas relevantes para el modelo serian:

- **(C) (EXP) Plazo y Pago_Anual (0.520009):** Esta variable tiene la mayor importancia, lo que indica que es crucial para la predicción del modelo, teniendo un gran impacto en el desempeño del modelo.
- **(C) (EXP) Plazo y Pago_Mensual (0.360397):** Aunque su importancia es menor que la del "Plazo y Pago Anual", sigue siendo una de las variables más relevantes, lo que sugiere que también juega un papel importante en las predicciones.
- **Capacitaciones_Hechas (0.033574):** Aunque tiene una importancia mucho menor que las variables anteriores, sigue siendo relevante y aporta valor a las predicciones del modelo.
- **Tipo de cliente_C (0.017034):** Esta variable, correspondiente al tipo de cliente "C", tiene una importancia moderada y afecta algo al modelo, aunque en menor medida que las anteriores.
- **Capacitaciones_Canceladas (0.009915):** Similar a la variable de "Capacitaciones Hechas", tiene una importancia baja, pero aún aporta algo al modelo.
- **Tipo de cliente_A (0.009911):** La categoría "A" del tipo de cliente tiene una relevancia pequeña, indicando que impacta ligeramente el modelo.
- **WA_Seguimiento_com (0.009617):** Aunque con un valor bajo, sigue siendo una variable que tiene algo de impacto en las predicciones.

- **Tipo de cliente_B (0.009525)**: Similar al "Tipo de cliente_A", esta categoría del tipo de cliente tiene una baja relevancia, aunque aún influye en el modelo.
- **Llamadas_Efectivas_exp (0.009000)**: Las llamadas efectivas durante la experiencia tienen una importancia moderada, aunque es algo menor en comparación con las variables anteriores.
- **R1yR2 (0.007400)**: Esta variable tiene una baja importancia, pero aún contribuye al modelo en una pequeña medida.
- **Llamadas_No_Efectivas_exp (0.007060)**: Similar a "Llamadas_Efectivas_exp", las llamadas no efectivas también tienen un impacto pequeño en la predicción.
- **Llamadas_Efectivas_com (0.006557)**: Esta variable tiene una relevancia pequeña, pero sigue siendo considerada en el modelo.
- **(C) (EXP) Plazo y Pago_Otros (0.000000)**: Esta variable no tiene ninguna importancia, lo que significa que no está contribuyendo al modelo y podría ser eliminada en futuras iteraciones del modelo.

En conclusión, las variables relacionadas con el Plazo y Pago (Anual y Mensual) son las que tienen un mayor impacto en las predicciones, mientras que las variables asociadas con el tipo de cliente y las capacitaciones también muestran una relevancia moderada. Las variables de llamadas efectivas y no efectivas, junto con "R1yR2", tienen una menor importancia, pero aún aportan al modelo. Finalmente, la variable Plazo y Pago_Otros no tiene impacto alguno en el modelo y podría eliminarse.

4.6. Discusión de resultados

En estudios previos sobre la aplicación de aprendizaje automático supervisado para la predicción del abandono de clientes, se evidencian los resultados obtenidos por los modelos propuestos por (Urrelo, 2024). En su investigación, se emplearon distintos algoritmos supervisados para la predicción del churn, coincidiendo en su mayoría con los modelos entrenados y evaluados en este proyecto. Podemos observar la comparativa de las métricas de evaluación obtenidas en el estudio de (Urrelo, 2024) y las métricas de evaluación obtenidas en este proyecto en la Tabla 4-8, donde 'A' representa las métricas obtenidas en el presente proyecto y 'B' las métricas obtenidas en el proyecto mencionado.

Modelo	Precisión		Recall		F1-Score		AUC-ROC	
	A	B	A	B	A	B	A	B
Naive Bayes	0.72	0.56	0.93	0.56	0.77	0.56	0.93	0.74
Logistic Regression	0.77	0.42	0.70	0.43	0.73	0.41	0.94	0.62
Decision Tree	0.80	0.90	0.84	0.90	0.81	0.90	0.97	0.91
Random Forest	0.75	0.92	0.95	0.87	0.81	0.90	0.93	0.92

Tabla 4-8 Comparación de métricas de evaluación entre proyectos

Fuente: Elaboración propia, (enero, 2025)

Los resultados obtenidos en el proyecto de (Urrelo, 2024) son bastante similares a los resultados obtenidos en este proyecto, como se pueden ver a continuación en la Figura 4-19.

Se encuentran diferencias notables entre resultados, tanto en la cantidad de datos con los que se trabajaron como en las características de los mismos. Mientras que en el proyecto de (Urrelo, 2024) se trabajó con un total de 1,849 datos, para el presente proyecto se utilizaron 373 datos, reflejando una diferencia bastante considerable en cuanto a cantidad de datos entre proyectos, sin embargo, ambos enfrentaron el desafío de contar con un volumen limitado de datos para el entrenamiento de los modelos.




Figura 4-19 Comparación de métricas de evaluación entre modelos

Fuente: Elaboración propia, (enero, 2025)

Además, puede verse un contraste significativo en la característica de los datos, como se puede evidenciar en la Figura 4-20, mientras que en el proyecto de (Urrelo, 2024) se contó con un porcentaje de datos etiquetados como 'churn' del 43% ('A'), en este proyecto solo el 9.38% ('B') de los datos corresponden al churn.




Figura 4-20 Comparación de porcentaje de churn entre proyectos

Fuente: Elaboración propia, (enero, 2025)

Otro aspecto a considerar al momento de evaluar las diferencias entre los resultados de los proyectos es que, el modelo de Urrelo aplica una clasificación multiclase como se puede ver en la Figura 4-21, para

predecir la tasa de abandono en una empresa de alojamiento web, mientras que el modelo desarrollado en este proyecto se basa en una clasificación binaria de churn comercial (ver Figura 3-28), centrado exclusivamente en el abandono dentro de los primeros 90 días posteriores a la suscripción en una startup. Este modelo utiliza los patrones de contacto como principal criterio de análisis, a diferencia del enfoque de (Urrelo, 2024), que emplea características de los clientes como variables predictoras. Sin embargo, estas características ya están implícitamente consideradas en este proyecto a través de la clasificación del Tipo de Cliente.’

Es importante resaltar otra diferencia significativa al comparar ambos estudios: la composición de los datos utilizados. Mientras que en el proyecto de (Urrelo, 2024) se trabajó con datos balanceados (tomando en cuenta que 3 clases son consideradas como churn: ‘Suspended’, ‘Terminated’ y ‘Cancelled’), en este proyecto se manejaron datos desbalanceados (ver Figura 3-28), siendo el ‘churn’ la clase minoritaria. Esto implica que el procesamiento previo de los datos antes del entrenamiento fue más exhaustivo, con el fin de reducir el impacto del desbalance y evitar que afectara el rendimiento del modelo.




Figura 4-21 Gráfica de barras de estados de cuentas

Fuente: (Urrelo, 2024)

A pesar de que en ambos proyectos se decidieron por modelos diferentes, es relevante destacar las similitudes entre ellos, ya que ambos lograron obtener buenos resultados con el entrenamiento de modelos de Decision Tree. En consecuencia, podemos concluir que los modelos de Decision Tree son bastante efectivos para manejar datos con características comunes en ambos proyectos, como la cantidad limitada de datos, o para tratar con datos con clases desbalanceadas, como los utilizados en este proyecto, demostrando buenos resultados y un rendimiento sólido.

Según los resultados obtenidos en este estudio, se puede concluir que el objetivo planteado para este proyecto se logró de manera exitosa. El modelo de Decision Tree Classifier ha demostrado su efectividad en la predicción del ‘Churn Comercial’ de clientes, alcanzando una exactitud del 93.33% y una precisión de clasificación del 62.5% de la variable objetivo binaria. Además, destacó por su capacidad de ajuste y generalización, incluso considerando la naturaleza de los datos. Su principal fortaleza fue el AUC-ROC, que con un 97% obtuvo el mejor desempeño entre los modelos evaluados, característica relevante por tratarse de una clasificación binaria con clases desbalanceadas.

5. Conclusiones

El análisis de datos y el desarrollo del modelo predictivo identificaron factores clave del ‘Churn Comercial’, permitiendo entender las necesidades y objetivos del negocio. No obstante, en el proceso la centralización de la información se vio dificultada por las diferentes perspectivas de las partes interesadas, lo que complicó la alineación de objetivos y requerimientos. A pesar de estos obstáculos, se logró una comprensión efectiva, lo que permitió que el proyecto se desarrollara de forma exitosa.

La extracción y normalización de datos se realizó de manera exitosa, aunque el proceso presentó varios desafíos, ya que consumir datos desde la API del CRM Pipedrive representó algo nuevo para el equipo. Esta tarea resultó compleja, ya que se tuvo que asegurar que los datos se transformaran correctamente en la capa bronce, convirtiéndolos en un formato más comprensible para su posterior análisis y procesamiento. Para lograrlo, se utilizaron herramientas de programación como Python en la consola de Visual Studio Code, junto con librerías especializadas como Pandas, NumPy y Requests, lo que facilitó la integración eficiente y fluida de los datos desde fuentes externas.

Durante el análisis exploratorio de datos se identificaron hallazgos clave sobre los patrones de contacto de los clientes a lo largo de su ciclo de vida. Estos hallazgos no solo reflejan la situación actual de la empresa, sino que también proporcionan valiosos recursos para optimizar la toma de decisiones y detectar oportunidades de mejora. Se analizaron los patrones de contacto de 373 clientes registrados entre 2021 y 2024, de los cuales 169 realizaron ‘churn’. Sin embargo, solo 35 de ellos correspondieron a ‘Churn Comercial’, es decir, abandonaron dentro de los primeros 90 días posteriores a su suscripción.

Según el análisis de datos, en 2024 se observó un aumento en el ‘Churn Comercial’ de clientes hacia fin de año, posiblemente influenciado por factores internos desconocidos y externos, como la crisis económica del país. Bolivia enfrentó crisis económicas agravadas por el alza del dólar, bloqueos e incendios, causando desabastecimiento, 8.8% de inflación y pérdidas millonarias (Aliaga, 2024).

La FEPC reportó 900 cancelaciones de matrículas comerciales en Cochabamba (FEPC, 2024). En Santa Cruz, la Fedemype registró el cierre de al menos 7,000 unidades productivas (eju, 2025) mientras que en El Alto, la Fermype indicó que el 80% de las pequeñas empresas cerraron en 2024 (Chambi, 2024). Al operar bajo un modelo B2B, su servicio de control de inventarios y facturación depende de la estabilidad de sus clientes, por lo que la reducción en la actividad empresarial impactó directamente en su retención. Esto se reflejó en el aumento del ‘churn’ a lo largo de 2024 y, en consecuencia, en el incremento del ‘Churn Comercial’ en la startup boliviana.

El análisis exploratorio de datos reveló que la mayoría de los clientes ganados son de tipo B (63%) y optan por el plan anual, lo cual podría deberse a la reciente introducción de planes mensuales en los últimos meses del 2024. El primer contacto en la etapa comercial suele ser efectivo, y no es usual que los clientes cancelen reuniones o capacitaciones.

No se observa una gran cantidad de clientes que hayan completado las reuniones R1 y R2 en la etapa comercial, ya que la división de estas reuniones se implementó en abril de 2024. Antes de esa fecha, solo se registraba como 'reunión'. Sin embargo, una proporción significativa de clientes ha cumplido con ambas reuniones, lo que sugiere que el cambio en el flujo de trabajo ha sido exitoso en mejorar la conversión de clientes.

Se observó una diferencia significativa en la cantidad de actividades entre los embudos. La mediana del embudo comercial es de 10 actividades, mientras que la del embudo de experiencia es de 4. Esto sugiere un mayor seguimiento en el área comercial, lo que podría afectar negativamente la retención de clientes a largo plazo. Sin embargo, también podría deberse a que en la etapa de experiencia no se requiere cumplir con tantas actividades a comparación de la etapa comercial. Se vio también que un mayor número de llamadas efectivas en la etapa comercial reduce la probabilidad de 'Churn Comercial'. En contraste, las llamadas no efectivas en la etapa de experiencia incrementan el riesgo de 'Churn Comercial'. Además, la cancelación de reuniones R1 o R2 aumenta significativamente el riesgo, mientras que una capacitación efectiva mejora las probabilidades de retención a largo plazo.

La preparación de datos a lo largo de las capas de la arquitectura Medallion, bajo la cual se trabajó en este proyecto, se logró con éxito utilizando librerías como NumPy y Pandas para la manipulación de datos, y plotly.express, matplotlib.pyplot y seaborn para la visualización y el análisis exploratorio. Sin embargo, se tuvo que prescindir de varias variables potencialmente relevantes para el análisis, como los tiempos entre eventos, debido a la falta de datos, ya que más del 50% de los datos resultaron faltantes tras el cálculo. Esto fue consecuencia de la omisión en el llenado de datos durante los procesos de captura.

Se entrenaron con éxito cinco modelos predictivos clasificatorios, destacándose entre ellos los modelos Decision Tree y XGBoost como los modelos con la mayor exactitud y precisión además del mejor ajuste para la predicción de los datos proporcionados. Durante el proceso, se llevaron a cabo ajustes y optimizaciones, utilizando herramientas validación cruzada y búsqueda de la mejor rejilla con el objetivo de mejorar los resultados debido a la naturaleza binaria y desbalanceada de los datos, así como para lograr una mayor capacidad de generalización en el entrenamiento de los modelos.

Modelo	Precisión		Recall		F1-Score		AUC-ROC	
	A	B	A	B	A	B	A	B
Naive Bayes	0.72	0.56	0.93	0.56	0.77	0.56	0.93	0.74
Logistic Regression	0.77	0.42	0.70	0.43	0.73	0.41	0.94	0.62
Decision Tree	0.80	0.90	0.84	0.90	0.81	0.90	0.97	0.91
Random Forest	0.75	0.92	0.95	0.87	0.81	0.90	0.93	0.92

Se evaluaron los modelos entrenados presentaron buenos resultados en métricas globales. Decision Tree Classifier destacó como el más efectivo, con un AUC-ROC de 97% y Recall de 84%, lo que garantiza una alta capacidad de discriminación y detección de la clase minoritaria. XGBoost Classifier también mostró buen rendimiento (AUC-ROC de 95.59%), pero con menor Recall. En contraste, Logistic

Regression tuvo un AUC-ROC de 93% y bajo Recall, limitando su capacidad predictiva. Naive Bayes, aunque competitivo en Recall (87%), obtuvo un menor F1-Score (77%).

Se seleccionó el modelo predictivo de clasificación Decision Tree Classifier debido a sus excelentes métricas de evaluación. Aunque su precisión global fue del 80%, su AUC-ROC, alcanzó un destacado 97%. Esta métrica fue clave debido a la naturaleza desbalanceada de los datos, el modelo mostró una mejor capacidad para distinguir entre clases, manteniendo un buen equilibrio entre precisión, F1-Score y Recall, evitando el overfitting, y generalizando mejor a medida que aumenta la cantidad de datos.

6. Recomendaciones

A partir de los hallazgos obtenidos en el desarrollo de este proyecto, se han generado un conjunto de sugerencias y recomendaciones fundamentadas en datos, con el objetivo de mejorar la situación actual de la empresa y proponer la implementación y mejorar la efectividad de los modelos de aprendizaje automático en la predicción del ‘Churn Comercial’.

Para el desarrollo de este proyecto, fue necesario extraer los datos directamente del CRM de la empresa. Sin embargo, durante la exploración y análisis, se identificaron deficiencias en la introducción de datos que afectan la calidad y precisión de los modelos predictivos. Por ello, se recomienda la implementación de formatos estandarizados para el llenado de campos en el CRM. Asimismo, se detectaron actividades con significados ambiguos, lo que complica el entendimiento de los procesos y los datos. También se identificó la presencia de actividades obsoletas en el CRM que, aunque ya no se utilizan, continúan apareciendo en los registros, afectando la calidad de la información disponible. Otro hallazgo crítico fue la omisión recurrente en la introducción de datos en ambos embudos, tanto comercial como de experiencia, lo que limita la precisión de los análisis y modelos predictivos.

Dado que la calidad de los datos influye directamente en el desempeño del modelo, esta observación es de carácter prioritario. Para abordar estas deficiencias, se recomienda la capacitación del personal en el uso adecuado del CRM, garantizando un registro más preciso y así datos más confiables. Esto permitirá evitar procesos retrospectivos de limpieza manual de datos ahorrando tiempo y optimizará la eficiencia de su análisis. Una vez optimizado el llenado de datos, se recomienda incluir más variables en la predicción de ‘Churn Comercial’. La baja calidad de los datos obligó a omitir factores clave, como el tiempo entre eventos, limitando la precisión del modelo. Incorporar estas variables no solo mejoraría la predicción, sino que también aportaría insights valiosos para decisiones estratégicas.

En cuanto a los resultados del análisis, se recomienda a la empresa priorizar la obtención de llamadas efectivas en la etapa comercial, ya que se ha observado que pueden reducir las probabilidades de ‘Churn.Comercial’. En la etapa de experiencia, también es clave garantizar interacciones eficaces, pues las llamadas inefectivas aumentan el riesgo de abandono. Se recomienda revisar el análisis del tiempo mínimo de primer contacto, ya que no se ha encontrado relevancia en su relación con el ‘Churn Comercial’. Además, el porcentaje de clientes contactados en ese tiempo es bajo, lo que sugiere que la estrategia debe ser ajustada.

También se recomienda un seguimiento constante a los clientes en las etapas comercial y de experiencia. Actualmente, el embudo comercial realiza más seguimientos que el embudo de experiencia, lo que podría afectar la retención. Esto es fundamental, ya que se ha identificado una correlación significativa entre los patrones de contacto en la etapa de experiencia y el ‘Churn Comercial’. Por lo tanto, es clave reforzar las el seguimiento constante en esta etapa, especialmente para evitar la cancelación de reuniones, ya que esto incrementa considerablemente las probabilidades de ‘Churn Comercial’. Esto podría lograrse implementando procedimientos estrictos para el cumplimiento de capacitaciones, en los que se gestione

de manera efectiva la cancelación o postergación de reuniones, exigiendo un mayor compromiso por parte de los clientes.

Los resultados de este proyecto han demostrado que los modelos predictivos de árboles de decisión, son herramientas clave y efectivas para identificar a los clientes en riesgo de ‘Churn Comercial’. La startup boliviana podría aprovechar estos modelos para priorizar a los clientes que muestren señales tempranas de abandono, ofreciéndoles un trato preferencial para reducir el riesgo de ‘Churn Comercial’. Además, es fundamental monitorear continuamente el desempeño de estos modelos y ajustarlos a medida que se recopilan más datos, asegurando su efectividad y mejores resultados a largo plazo. Se ha observado que el desempeño de los modelos mejora al ajustar parámetros y aplicar técnicas de optimización. Por lo tanto, se recomienda monitorear constantemente el rendimiento del modelo al implementarlo, especialmente al aumentar la cantidad de datos y variables. Aunque los resultados actuales muestran un modelo robusto y eficiente con los datos limitados, es crucial seguir evaluando su efectividad a medida que se amplía la información.

Dado que la mayoría de los clientes adquiridos son del tipo ‘B’ y se ve una preferencia por los planes anuales, se recomienda realizar un análisis más detallado de la segmentación de clientes. Esto permitirá adaptar los planes y servicios de forma personalizada, lo que incrementará la satisfacción y reducirá las probabilidades de ‘Churn Comercial’. A medida que se recopilen más datos, se podrán ajustar los planes de suscripción para satisfacer mejor las necesidades de cada segmento.

Finalmente, en cuanto al contexto social y económico del país, se recomienda prestar especial atención a factores que puedan influir en los clientes, como las crisis económicas, que han afectado negativamente a varios sectores, especialmente al sector empresarial, que constituye una parte clave de los clientes de la startup. Es crucial considerar estos factores para anticipar posibles cambios en el comportamiento de los clientes y ajustar las estrategias de retención de forma proactiva. La empresa debe desarrollar estrategias resilientes que le permitan adaptarse rápidamente a los cambios del entorno, asegurando la satisfacción de sus clientes durante períodos difíciles y fortaleciendo así la lealtad a largo plazo.

Se espera que estas recomendaciones permitan a la empresa optimizar las interacciones con los clientes, mejorar la calidad del servicio y tomar decisiones basadas en datos. Esto contribuirá a reducir el ‘Churn Comercial’, mejorar la retención de clientes y asegurar un crecimiento sostenible a largo plazo para la startup.

Referencias bibliográficas

- A. K. Mishra, S. K. (2017). Customer churn analysis for a software-as-a-service company. *2017 Systems and Information Engineering Design Symposium (SIEDS)*. Charlottesville, VA. doi:10.1109/SIEDS.2017.7937698
- Aliaga, J. (2024, 12 18). *France 24*. Retrieved from Bolivia despide un 2024 con una crisis múltiple y avizora un 2025 de alta tensión: <https://www.france24.com/es/am%C3%A9rica-latina/20241218-bolivia-despide-un-2024-con-una-crisis-m%C3%BAltiple-y-avizora-un-2025-de-alta-tensi%C3%B3n>
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Berkeley: Springer.
- Bismart. (2025, enero). *Técnicas y tipos de análisis predictivo: clasificación vs. regresión*. Retrieved 01 22, 2025, from <https://blog.bismart.com/tipos-analisis-predictivo-clasificacion-regresion#:~:text=Podemos%20diferenciar%20entre%20dos%20tipos,de%20regresi%C3%B3n%20modelan%20variables%20continuas>
- Breiman, L. (2001). Random forests. . *Machine Learning Journal*.
- Chambi, P. P. (2024, 11 25). *El Alto*. Retrieved from En El Alto 80% de pequeñas empresas cerraron y los que quedan no podrán pagar el aguinaldo 2024: <https://www.elalto.com.bo/ciudad/20241125/en-el-alto-80-de-pequenas-empresas-cerraron-y-los-que-quedan-no-podran-pagar-el#:~:text=Sobrescribir%20enlaces%20de%20ayuda%20a%20la%20navegaci%C3%B3n,quedan%20no%20podr%C3%A1n%20pagar%20el%20aguinaldo%202024>
- Chawla, N. V. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *AI Access Foundation and Morgan Kaufmann Publishers*.
- Chen, T. &. (2016). XGBoost: A scalable tree boosting system. . *KDD Conference on Knowledge Discovery and Data Mining*.
- Cox, D. R. (1958). The regression analysis of binary sequences. . *Journal of the Royal Statistical Society: Series B*.
- Cristianini, N. &.-T. (2000). *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge University Press. doi:<https://doi.org/10.1017/CBO9780511801389>
- Databricks. (2024). *Medallion Architecture*. Retrieved from <https://www.databricks.com/glossary/medallionarchitecture>
- eju. (2025, 01 11). *Fedemype Santa Cruz reporta el cierre de al menos 7 mil unidades productivas en 2024 por la crisis económica*. Retrieved from <https://eju.tv/2025/01/fedemype-santa-cruz-reporta-el-cierre-de-al-menos-7-mil-unidades-productivas-en-2024-por-la-crisis-economica/#:~:text=econ%C3%B3mica%20%E2%80%93%20eju.tv->

,Fedemype%20Santa%20Cruz%20reporta%20el%20cierre%20de%20al%20menos%207,2024%20

El Naqa, I. &. (2015). *Machine Learning in Radiation Oncology: Theory and Applications*. (R. L. I. El Naqa, Ed.) Springer International Publishing. doi:https://doi.org/10.1007/978-3-319-18305-3_1

Espinosa-Zúñiga, J. J. (2020). Aplicación de metodología CRISP-DM para segmentación geográfica de una base de datos pública. *Ingeniería, investigación y tecnología*, 21(1).

FEPC. (2024, 12). *Reporte Empresarial*. Retrieved from chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/[https://fepc.bo/archivos/DIRCOM/Gestio n%202024/Reporte%20Empresarial/2024/Diciembre%202024/REPORTE%20EMPRESARIAL%202024%20.pdf](https://fepc.bo/archivos/DIRCOM/Gestio%20n%202024/Reporte%20Empresarial/2024/Diciembre%202024/REPORTE%20EMPRESARIAL%202024%20.pdf)

García-Herrero, J. B. (2018). *Ciencia de datos: Técnicas analíticas y aprendizaje estadístico. Un enfoque práctico*. Altaria Publicaciones Alfaomega.

geekforgeeks. (2025, enero). *One Hot Encoding in Machine Learning*. Retrieved from GeeksforGeeks: <https://www.geeksforgeeks.org/ml-one-hot-encoding/>

González Duque, R. (2011). *Python para todos*. Retrieved from <http://mundogeek.net/tutorial-python/>

Gupta, M., Gupta, D., & Rai, P. (2024). Exploring the Impact of Software as a Service (SaaS) on Human Life. *EAI Endorsed Transactions on Internet of Things*, 10.

Hastie, T. T. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.

HLEG, A. (2019). High-level expert group on artificial intelligence. Ethics guidelines for trustworthy AI. 6.

IBM. (2024, 05 14). *Análisis predictivos*. Retrieved from https://www.ibm.com/es-es/topics/predictive-analytics?utm_source=chatgpt.com

INE. (2020). *ASPECTOS GEOGRAFICOS*. Retrieved from <https://www.ine.gob.bo/index.php/bolivia/aspectos-geograficos/#:~:text=Limita%20al%20norte%20y%20este,y%20al%20sudoeste%20con%20Chile.&text=El%20sistema%20nacional%20de%20carreteras,integran%20a%20todos%20los%20departamentos>.

Keyrus. (2025, enero). *Las 11 técnicas más utilizadas en el modelado de análisis predictivo*. Retrieved 01 22, 2025, from <https://keyrus.com/sp/es/insights/las-11-tecnicas-mas-utilizadas-en-el-modelado-de-analisis-predictivos/>

Lacasa, A. (2024, septiembre). *TodoStartups*. Retrieved from ¿Qué es el churn rate y cómo reducirlo en una startup?: <https://www.todostartups.com/3/186305/churn-rate-como-reducirlo-startup>

Laplante, P. A., Zhang, J., & Voas, J. (2008). What's in a Name? Distinguishing between SaaS and SOA. *IT Professional*, 10(3), 50.

- Larson, M. G. (2008). Analysis of variance. *Circulation*, 117(1), 115-121.
- Lazarov, V. &. (2007). *Churn prediction and retention strategies*. Technical University of Munich, Alemania. Retrieved from chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=dbf15b7c5f766ef9f84ba83127c626d79b2087b2
- León del Apio, J. (2017). *Online Marketing Analytics: Entender a nuestros clientes analizando su ciclo de vida*. Retrieved from Analítica Web: <https://www.analiticaweb.es/entender-clientesanalizando-ciclo-vida/>
- Mahesh, B. (2020). Machine learning algorithms - a review. *International Journal of Science and Research (IJSR)*, 9(1), 381-386.
- McKinney, W. (2022). *Python for Data Analysis*. O'Reilly Media, Inc.
- Milo, T. &. (2020). *Automating exploratory data analysis via machine learning: An overview*, *Proceedings of the 2020 ACM SIGMOD international conference on management of data*.
- Mukhiya, S. K. (2020). *Hands-On Exploratory Data Analysis with Python: Perform EDA techniques to understand, summarize, and investigate your data*. Packt Publishing Ltd.
- Negnevitsky, M. (2005). Artificial Intelligence: A Guide to Intelligent Systems. In M. Negnevitsky, *Artificial Intelligence: A Guide to Intelligent Systems* (p. 415). England: PearsonEducationLimited.
- Pineda Pertuz, C. M. (2022). *Aprendizaje automático y profundo en Python*. Ra-Ma S.A. Editorial y Publicaciones.
- Posada Hernández, G. J. (2016). *Elementos básicos de estadística descriptiva para el análisis de datos*. Fondo Editorial Luis Amigó.
- Pramoditha, R. (2021, 12 16). *Medium*. Retrieved from Encoding Categorical Variables: One-hot vs Dummy Encoding: <https://medium.com/towards-data-science/encoding-categorical-variables-one-hot-vs-dummy-encoding-6d5b9c46e2db>
- PredikData. (2025, enero). *¿Qué son y para qué se usan los modelos predictivos?* Retrieved 01 22, 2025, from <https://predikdata.com/es/que-son-y-para-que-se-usan-los-modelos-predictivos/>
- Quinlan, J. R. (1986). Induction of decision trees. . *Machine Learning*.
- Rababah, K. M. (2011). Customer relationship management (CRM) processes from theory to practice: The pre-implementation plan of CRM system. *International Journal of e-Education, e-Business, e-Management and e-Learning*, 1(1), 22-27.
- Redondo, M. (2025). *mamel*. Retrieved from Modelos Predictivos y la Curva ROC: <https://mamel.es/modelos-predictivos-y-la-curva-roc/>
- REPSOL. (2023, Septiembre 11). *Innovacion, tecnologia y talento*. Retrieved from ¿Que es una startup?: <https://www.repsol.com/es/energia-futuro/personas/que-es-una->

startup/index.cshhtml#:~:text=%C2%BFQu%C3%A9%20son%20las%20startup%3F,de%20manera%20%C3%A1gil%20y%20r%C3%A1pida.

Rigatti, S. J. (2017). Random forest. *Journal of Insurance Medicine*, 47(1), 31-39.

Rojas, Y. L. (2019). *STARTUP Y SUS METODOLOGÍAS PARA NO FRACASAR*. Bogotá, Colombia.

Sawyer, S. F. (2009). Analysis of variance: The fundamental concepts. *Journal of Manual & Manipulative Therapy*, 17(2), 27E-38E.

Schröer, C. K. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science*, 526-534.

scikit-learn. (2025, febrero). *BernoulliNB*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.BernoulliNB.html#sklearn.naive_bayes.BernoulliNB

scikit-learn. (2025, febrero). *CategoricalNB*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.CategoricalNB.html#sklearn.naive_bayes.CategoricalNB

scikit-learn. (2025, febrero). *ComplementNB*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.ComplementNB.html#sklearn.naive_bayes.ComplementNB

scikit-learn. (2025, febrero). *DecisionTreeClassifier*. Retrieved from <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html#sklearn.tree.DecisionTreeClassifier>

scikit-learn. (2025, febrero). *GaussianNB*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

scikit-learn. (2025, febrero). *LogisticRegression*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html#sklearn.linear_model.LogisticRegression

scikit-learn. (2025, febrero). *MultinomialNB*. Retrieved from https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.MultinomialNB.html?utm_source=chatgpt.com


scikit-learn. (2025, febrero). *Naive Bayes*. Retrieved from https://scikit-learn.org/stable/modules/naive_bayes.html

scikit-learn. (2025, febrero). *RandomForestClassifier*. Retrieved from <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html#sklearn.ensemble.RandomForestClassifier>

- scikit-learn. (2025, febrero). *Supervised learning*. Retrieved from https://scikit-learn.org/stable/supervised_learning.html
- Shinde, P. P. (2018). *A review of machine learning and deep learning applications, 2018 Fourth international conference on computing communication control and automation (ICCUBEA)*. IEEE.
- Torres, J. S. (2018). Del ciclo de vida del producto al ciclo de vida del cliente. Una aproximación hacia una construcción teórica del ciclo de vida del cliente. *Investigación & Negocios*, 11(18), 110.
- Urrelo, J. O. (2024). *MODELO DE ANÁLISIS PREDICTIVO PARA EL ABANDONO DE CLIENTES EN UNA EMPRESA DE ALOJAMIENTO WEB CON HERRAMIENTAS DE MACHINE LEARNING*. Cochabamba: Dirección de Posgrado de la Facultad de Ciencias y Tecnología.
- VanderPlas, J. (2017). Python Data Science Handbook. In J. VanderPlas, *Python Data Science Handbook* (p. 517). United States of America: Kristen Brown.
- Wiselka, M. (2024). *Development of Modern Data Platform using Medallion Architecture*. Retrieved from <https://urn.fi/URN:NBN:fi:amk-2024111828633>
- xgboost. (2022). *DMLC XGBoost*. Retrieved from XGBoost Documentation: <https://xgboost.readthedocs.io/en/stable/>
- XGBoost. (2025, febrero). *XGBoost Parameters*. Retrieved from https://xgboost.readthedocs.io/en/stable/parameter.html?utm_source=chatgpt.com
- Yu, C. H. (2010). Exploratory data analysis in the context of data mining and resampling. *International Journal of Psychological Research*, 3(1), 9-22.

Anexos

Anexo 1. Estructura de trabajo: Arquitectura MEDALLION



https://github.com/datafla/Modelo-Predictivo_Churn-Comercial

Anexo 2. Procesamiento de datos capa Bronce

The screenshot shows a Jupyter Notebook interface with the following structure:

- EXPLORER:**
 - OPEN EDITORS: 01_bronze_data.ipynb no...
 - EXPERIENCIA:
 - .pycache
 - .Rproj.user
 - data:
 - output_bronze:
 - act.col.json
 - activities.com.csv
 - activities.exp.csv
 - deals.col.json
 - deals.com.csv
 - deals.exp.csv
 - json.activities.json
 - json.deals.json
 - output_gold:
 - contact_metrics_clean.csv
 - output_silver:
 - 01_silver_standardized:
 - activities.com.csv
 - activities.exp.csv
 - deals.com.csv
 - deals.exp.csv
 - 02_silver_filtered:
 - activities.com.csv
 - activities.exp.csv
 - deals.com.csv
 - deals.exp.csv
 - 03_silver_enriched:
 - contact_metrics.com.csv
 - contact_metrics.exp.csv
 - contact_metrics.csv
 - notebooks:
 - quarto:
 - freeze
 - idx
 - xref
 - 01_bronze_data.ipynb
 - 02_1_silver_standardized.ip...
 - 02_2_silver_filtered.ipynb
 - 02_3_silver_enriched.ipynb
 - 03_gold_data.ipynb
 - EDA_contactabilidad.quar...
 - EDA_churn.ipynb
 - EntendimientoNegocio.p...
 - Graficas.ipynb
 - stages.dict.json
 - Training ML Churn Comer...
 - scripts:
 - .env
 - service_account.json

01_bronze_data.ipynb

notebooks > 01_bronze_data.ipynb > ...

+ Code + Markdown | Run All | Clear All Outputs | Outline ...

Credentials

```
[3] load_dotenv()

# credentials
api_token_exp = os.getenv("api_token_exp")
api_token_com = os.getenv("api_token_com")
company_domain = os.getenv("company_domain")
```

GET DATA

GET Metadata

```
[4] # getting metadata - Deals
json_deals_metadata = deals_metadata(
    api_token_exp,
    company_domain
)
df_deals_metadata = pd.json_normalize(json_deals_metadata)
```

```
[5] # getting metadata - Activities
json_act_metadata = activities_metadata(
    api_token_exp,
    company_domain
)
df_act_metadata = pd.json_normalize(json_act_metadata)
```

GET Data from Filters

Activities

```
[6] # getting activities from filter 13666
json_activities_com = get_activities(
    user_id = 0,
    filter_id=13666,
    done=True,
    api_token=api_token_com,
    company_domain= company_domain
)
```

```
[7] # getting activities from filter
json_activities_exp = get_activities(
    user_id = 0,
    filter_id=13671,
    done=True,
    api_token=api_token_exp,
    company_domain= company_domain
)
```

Deals

```
[8] # getting deals from filter All 'Mensual' Deals without
json_deals_com = get_deals(
    filter_id=14375,
    api_token=api_token_com,
    company_domain= company_domain
)
```

https://github.com/datafla/Modelo-Predictivo_Churn-Comercial/blob/main/notebooks/01_bronze_data.ipynb

Anexo 3. Procesamiento de datos capa Plata (subcapa de estandarización)

The screenshot shows a Jupyter Notebook titled '02_1_silver_standardized.ipynb'. The left sidebar displays a file explorer with the following structure:

- EXPERIENCIA
 - pycache
 - .Rproj.user
 - data
 - output_bronze
 - act_col.json
 - activities_com.csv
 - activities_exp.csv
 - deals_col.json
 - deals_com.csv
 - deals_exp.csv
 - json_activities.json
 - json_deals.json
 - output_gold
 - contact_metrics_clean.csv
 - output_silver
 - 01_silver_standardized
 - activities_com.csv
 - activities_exp.csv
 - deals_com.csv
 - deals_exp.csv
 - 02_silver_filtered
 - activities_com.csv
 - activities_exp.csv
 - deals_com.csv
 - deals_exp.csv
 - 03_silver_enriched
 - contact_metrics_com.csv
 - contact_metrics_exp.csv
 - contact_metrics.csv
 - notebooks
 - .quarto
 - freeze
 - idx
 - xref
 - 01_bronze_data.ipynb
 - 02_1_silver_standardized.ipynb (active)
 - 02_2_silver_filtered.ipynb
 - 02_3_silver_enriched.ipynb
 - 03_gold_data.ipynb
 - EDA_contactabilidad_quar...
 - EDA_churn.ipynb
 - EntendimientoNegocio.p...
 - Graficas.ipynb
 - stages_dict.json
 - Training ML Churn Comer...
 - scripts
 - .env
 - service_account.json

The main notebook area contains the following code sections:

Import Bronze Data

```
[3] # Import Bronze Data from csv
# Activities
df_activities_com = pd.read_csv(r'..\data\output_bronze\activities_com.csv', dtype=str)
df_activities_exp = pd.read_csv(r'..\data\output_bronze\activities_exp.csv', dtype=str)

# Deals
df_deals_com = pd.read_csv(r'..\data\output_bronze\deals_com.csv', dtype=str)
df_deals_exp = pd.read_csv(r'..\data\output_bronze\deals_exp.csv', dtype=str)
```

MAP DATA

Restructuring JSON

```
[4] # Import Bronze Data from JSON
with open(r'..\data\output_bronze\json_deals.json', "r") as json_file:
    json_deals_metadata = json.load(json_file)

with open(r'..\data\output_bronze\json_activities.json', "r") as json_file:
    json_act_metadata = json.load(json_file)

with open(r'..\data\output_bronze\act_col.json', "r") as json_file:
    act_col = json.load(json_file)

with open(r'..\data\output_bronze\deals_col.json', "r") as json_file:
    deals_col = json.load(json_file)

with open('stages_dict.json', 'r') as f:
    stages_dict = json.load(f)
```

Mapping Columns

```
[7] # Restructuring metadata - Deals
restructured_deals = restructure_metadata(json_deals_metadata)

[8] # Restructuring metadata - Activities
restructured_activities = restructure_metadata(json_act_metadata)

[9] # mapping columns - Activities
act_map = {field['key']: field['name'] for field in act_col}

[10] # mapping activities
df_activities_com.rename(columns=act_map, inplace=True)
df_activities_exp.rename(columns=act_map, inplace=True)

[11] # mapping columns - Deals
deals_map = {field['key']: field['name'] for field in deals_col}

[12] # mapping activities
df_deals_com.rename(columns=deals_map, inplace=True)
df_deals_exp.rename(columns=deals_map, inplace=True)
```

https://github.com/datafla/Modelo-Predictivo-Churn-Comercial/blob/main/notebooks/02_1_silver_standardized.ipynb

Anexo 4. Procesamiento de datos capa Plata (subcapa de filtrado)

The screenshot shows a Jupyter Notebook interface with the following components:

- EXPLORER (Left Sidebar):** Displays a file tree structure.
 - OPEN EDITORS:** Shows the active file '02_2_silver_filtered.ipynb'.
 - EXPERIENCIA:** A folder containing various data files.
 - data:** Contains files like 'act.col.json', 'activities.com.csv', 'activities.exp.csv', 'deals.col.json', 'deals.com.csv', 'deals.exp.csv', 'json.activities.json', and 'json.deals.json'.
 - output_bronze:** Contains 'act.col.json'.
 - output_gold:** Contains 'contact_metrics_clean.csv'.
 - output_silver:** Contains '01_silver_standardized' folder with 'activities.com.csv', 'activities.exp.csv', 'deals.com.csv', and 'deals.exp.csv'.
 - 02_silver_filtered:** Contains 'activities.com.csv', 'activities.exp.csv', 'deals.com.csv', and 'deals.exp.csv'.
 - 03_silver_enriched:** Contains 'contact_metrics.com.csv', 'contact_metrics.exp.csv', and 'contact_metrics.csv'.
 - notebooks:** Contains various notebook files like '01_bronze_data.ipynb', '02_1_silver_standardized.ipynb', '02_2_silver_filtered.ipynb' (selected), '02_3_silver_enriched.ipynb', '03_gold_data.ipynb', 'EDA_contactabilidad.quar...', 'EDA_churn.ipynb', 'EntendimientoNegocio.p...', 'Graficas.ipynb', 'stages.dict.json', and 'Training ML Churn Comer...'.
 - scripts:** Contains '.env' and 'service_account.json'.
- MAIN AREA:** Displays the code for the '02_2_silver_filtered.ipynb' notebook.
 - Import Standardized Data:**

```
# Export Standardized Data to CSV

# Activities
df_activities_com = pd.read_csv(r'..\data\output_silver\01_silver_standardized\activities_com.csv', low_memory=False)
df_activities_exp = pd.read_csv(r'..\data\output_silver\01_silver_standardized\activities_exp.csv', low_memory=False)

# Deals
df_deals_com = pd.read_csv(r'..\data\output_silver\01_silver_standardized\deals_com.csv', low_memory=False)
df_deals_exp = pd.read_csv(r'..\data\output_silver\01_silver_standardized\deals_exp.csv', low_memory=False)
```
 - DATA SELECTION**
 - Columns Selection - Deals:**

```
# filtering deals columns
columns = [
    'org_id.value', # to merge with pipeline
    'Negocio creado el',
    'Fecha de ganado',
    'Fecha de cierre prevista',
    'Origen',
    'Tipo de cliente',
    'Tiempo de contacto (min)',
]

df_deals_com = df_deals_com[columns]
```
 - Columns Selection - Activities:**

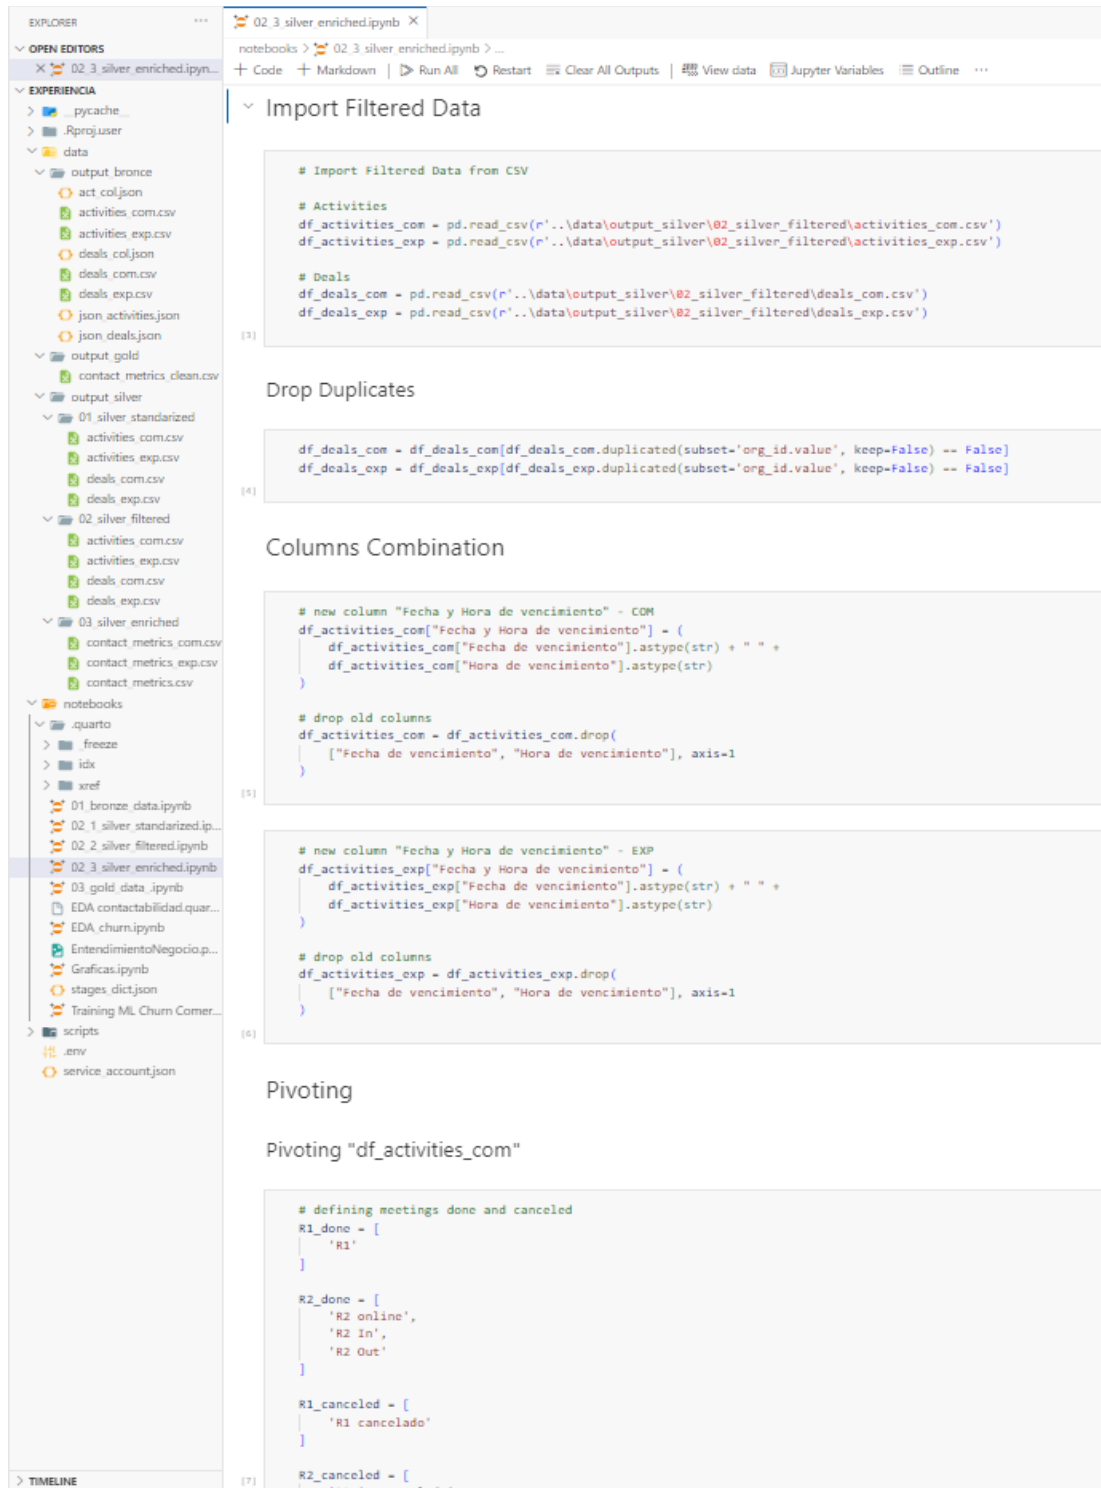
```
# filtering activities columns
columns = [
    'Negocio',
    'Organización',
    'org_name',
    'Tipo',
    'Fecha de vencimiento',
    'Hora de vencimiento',
    'Hora en que se marcó como completada'
]

df_activities_com = df_activities_com[columns]
df_activities_exp = df_activities_exp[columns]
df_activities_churn = df_activities_churn[columns]

# review the selected columns
```

https://github.com/datafla/Modelo-Predictivo_Churn-Comercial/blob/main/notebooks/02_2_silver_filtered.ipynb

Anexo 5. Procesamiento de datos capa Plata (subcapa de enriquecimiento)



Import Filtered Data

```
# Import Filtered Data from CSV

# Activities
df_activities_com = pd.read_csv(r'..\data\output_silver\02_silver_filtered\activities_com.csv')
df_activities_exp = pd.read_csv(r'..\data\output_silver\02_silver_filtered\activities_exp.csv')

# Deals
df_deals_com = pd.read_csv(r'..\data\output_silver\02_silver_filtered\deals_com.csv')
df_deals_exp = pd.read_csv(r'..\data\output_silver\02_silver_filtered\deals_exp.csv')
```

Drop Duplicates

```
df_deals_com = df_deals_com[df_deals_com.duplicated(subset='org_id.value', keep=False) == False]
df_deals_exp = df_deals_exp[df_deals_exp.duplicated(subset='org_id.value', keep=False) == False]
```

Columns Combination

```
# new column "Fecha y Hora de vencimiento" - COM
df_activities_com["Fecha y Hora de vencimiento"] = (
    df_activities_com["Fecha de vencimiento"].astype(str) + " " +
    df_activities_com["Hora de vencimiento"].astype(str)
)

# drop old columns
df_activities_com = df_activities_com.drop(
    ["Fecha de vencimiento", "Hora de vencimiento"], axis=1
)

# new column "Fecha y Hora de vencimiento" - EXP
df_activities_exp["Fecha y Hora de vencimiento"] = (
    df_activities_exp["Fecha de vencimiento"].astype(str) + " " +
    df_activities_exp["Hora de vencimiento"].astype(str)
)

# drop old columns
df_activities_exp = df_activities_exp.drop(
    ["Fecha de vencimiento", "Hora de vencimiento"], axis=1
)
```

Pivoting

Pivoting "df_activities_com"

```
# defining meetings done and canceled
R1_done = [
    'R1'
]

R2_done = [
    'R2 online',
    'R2 in',
    'R2 Out'
]

R1_canceled = [
    'R1 cancelado'
]

R2_canceled = [
    'R2 cancelado'
]
```

https://github.com/datafla/Modelo-Predictivo-Churn-Comercial/blob/main/notebooks/02_3_silver_enriched.ipynb

Anexo 6. Procesamiento de datos capa Oro

EXPLORER

OPEN EDITORS

03 gold_data.ipynb

notebooks > 03 gold_data.ipynb > ...

+ Code

+ Markdown

Run All

Restart

Clear All Outputs

View data

Jupyter Variables

Outline

...

EXPERIENCIA

pycache...

.Rproj.user

data

output bronze

act.col.json

activities.com.csv

activities.exp.csv

deals.col.json

deals.com.csv

deals.exp.csv

json.activities.json

json.deals.json

output gold

contact.metrics.clean.csv

output silver

01 silver.standardized

activities.com.csv

activities.exp.csv

deals.com.csv

deals.exp.csv

02 silver.filtered

activities.com.csv

activities.exp.csv

deals.com.csv

deals.exp.csv

03 silver.enriched

contact.metrics.com.csv

contact.metrics.exp.csv

contact.metrics.csv

notebooks

.quarto

freeze

idx

xref

01 bronze_data.ipynb

02_1 silver.standardized.ip...

02_2 silver.filtered.ipynb

02_3 silver.enriched.ipynb

03 gold_data.ipynb

EDA contactabilidad.quar...

EDA churn.ipynb

EntendimientoNegocio.p...

Graficas.ipynb

stages.dict.json

Training ML Churn Comer...

scripts

.env

service.account.json

Import Filtered Data

```
# import CSV to DataFrame
df = pd.read_csv(r'..\data\output_silver\silver_enriched\contact_metrics.csv')
```

```
df['Tipo de cliente'] = df['Tipo de cliente'].str.strip()
```

outliers treatment

Debido a que los campos seleccionados se tratan de conteos de actividades y variables categoricas nuestro dataset no cuenta con valores nulos

```
variable="Total_Actividades_com"
fig = px.box(
    df,
    y=variable,
    points="all",
    title=f'Box Plot de {variable}',
    template="plotly_white"
)
fig.update_layout(width=400, height=500)
fig.show()
```

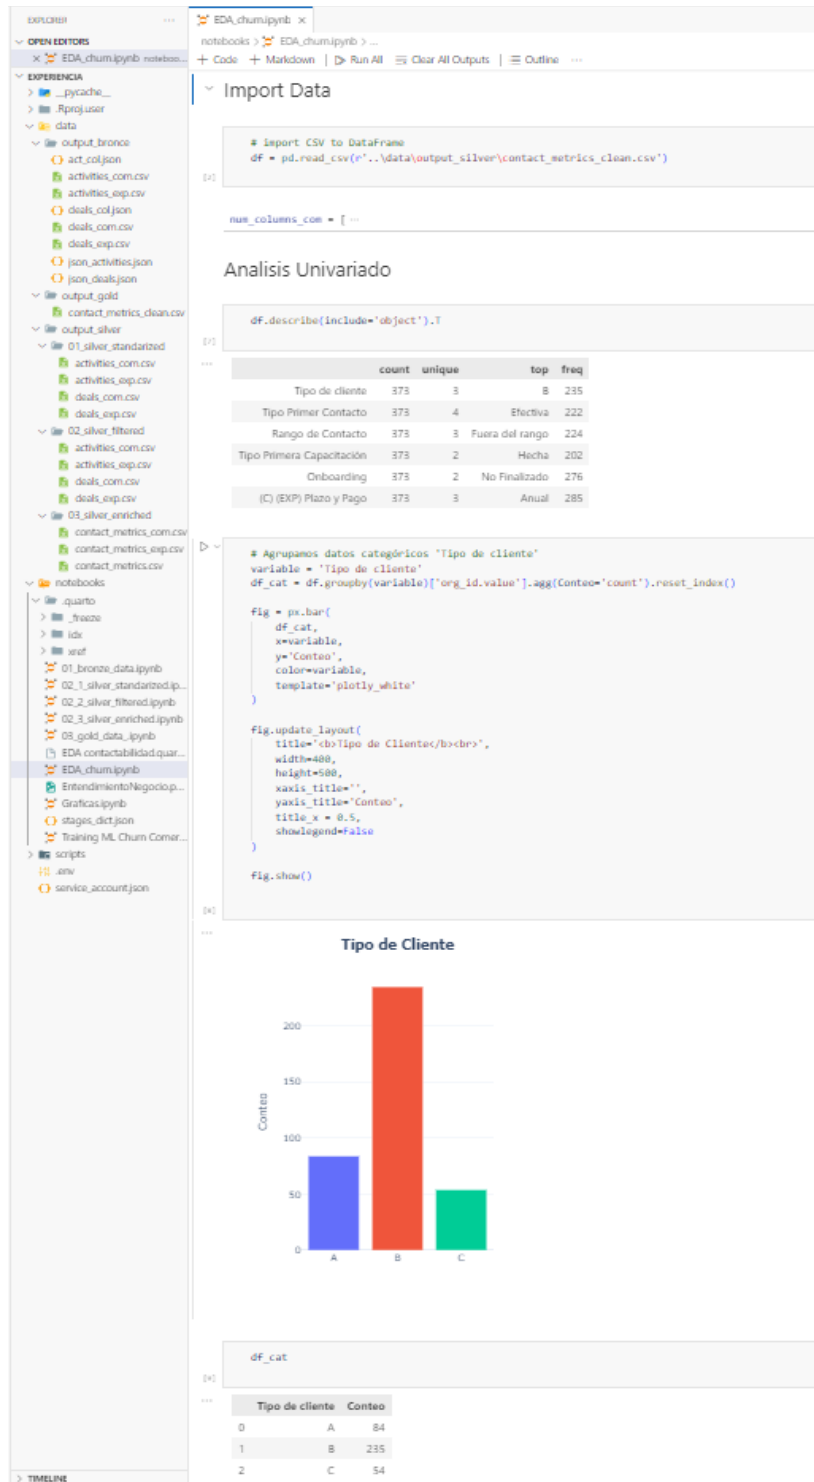
Box Plot de Total_Actividades_com

```
fig = px.histogram(
    df,
    x=variable,
    title=f'Histograma de {variable}',
    template="plotly_white",
    nbins=30
)
fig.update_layout(width=400, height=500)
fig.show()
```

Histograma de Total_Actividades_com

https://github.com/datafla/Modelo-Predictivo_Churn-Comercial/blob/main/notebooks/03_gold_data.ipynb

Anexo 7. Análisis exploratorio de datos



https://github.com/datafla/Modelo-Predictivo_Churn-Comercial/blob/main/notebooks/EDA_churn.ipynb

Anexo 8. Entrenamiento de Modelos

EXPLORER

Training ML Churn Comercial .ipynb

notebooks > Training ML Churn Comercial .ipynb > ...

+ Code + Markdown | ▶ Run All | 🔄 Restart | 🗑️ Clear All Outputs | 📊 View data | 📄 Jupyter Variables | 📖 Outline

OPEN EDITORS

Training ML Churn Comercial...

EXPERIENCIA

__pycache__

__projuser

data

output_bronze

act_col.json

activities_com.csv

activities_exp.csv

deals_col.json

deals_com.csv

deals_exp.csv

json_activities.json

json_deals.json

output_gold

contact_metrics_clean.csv

output_silver

01_silver_standardized

activities_com.csv

activities_exp.csv

deals_com.csv

deals_exp.csv

02_silver_filtered

activities_com.csv

activities_exp.csv

deals_com.csv

deals_exp.csv

03_silver_enriched

contact_metrics_com.csv

contact_metrics_exp.csv

contact_metrics.csv

notebooks

quarto

_freeze

idx

srcif

01_bronze_data.ipynb

02_1_silver_standardized.ip...

02_2_silver_filtered.ipynb

02_3_silver_enriched.ipynb

03_gold_data.ipynb

EDA_contactabilidad.quar...

EDA_churn.ipynb

EntendimientoNegocio.ip...

Graticas.ipynb

stages_dict.json

Training ML Churn Comer...

scripts

env

service_account.json

Sección 1: Importacion de Librerias

```

import pandas as pd
import numpy as np
from scipy.stats import chi2_contingency
from scipy.stats import f_oneway
from imblearn.over_sampling import SMOTE
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix, recall_score, f1_score
import matplotlib.pyplot as plt
import seaborn as sns

```

Sección 2: Carga de Datos

```

# Import CSV to DataFrame
df = pd.read_csv(r'..\data\output_gold\contact_metrics_clean.csv')

```

Sección 3: Selección de Variables

```

num_columns_com = [ ...

```

ANÁLISIS DE CORRELACION LINEAL

```

subset_cols = num_columns_com + num_columns_exp + label ...

corr_matrix = df_subset.corr()

plt.figure(figsize=(10, 6))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2F", linewidths=0.5)
plt.title("Matriz de Correlación")
plt.show()

```

Matriz de Correlación

	Total_Actividades_com	Total_Llamadas_com	Llamadas_Efectivas_com	Llamadas_No_Efectivas_com	WA_Seguiemiento_com	Reuniones_Hechas	Reuniones_Canceladas	Total_Actividades_exp	Total_Llamadas_exp	Llamadas_Efectivas_exp	Llamadas_No_Efectivas_exp	WA_Seguiemiento_exp	Kickoff_Hechas	Kickoff_Canceladas	Capacitaciones_Hechas	Capacitaciones_Canceladas	Churn Comercial
Total_Actividades_com	1.00	0.94	0.83	0.83	0.89	0.32	0.41	0.01	0.04	0.36	0.03	0.03	0.05	-0.03	0.08	0.12	0.35
Total_Llamadas_com	0.94	1.00	0.90	0.85	0.69	0.25	0.36	-0.02	-0.05	-0.07	-0.04	-0.07	0.11	-0.03	0.02	0.11	0.35
Llamadas_Efectivas_com	0.83	0.90	1.00	0.56	0.58	0.28	0.32	0.11	0.11	0.09	0.13	0.16	0.11	0.01	0.03	0.13	0.37
Llamadas_No_Efectivas_com	0.83	0.85	0.56	1.00	0.66	0.15	0.33	0.05	0.01	-0.02	0.05	0.03	0.09	-0.05	0.01	0.04	0.32
WA_Seguiemiento_com	0.89	0.69	0.58	0.66	1.00	0.23	0.35	0.05	-0.03	-0.02	-0.02	0.01	-0.00	-0.03	0.12	0.12	0.36
Reuniones_Hechas	0.32	0.25	0.28	0.15	0.23	1.00	0.14	0.12	0.07	0.05	0.05	0.12	0.06	0.02	0.09	0.06	0.34
Reuniones_Canceladas	-0.41	0.36	0.32	0.33	0.35	0.14	1.00	-0.03	-0.03	-0.02	-0.02	-0.04	0.06	0.05	-0.01	-0.00	0.33
Total_Actividades_exp	-0.01	-0.03	0.11	0.05	0.05	0.12	-0.01	1.00	0.77	0.61	0.66	0.82	-0.19	-0.04	0.33	0.22	0.35
Total_Llamadas_exp	-0.04	-0.05	0.11	0.01	0.03	0.07	-0.03	0.77	1.00	0.74	0.89	0.55	-0.28	-0.09	-0.00	0.08	0.21
Llamadas_Efectivas_exp	-0.04	-0.07	0.09	0.05	0.03	0.05	0.02	0.61	0.74	1.00	0.38	0.48	-0.33	-0.09	0.05	0.09	0.11
Llamadas_No_Efectivas_exp	-0.03	-0.04	0.11	0.05	-0.02	0.05	-0.02	0.66	0.89	0.38	1.00	0.45	-0.10	-0.05	-0.04	0.06	0.22
WA_Seguiemiento_exp	0.03	0.07	0.16	0.03	0.01	0.12	0.04	0.82	0.55	0.48	0.45	1.00	0.31	0.11	0.05	0.07	0.37
Kickoff_Hechas	-0.05	0.11	0.11	0.09	-0.00	0.00	-0.19	-0.29	-0.12	-0.18	-0.31	0.31	1.00	0.03	-0.02	0.00	0.30
Kickoff_Canceladas	-0.03	-0.03	0.01	0.05	0.03	0.07	0.05	0.04	0.09	0.06	0.05	0.11	0.03	1.00	0.02	0.15	0.30
Capacitaciones_Hechas	0.08	0.02	0.03	0.01	0.12	0.09	-0.01	0.33	-0.00	0.05	-0.34	0.05	-0.02	0.02	1.00	0.23	0.15
Capacitaciones_Canceladas	-0.12	0.11	0.13	0.04	0.12	0.06	-0.00	0.22	0.08	0.09	0.06	-0.07	0.06	0.15	0.23	1.00	0.10
Churn Comercial	-0.05	-0.05	-0.07	-0.02	-0.06	0.04	0.03	0.05	0.21	0.11	0.22	-0.02	-0.08	-0.00	-0.15	0.10	1.00

<https://github.com/datafla/Modelo-Predictivo-Churn-Comercial/blob/main/notebooks/Training%20ML%20Churn%20Comercial%20.ipynb>

Anexo 9. Data Frame resultante de la extracción de datos

df

✓ 0.0s Open 'df' in Data Wrangler

	org id.value	Tipo de cliente	Total Actividades com	Total Llamadas com	Llamadas Efectivas com	Llamadas No Efectivas com	WA Seguimiento com	Reuniones Hechas	Reuniones Canceladas	Tipo Primer Contacto	...
0	515.0	B	30	16	7	9	13	1	0	No Efectiva	...
1	2249.0	B	12	8	4	4	3	1	0	Efectiva	...
2	3120.0	B	9	6	5	1	2	1	0	Efectiva	...
3	5181.0	B	10	3	2	1	6	1	0	No Efectiva	...
4	8446.0	A	8	3	3	0	4	1	0	Efectiva	...
...	...	...	...	...	...	...	...	...	...	...	...
368	243947.0	B	4	1	1	0	1	2	0	Efectiva	...
369	244105.0	B	9	0	0	0	9	0	0	No tuvo	...
370	244173.0	A	8	2	2	0	4	2	0	Efectiva	...
371	244384.0	A	16	5	4	1	9	2	0	Efectiva	...
372	245287.0	B	5	0	0	0	4	1	0	No tuvo	...

373 rows × 26 columns

Anexo 10. Instrucciones para la reproducción del modelo

Las instrucciones para poder reproducir el presente proyecto en github se encuentran en los documentos: 01_READ ME_Capas-Medallion.txt y 02_READ ME_Entrenamiento de modelos.txt

 datafla	Monografia_UMSS-2025	5dafaf4 · 2 days ago	3 Commits
	__pycache__	First commit	2 days ago
	data	First commit	2 days ago
	notebooks	First commit	2 days ago
	scripts	First commit	2 days ago
	.gitignore	First commit	2 days ago
	01_READ ME_Capas-Medallion.txt	First commit	2 days ago
	02_READ ME_Entrenamiento de modelos.txt	First commit	2 days ago
	MODELO PREDICTIVO DE CLASIFICACIÓN DE ...	Monografia_UMSS-2025	2 days ago

Anexo 11.CD

Revise el CD adjunto, haga clic en el siguiente enlace para acceder a toda la documentación del proyecto o escanee el código QR a continuación.

https://github.com/datafla/Modelo-Predictivo_Churn-Comercial

